

极度稀疏矩阵的低秩补全 与潜在特征发现

基于 Soft-Impute 与 ALS 的矩阵补全实验

汇报小组：唐诚泉 刘程 余炆

1. 研究背景与问题描述
2. 低秩假设与奇异值分解
3. Soft-Impute 算法
4. ALS 算法与对比分析
5. 实验设计与结果
6. 结论与展望

在推荐系统中，用户-物品交互数据以矩阵形式组织。由于每个用户仅评价极少数物品，该矩阵极度稀疏。

典型场景：Netflix Prize 约 48 万用户、1.8 万电影，观测评分仅占 1.2%。

MovieLens-100k 数据集：

- 943 用户 $\times$ 1682 电影，100,000 条评分
- 评分范围 1-5，**原始缺失率 93.7%**

问题形式化：设观测矩阵为 $X \in \mathbb{R}^{m \times n}$ ，观测位置集合为 Ω ，旨在恢复低秩矩阵 Z 。

用户偏好并非独立：喜欢科幻的人通常也喜欢动作片；喜欢文艺片的人评分风格往往相似。这些**潜在特征**决定了评分，使评分矩阵可用少量潜在维度近似。

低秩假设：评分矩阵 M 可近似为两个瘦矩阵的乘积：

$$M \approx UV^T,$$

其中 $U \in \mathbb{R}^{m \times k}$ 为用户特征矩阵， $V \in \mathbb{R}^{n \times k}$ 为物品特征矩阵， $k \ll \min(m, n)$ 。

SVD 验证：对评分矩阵做奇异值分解，发现奇异值快速衰减，主要结构集中在前几个维度。

对任意矩阵 $M \in \mathbb{R}^{m \times n}$, 奇

异值分解为:

$$M = U\Sigma V^T = \sum_{i=1}^r \sigma_i u_i v_i^T,$$

其中 $r = \text{rank}(M)$, 奇异值满



足 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ 。

Eckart-Young-Mirsky 定

理: 截断 SVD M_k 是 M 的

最佳秩 k Frobenius 范数近

似。



直接优化矩阵的秩是组合困难的问题。Mazumder et al.

(2010) 将秩约束替换为**核范数**:

$$\|Z\|_* = \sum_{i=1}^r \sigma_i(Z),$$

即矩阵所有奇异值之和。核范数是 $\text{rank}(\cdot)$ 的有效凸松弛,

类比于 ℓ_1 范数是 ℓ_0 范数的凸松弛。由此得到凸优化问题:

$$\min_Z \frac{1}{2} \|P_\Omega(X) - P_\Omega(Z)\|_F^2 + \lambda \|Z\|_*.$$

该问题是凸的, 保证收敛到全局最优解。

Soft-Impute 的核心在于对 SVD 得到的奇异值施加**软阈值**操作:

$$(d - \lambda)_+ = \max(d - \lambda, 0).$$

该操作具有两重效果:

- 小于 λ 的奇异值被压至 0, 实现**自动降秩**;
- 大于 λ 的奇异值被收缩 λ , 起到**正则化**作用, 抑制噪声。

与硬截断相比, 软阈值在保留主要结构的同时对所有非零奇异值进行收缩, 模型选择更精细。

记 Z^{old} 为当前迭代矩阵, 更新规则为:

$$Z^{\text{new}} \leftarrow S_{\lambda}(P_{\Omega}(X) + P_{\Omega}^{\perp}(Z^{\text{old}})).$$

算法流程:

1. 构造辅助矩阵: 观测位置用真实值, 缺失位置用上一轮估计填充;
2. 对辅助矩阵执行 SVD 并施加软阈值算子 S_{λ} ;
3. 以阈值后的低秩矩阵作为新估计, 返回步骤 1 直至收敛。

ALS 直接对目标矩阵进行双线性参数化 $M \approx UV^T$, 交替固定一个因子求解另一个因子的最小二乘子问题。

优化目标为:

$$\min_{U, V} \sum_{(i,j) \in \Omega} (M_{ij} - (UV^T)_{ij})^2 + \lambda (\|U\|_F^2 + \|V\|_F^2).$$

固定 V 时, 对用户 i 的子问题为凸的最小二乘问题, 具有闭式解:

$$u_i = (V_{\Omega_i}^T V_{\Omega_i} + \lambda I)^{-1} V_{\Omega_i}^T M_{i, \Omega_i}.$$

类似地, 固定 U 可逐列更新 V 。

理论性质:

- 每个子问题为凸优化, 可高效求解;
- 子问题之间可并行化, 适合大规模分布式计算;
- Netflix Prize 获胜方案大量采用类似矩阵分解技术。

固有局限:

- 整体目标关于 (U, V) 联合非凸, 可能陷入局部最优;
- 潜在秩 k 需预先设定, 过大时存在过拟合风险;
- 对正则化参数与初始化较为敏感, 调参成本较高。

特性	Soft-Impute	ALS
优化性质	凸优化	非凸优化
收敛保证	全局最优	局部最优
秩的选择	自动（软阈值）	手动设定
核心操作	SVD + 软阈值	解多个最小二乘
超参数敏感度	较低	较高
并行性	每步一次 SVD	子问题可并行
代表性文献	Mazumder et al., 2010	Jain et al., 2013

Soft-Impute 在数学上更为优雅，具有全局收敛保证与自动秩选择机制；ALS 在工程实现上更为灵活，子问题天然可并行，但需承担非凸优化带来的局部最优风险。

数据集： MovieLens-100k


- 943 用户、1682 电影、100,000 条评分
- 评分范围：1–5 的整数评分
- 训练/测试划分：80% / 20%

评价指标：

- RMSE: $\sqrt{\frac{1}{|\Omega_{\text{test}}|} \sum_{(i,j)} (M_{ij} - \hat{M}_{ij})^2}$
- MAE: $\frac{1}{|\Omega_{\text{test}}|} \sum_{(i,j)} |M_{ij} - \hat{M}_{ij}|$

实验内容： 不同缺失率、不同潜在秩、奇异值谱分析、潜在特征语义解释。

在原始观测条目上按不同比例进一步隐藏部分评分，构造不同缺失率的训练集。




在原始观测条目上按不同比例进一步隐藏部分评分，构造不同缺失率的训练集。

主要发现：

- Soft-Impute 在所有缺失率下均优于 ALS，且优势随缺失率增加而更显著；
- 在 90% 缺失率下，Soft-Impute 的 RMSE 比 ALS 低 32.8%；
- 核范数正则化方法在高缺失率场景下具有更强的鲁棒性。

固定 80%/20% 训练/测试划分，比较不同预设秩对两种算法的影响。



不同潜在秩：Soft-Impute 对预设秩几乎不敏感（自动秩选择），ALS 随 rank 增加显著过拟合。

奇异值谱：第一个奇异值很大（约 4000），前 10 个迅速降至约 30。矩阵主要能量集中于少数几个奇异值，低秩假设在实际数据中得到有力验证。

通过 ALS 分解出的 V 矩阵，可对前几个潜在维度进行语义分析：

维度 1：” 严肃情感深度 vs. 轻松娱乐”

- 正向：FairyTale、Les Misérables（文艺/家庭片）
- 负向：Mr. Wrong、Kingpin（低俗喜剧）

维度 2：” 独立/小众 vs. 主流商业”

- 正向：The Stupids、Cabin Boy（另类片）
- 负向：Transformers、Michael Collins（主流片）

低秩分解提取到了具有可解释性的用户偏好模式。

理论层面：系统梳理了低秩矩阵补全的数学基础（SVD、低秩近似、核范数松弛、交替最小二乘）。

算法层面：Soft-Impute（凸优化、全局收敛、自动选秩）数学优雅；ALS（非凸分解、子问题可并行）工程灵活，但需承担局部最优风险。

实验层面：在 50%–90% 缺失率下验证了 Soft-Impute 的优越性；奇异值谱快速衰减支持低秩假设；潜在特征具有语义可解释性。

未来方向：

- 加权正则化与差异化模型约束
- 时间动态模型与用户偏好演化
- 冷启动问题与辅助信息融合
- 深度学习方法（AutoEncoder、Neural CF）

谢谢聆听！ 欢迎提问