

# 大数据解析与应用导论

## Introduction to Big Data Analytics and Application

授课教师: 赵春晖

# 第一章 绪论

1.

课程综述1（历史背景）

2.

课程综述2（实际应用）

3.

课程综述3（基本内容1）

4.

课程综述3（基本内容2）

5.


统计基础

# 本小节大纲

- ◆ 什么是多元统计分析
- ◆ 多元统计分析的研究对象和方法

# (一) 多元统计分析的关键词


**多元**：多个变量（或称因素、指标）



**统计**：指对某一现象有关的数据的搜集、整理、计算和分析等。

## (二) 什么是多元统计分析

在实际问题中，很多随机现象涉及到的**变量不止一个，而经常是多个变量**，而且这些变量间又**存在一定的联系**。我们常常需要处理多个变量的观测数据。



## (二) 什么是多元统计分析

如何对观测数据进行有效的分析和研究？

- 做法1：把多个随机变量分开分析（忽视了变量之间的相关性，会丢失信息，也不容易取得好的研究结果）。一元统计分析：研究一个随机变量统计规律的学科。
- 做法2：针对多个随机变量同时进行分析研究。采用多元统计分析方法，通过对多个随机变量观测数据的分析，来研究变量之间的相互关系以及揭示这些变量内在的变化规律。

## (二) 什么是多元统计分析

下表给出从中学某年级随机抽取的12名学生中5门主要课程期末考试成绩

举 例

| 序号 | 政治  | 语文 | 外语 | 数学  | 物理  |
|----|-----|----|----|-----|-----|
| 1  | 99  | 94 | 93 | 100 | 100 |
| 2  | 99  | 88 | 96 | 99  | 97  |
| 3  | 100 | 98 | 81 | 96  | 100 |
| 4  | 93  | 88 | 88 | 99  | 96  |
| 5  | 100 | 91 | 72 | 96  | 78  |
| 6  | 90  | 78 | 82 | 75  | 97  |
| 7  | 75  | 73 | 88 | 97  | 89  |
| 8  | 93  | 84 | 83 | 68  | 88  |
| 9  | 87  | 73 | 60 | 76  | 84  |
| 10 | 95  | 82 | 90 | 62  | 39  |
| 11 | 76  | 72 | 43 | 67  | 78  |
| 12 | 85  | 75 | 50 | 34  | 37  |

## (二) 什么是多元统计分析

上表提供的数据，如果用一元统计方法，势必要把多门课程分开分析，每次分析处理一门课的成绩。这样处理，由于忽视了课程之间可能存在的相关性，因此，一般说来，丢失信息太多。分析的结果不能客观全面地反映某年级学生的学习情况。

这里要讨论的多元分析方法，它同时对多门课程成绩进行分析。这样的分析对这些课程之间的相互关系、相互依赖性等都能提供有用的信息。



## (二) 什么是多元统计分析

### ■ 多元统计分析

研究**多个随机变量**之间相互依赖关系以及内在统计规律性的理论和统计方法的总称。

- **研究的对象**就是**多维随机向量**。
- **研究的内容**既包括一元统计学中某些方法的直接推广，也包括多个随机变量特有的一些问题。

多元统计分析是一类范围很广的理论和方法，是统计学的一个重要分支，也是机器学习的基础。

### (三) 多元统计分析的对象和内容

综上所述，多元分析以  $p$  个变量的  $n$  次观测数据组成的数据矩阵为依据。

$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \cdots & \cdots & \cdots & \cdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

根据实际问题的需要，给出种种方法。

英国著名统计学家M. 肯德尔 (M. G. Kendall) 在《多元分析》一书中把多元分析所研究的内容和方法概括为以下几个方面。

# (三) 多元统计分析的对象和内容

## 1、简化数据结构(降维问题)

- 通过变量变换等方法使相互依赖的变量变成互不相关的;
- 或把高维空间的数据投影到低维空间,使问题得到简化而损失的信息又不太多。

--主成分分析  
--因子分析  
--对应分析

## 2、分类与判别(归类问题)

- 对所考查的对象(样品点或变量)按相似程度进行分类(或归类)。

--聚类分析  
--判别分析

# (三) 多元统计分析的对象和内容

## 3. 变量间的相互联系

相互依赖关系：分析一个或几个变量的变化是否依赖于另一些变量的变化？如果是，建立变量间的定量关系式，并用于预测或控制。

预测或控制--回归分析

两组变量间的相互关系--典型相关分析

一组变量依赖另一组变量的变化关系--偏最小二乘回归分析

# (三) 多元统计分析的对象和内容

## 4、多元数据的统计推断

参数估计和假设检验问题，特别是多元正态分布的均值向量和协差阵的估计和假设检验等问题。

## 5、多元统计分析的理论基础

- 包括多维随机向量及多维正态随机向量，及由此定义的各种多元统计量，推导它们的分布并研究其性质，研究它们的抽样分布理论。
- 这些不仅是统计估计和假设检验的基础，也是多元统计分析的理论基础