

大数据解析与应用导论

Introduction to Big Data Analytics and Application

授课教师: 赵春晖

第一章 绪论

1.

课程综述1（历史背景）

2.

课程综述2（实际应用）

3.

课程综述3（基本内容1）

4.

课程综述3（基本内容2）

5.

统计基础

本小节大纲


- ◆ 多元统计数据的图表示法
- ◆ 多元统计分析的简单指标

(四) 多元统计数据的图表示法

图形有助于对所研究的数据的直观了解, 一维或二维数据的图形容易得到, 三维图形虽也可以画出, 但并不方便.

三维以上图形如何表示? 目前尚未有公认的方法.

设变量个数为 p , 观测次数为 n , 第 k 次观测值记为 $X_{(k)} = (x_{k1} \ x_{k2} \ \dots \ x_{kp})$
($k=1, 2, \dots, n$)



(四) 多元统计数据的图表示法

——统计过程监测图


从单变量到多变量

■ 常见的单变量统计控制图

- Shewhart
- CUSUM
- EWMA

■ 从单变量到多变量统计控制图


- PCA
- PLS




- 可同时监视多个过程变量
- 可监视变量之间的相关性变化

(四) 多元统计数据的图表示法—轮廓图


表中12个学生学习成绩的轮廓图如下：



(四) 多元统计数据的图表示法—雷达图




(四) 多元统计数据的图表示法 ——调和曲线图



(四) 多元统计数据的图表示法

— 散布图矩阵



（四）多元统计数据的图表示法 ——其他

在多元数据的图表示法中，还有**星座图**、**脸谱图**、**装饰图**等表示法。

多元数据的图表示法的**难点在于变量过多**。

如果有一种方法可以把高维数据投影到二维空间(平面)中去，并且在投影过程中不会过多地损失原有数据信息的话，就可以使用通常方法在平面上画出这些本来是高维数据的图形来。

(五) 多元统计分析的简单指标

- 统计分析是数据分析的主要工具
- 完整的数据分析过程包括
 - ✓ 数据的采集（数据可靠性、完备性、相关性，各种数据类型如极大型指标、极小型指标、居中型指标，时变的或静态的等等）
 - ✓ 数据的清洗：**格式标准化、异常数据清除、错误纠正、缺损值处理、时间校准等**
 - ✓ 数据的分析（模型的适用性）

统计学为数据分析过程提供了一套完整的科学的方法论。

(五) 多元统计分析的简单指标

整理好的数据具有如下结构：

指 标 (属性)

对象的
观察值
样本

编号	x_1	x_2	x_3	x_4	...	x_m
1						
2	x_{11}					
3	x_{21}					
...	x_{31}					
n	x_{n1}					

数据是信息载体，需要分析数据的主要特征。一些简单的统计指标可以对研究对象的做一些定量刻画。

（五）多元统计分析的简单指标

——基础（平均数）

疫情期间，大家都在家工作和学习。

现在某大学有**2**万名师生，针对他们在家的每天学习时间进行一次统计，那么他们的每天平均学习时间是多少？这个值叫做**总体平均数**。

假设现在你需要估算全校师生的时间。

可以从全校学生中随机选一批，这 n 个学生就是你的样本。拿这 n 个师生的学习时间相加并除以 n ，你就得到了**样本平均数**。这个数就是你估算出来的全校师生在家平均每天学习时间。

（五）多元统计分析的简单指标

——基础（平均数）

□ 样本平均数会不会等于总体平均数？

很显然这和你的“手气”有关——不过大多数情况下是
不会相等的。

□ 既然样本平均数不等于总体平均数，要它还有用吗？

有！因为样本平均数是总体平均数的无偏估计。这种估算方法没有系统上的偏差，而产生误差的原因只有一个：随机因素（也就是你的手气好坏造成的）。

(五) 多元统计分析的简单指标—均值

- (1) 单变量的均值 (mean)

- 均值作为一组数据的代表，反映该组数据平均水平，计算公式如下：

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- 性质1：

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

Matlab命令：mean(x)

(五) 多元统计分析的简单指标—方差

❖ (2) 方差 (variance)

- 方差用于衡量数据的集中或分散程度，公式为：

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Matlab命令：var(x)

- 标准差 (standard deviation) 是观测值与均值间的平均距离，公式为：

$$S = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Matlab命令：std(x)

(五) 多元统计分析的简单指标—方差

❖(2)方差 (variance)




图1. 不同方差数据示意图：变异性越大，说明指标对各种场景的遍历性越强，提供的信息越充分，信息量越大。

(五) 多元统计分析的简单指标—协方差

❖ (3)两个变量的协方差 (covariance)

➤ 协方差用于衡量数据的协变趋势，公式为：

$$\text{cov} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

记为 $c(x, y) = \sigma_{xy}$. 若 $x = y$, $c(x, x) = v(x) = \sigma^2$

若 X 和 Y 的均值为零，协方差 $c(x, y) = \frac{1}{n} x^T y$

如果 X 与 Y 是不相关的，二者之间的协方差就是0。

Matlab命令: `cov(x,y)`

(五) 多元统计分析的简单指标—相关系数

❖ (4) 相关系数(correlation coefficient)

- 相关系数是对于变量而言，第 j 个和第 k 个变量之间的相关系数公式为：

$$\text{corr} = \frac{\sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)}{\sqrt{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 \sum_{i=1}^n (x_{ik} - \bar{x}_k)^2}}$$

- 相关系数大小在区间 $[-1,1]$ 之间，也可写为：

$$\text{corr} = \frac{\text{cov}(x_j, x_k)}{\sqrt{\text{var}(x_j)\text{var}(x_k)}}$$

- (标准化变换不改变相关系数)