

大数据解析与应用导论

Introduction to Big Data Analytics and Application

授课教师: 赵春晖

第二章 绪论数据预处理及特征提取

1.

数据清洗

2.

数据转换

3.

主成分分析1（基本概念）

4.

主成分分析2（算法）

5.


实例应用

(一) 什么是数据清洗



- 海量原始数据中存在大量不完整, 有异常的数据
- 分析错误的数据会导致分析结果的偏差

数据清洗：对“脏数据”进行处理



(二) 缺失值处理

姓名	身高	体重	...	血糖值
XX	XX	XX	...	XX
XX	XX	XX	...	XX
XX	XX		...	XX
XX	XX	XX	...	XX
XX	XX	XX	...	XX
XX	XX	XX	...	XX

缺失数据：

□ 空单元表示

□ NaN

缺失值处理方法


删去整条数据

删除法的优点：
简单，保证数据的准确性

删除法的缺点：
数据成本高，其余数据可能已包括大部分信息，删去浪费

插补

(二) 缺失值处理




(三) 异常值处理

异常值分析：检测数据是否有输入错误或者含有不合常理的数据

□ 影响模型

□ 影响分析结果



异常值检查

简单统计量分析

3σ 准则

箱型图分析


(三) 异常值处理

简单统计量分析

计算数据的统计量，进行分析

最常用的是最大值最小值并分析是否合理

- 最大年龄是200？
- 体重出现负数？



(三) 异常值处理

3 σ 准则

正态分布3倍标准差之外为异常

1倍标准差之内：68.3%

2倍标准差之内：95.5%

3倍标准差之内：99.7%


不符合标准分布：

定义远离均值的多少倍标准差作异常值

举个例子：

均值是10，标准差是2，定义远离3倍标准差就是异常值

在4~16之间的数字为正常



(三) 异常值处理

箱型图分析

箱型图外部为异常


上四分位数：全部数据中有1/4的数据比它大，记作 Q_U

下四分位数：全部数据中有1/4的数据比它小，记作 Q_L

$Q_U \sim Q_L$ 之间包含了一半的数据，记 $IQR = Q_U - Q_L$

异常数据：小于 $Q_L - 1.5IQR$ ，或者大于 $Q_U + 1.5IQR$

箱型图具有比较好的鲁棒性



(四) 一致性分析


不一致性：数据的矛盾性和不相容性

姓名	上班方式	...	是否有车
XXX	XXX	...	XX
XXX	开车	...	否
XXX	XXX	...	XX

姓名	满意度	...	频率
XXX	XXX	...	XX
XXX	10	...	很少去
XXX	XXX	...	XX



(五) 总结



数据是分析的对象和基础，了解数据特性，选择适合方法