

大数据解析与应用导论

Introduction to Big Data Analytics and Application

授课教师: 赵春晖

第二章 数据预处理及特征提取

1.

数据清洗

2.

数据转换

3.

主成分分析1


4.

主成分分析2


5.

实例应用

(一) 主成分分析简介



(一) 主成分分析简介



- 主成分分析 (Principle Component Analysis, PCA) 是一种**通过线性变换，将原始数据的多个变量组合成相互正交的少数几个能充分反映总体信息的指标**，以便于进一步分析。

尽可能保留原始数据信息



分析后的变量相互独立

- 理想弹簧运动规律的测定实验。红球连接在弹簧之上，从平衡位置沿x轴拉开一定的距离然后释放，**显然理想情况下，红球的运动只在x轴方向上发生**。然而，对于三个相机Camera ABC来说，**每个相机都会以自己作为坐标系原点，收集到一系列二维的图像**，则通过所有相机收集到的数据可写作： $[(x_A, y_A), (x_B, y_B), (x_C, y_C)]$



此例PCA的作用：

收集到的冗余数据

主成分分析
PCA


剔除冗余变量
化归到红球运动的x轴

(二) 主成分分析的几何解释





(二) 主成分分析的几何解释

主成分分析的几何解释




主成分分析的几何解释




主成分分析的几何解释

平移、旋转坐标轴



平移、旋转坐标轴


主成分分析的几何解释



(三) 主成分分析的数学模型

$$\begin{aligned}t_1 &= u_{11}X_1 + u_{21}X_2 + \cdots + u_{p1}X_p \\t_2 &= u_{12}X_1 + u_{22}X_2 + \cdots + u_{p2}X_p \\&\dots\dots\dots \\t_p &= u_{1p}X_1 + u_{2p}X_2 + \cdots + u_{pp}X_p\end{aligned}$$

线性组合的公式理解



(三) 主成分分析的数学模型

- 主成分分析满足如下的条件：

1. 每个主成分的系数平方和为1，即：

$$u_{1i}^2 + u_{2i}^2 + \cdots + u_{pi}^2 = 1$$

2. 主成分之间线性无关，即无重叠的信息。即

$$\text{Cov}(t_i, t_j) = 0, \quad i \neq j, \quad i, j = 1, 2, \dots, p$$

3. 主成分的方差依次递减，重要性依次递减，即

$$\text{Var}(t_1) \geq \text{Var}(t_2) \geq \cdots \geq \text{Var}(t_p)$$

注：

- 统计学中，方差越大，包含的信息量越大，降维后的主成分向量应包含尽可能大的方差。
- 当主成分变量个数大于1个时，为了避免信息重叠（相关），要求各主成分向量之间不相关。

(三) 主成分分析的数学模型

设原数据 $\mathbf{X}_{n \times p}$ （ n 个样本， p 个变量），线性变换的负载矩阵 $\mathbf{U}_{p \times m}$ （ p 个系数，保留 m 个主元），则主元矩阵 $\mathbf{T}_{n \times m}$ （ n 个样本， m 个主元）可由原数据的线性组合得到：

$$\mathbf{T} = \mathbf{X}\mathbf{U}$$

主成分分析的目标：使得每个主元所包含的信息最多（方差最大）。加上之前所述的三个约束，形成主成分分析的数学模型：

$$\begin{aligned} & \max t_i^T t_i \\ \text{s.t.} & \begin{cases} t_i^T t_j = 0 \\ u_i^T u_i = 1 \end{cases} \end{aligned}$$

其中， t_i 为第 i 个主元， t_j 为第 j 个主元， u_i 为第 i 个主元对应的权重向量。

(四) 主成分分析小结

主成分分析 PCA

分析基础：变量间具有相关性

分析目的：降维的同时尽可能少地损失原始数据信息

分析方法：基于约束条件对变量做线性组合进行优化求解

约束条件

- (1) 降维后主元间互不相关
- (2) 主成分按照方差大小依次降序排列
- (3) 每个主元方差尽可能大
- (4) 线性组合的系数向量模长为1