

大数据解析与应用导论

Introduction to Big Data Analytics and Application

授课教师: 赵春晖

第三章 判别分析

1.

基本原理

2.

距离判别

3.

Fisher判别

4.

贝叶斯判别


5.

SVM

一、距离判别的思想

- 两个总体的距离判别问题：设两个总体 G_1 和 G_2 ，对于一个新的样品 X ，要判断它来自哪个总体。
- 方法：按就近原则归类。求新样品 X 到 G_1 的距离与到 G_2 的距离之差，如果其值为正， X 属于 G_2 ；否则 X 属于 G_1 。
- 对于距离判别，合适的距离定义很重要。

如何定义 X 点两个总体的距离更好？




二、距离度量方法——欧氏距离

- 欧式距离，或称直线距离，是最简单的距离度量方法。
- 求解方法：设n维空间有两个坐标点 $X_1=(x_{11}, x_{12}, \dots, x_{1n})$ 和 $X_2=(x_{21}, x_{22}, \dots, x_{2n})$ ，则它们的欧氏距离定义为：

$$d(X_1, X_2) = \sqrt{(x_{11} - x_{21})^2 + (x_{12} - x_{22})^2 + \dots + (x_{1n} - x_{2n})^2}$$

- 特殊情况下，当空间维度 $n=2$ 时，欧氏距离即为平面上两点所成线段的长度。



$$c = \sqrt{a^2 + b^2}$$

二、距离度量方法——欧氏距离

举例

- 下图中横坐标 x_1 与纵坐标 x_2 分别表示重量（以kg为单位）和长度（以cm为单位）
- 此时有：

$$AB = \sqrt{5^2 + 10^2} = \sqrt{125}$$

$$CD = \sqrt{10^2 + 1^2} = \sqrt{101}$$


显然AB间的欧氏距离大于CD之间的欧氏距离。

- 若将长度 x_2 的单位改为mm，再次计算欧氏距离，有：

$$AB = \sqrt{50^2 + 10^2} = \sqrt{2600}$$

$$CD = \sqrt{100^2 + 1^2} = \sqrt{10001}$$

此时CD间的欧氏距离反而大于AB间的。




当变量的量纲和数量级不统一时，欧氏距离将带来不同的分析结果

三、距离度量方法——马氏距离




思考

下图中1、2两点哪个点应该与总体（原点）更接近？



三、距离度量方法——马氏距离

更合理的距离度量方式



马氏距离

- 马氏距离是印度统计学家马哈拉诺比斯 (*Mahalanobis*) 于1936年引入的距离
- 这种距离度量方法同时考虑了样本的方差和变量间的协方差

三、距离度量方法——马氏距离

马氏距离的计算方式

- 设 X 、 Y 是从均值向量为 μ ，协方差矩阵为 Σ 的总体 G 中抽取的两个样本

- X 与 Y 间的马氏距离定义为：


$$d(X, Y) = \sqrt{(X - Y)^T \Sigma^{-1} (X - Y)}$$

- 同时， X 与**总体 G** 间的马氏距离可以计算为：


$$d(X, G) = \sqrt{(X - \mu)^T \Sigma^{-1} (X - \mu)}$$

三、距离度量方法——马氏距离

欧氏距离与马氏距离的直观对比



欧氏距离



马氏距离

曼哈顿距离

- $$d(X_1, X_2) = |x_{11} - x_{21}| + |x_{12} - x_{22}| + \dots + |x_{1n} - x_{2n}|$$

A 10x10 grid with a gray background and white grid lines. Four black dots are located at the corners: top-left, top-right, bottom-left, and bottom-right. Three paths connect these dots: a red L-shaped path (top-left to top-right to bottom-right), a blue staircase path (top-left to bottom-right), and a yellow L-shaped path (bottom-left to bottom-right to top-right). A green diagonal line also connects the top-left and bottom-right dots.

四、其他距离衡量手段

余弦相似度与余弦距离


- 余弦相似度：对于n维空间有两个坐标点 $X_1=(x_{11}, x_{12}, \dots, x_{1n})$ 和 $X_2=(x_{21}, x_{22}, \dots, x_{2n})$ ，其夹角余弦值可以计算为：

$$\cos \theta = \frac{\sum_{i=1}^n x_{1i} x_{2i}}{\sqrt{\sum_{i=1}^n x_{1i}^2} \sqrt{\sum_{i=1}^n x_{2i}^2}}$$

其取值在 $[-1, 1]$ 之间，其值越高说明相似度越高

- 两点的余弦距离计算为：

$$d(X_1, X_2) = 1 - \cos \theta$$



- 余弦距离常用于文本检索与文本挖掘中，用于衡量文本或词向量的相似程度。

五、选择距离衡量手段的原则

□ 没有最好的方法，只有最适合的方法

□ 根据应用场景与数据类型，合理选择距离度量方式

- ✓ 欧氏距离用于直接衡量样本间的几何距离
- ✓ 马氏距离用于衡量给定样本总体条件下的距离
- ✓ 曼哈顿距离用于衡量样本间的绝对值距离，如行车路径长度
- ✓ 余弦距离用于衡量样本的方向差异，忽略样本各分量本身的幅度或数量级