

大数据解析与应用导论

Introduction to Big Data Analytics and Application

授课教师: 赵春晖

第三章 判别分析

1.

基本原理

2.

距离判别

3.

Fisher判别

4.

贝叶斯判别

5.



SVM

一、Fisher判别的思想


- 构造一个线性投影：

$$W = b_0 + b_1 X_1 + \cdots + b_p X_p$$

- 寻找投影方向，使两组数据投影后在直线上尽可能区分开



一、Fisher判别的思想




$$y_i = w^T x_i$$

满足类内紧凑，类间分离的原则

二、Fisher判别的优化目标

怎么评估类内的紧凑程度和不同类别之间的分离程度？



二、Fisher判别的优化目标

以两类数据为例，给定训练数据集 $D=\{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ ，其中样本 x_i 为 n 维向量，标签 y_i 为0或1， N_j 为第 j 类样本的个数， X_j 为第 j 类样本的集合，则第 j 类样本的类别中心和离差为


类别中心

$$\mu_j = \frac{1}{N_j} \sum_{x \in X_j} x (j = 0, 1)$$

类内离差

$$\Sigma_j = \sum_{x \in X_j} (x - \mu_j)(x - \mu_j)^T (j = 0, 1)$$

二、Fisher判别的优化目标



类内离差和
$$S_w = \Sigma_0 + \Sigma_1 = \sum_{x \in X_0} (x - \mu_0)(x - \mu_0)^T + \sum_{x \in X_1} (x - \mu_1)(x - \mu_1)^T$$

类间离差
$$S_b = (\mu_0 - \mu_1)(\mu_0 - \mu_1)^T$$

二、Fisher判别的优化目标

S_w 是类内离差和, S_b 是类间离差

$$\begin{array}{l} \min(w^T S_w w) \\ \max(w^T S_b w) \end{array}$$



$$\begin{array}{l} \min(w^T S_w w) \\ w^T S_b w = c \end{array}$$



$$S_b^{-1} S_w w = \lambda w$$

特征根分解问题

三、Fisher判别法计算步骤

■ 训练步骤

输入两个类别的原始数据矩阵



计算类别中心，类内离差和，类间离差



求解特征根分解问题
得到投影向量w

$$W^0 = \begin{bmatrix} x_{11}^0 & x_{12}^0 & \cdots & x_{1p}^0 \\ x_{21}^0 & x_{22}^0 & \cdots & x_{2p}^0 \\ \vdots & \vdots & \vdots & \vdots \\ x_{s1}^0 & x_{s2}^0 & \cdots & x_{sp}^0 \end{bmatrix}$$

$$W^1 = \begin{bmatrix} x_{11}^1 & x_{12}^1 & \cdots & x_{1p}^1 \\ x_{21}^1 & x_{22}^1 & \cdots & x_{2p}^1 \\ \vdots & \vdots & \vdots & \vdots \\ x_{t1}^1 & x_{t2}^1 & \cdots & x_{tp}^1 \end{bmatrix}$$

$$\bar{x}_j^0 = \frac{1}{s} \sum_{i=1}^s x_{ij}^0$$

$$\bar{x}_j^1 = \frac{1}{t} \sum_{i=1}^t x_{ij}^1$$

$$A = \begin{bmatrix} x_{11}^0 - \bar{x}_1^0 & x_{12}^0 - \bar{x}_2^0 & \cdots & x_{1p}^0 - \bar{x}_p^0 \\ x_{21}^0 - \bar{x}_1^0 & x_{22}^0 - \bar{x}_2^0 & \cdots & x_{2p}^0 - \bar{x}_p^0 \\ \vdots & \vdots & \vdots & \vdots \\ x_{s1}^0 - \bar{x}_1^0 & x_{s2}^0 - \bar{x}_2^0 & \cdots & x_{sp}^0 - \bar{x}_p^0 \end{bmatrix}$$

$$C = \begin{bmatrix} \bar{x}_{11}^0 - \bar{x}_1 & \cdots & \bar{x}_{1p}^0 - \bar{x}_p \\ \bar{x}_{11}^1 - \bar{x}_1 & \cdots & \bar{x}_{1p}^1 - \bar{x}_p \end{bmatrix}$$

$$B = \begin{bmatrix} x_{11}^1 - \bar{x}_1^1 & x_{12}^1 - \bar{x}_2^1 & \cdots & x_{1p}^1 - \bar{x}_p^1 \\ x_{21}^1 - \bar{x}_1^1 & x_{22}^1 - \bar{x}_2^1 & \cdots & x_{2p}^1 - \bar{x}_p^1 \\ \vdots & \vdots & \vdots & \vdots \\ x_{t1}^1 - \bar{x}_1^1 & x_{t2}^1 - \bar{x}_2^1 & \cdots & x_{tp}^1 - \bar{x}_p^1 \end{bmatrix}$$

$$S_1 = A^T A, S_2 = B^T B, S_w = S_1 + S_2$$

$$S_b = C^T C$$

$$S_b^{-1} S_w w = \lambda w$$

三、Fisher判别法计算步骤

■ 判别步骤

输入未知类别样本
 $x = (x_1, x_2, \dots, x_p)$



利用投影向量计算投影
 y 以及阈值 y_0



作判别

得到投影向量 w 之后，我们就可以对未知类别的新样本作判别了。

$$\begin{aligned}y &= wx \\ \bar{y}_0 &= w\mu_0 \\ \bar{y}_1 &= w\mu_1 \\ y_0 &= \frac{\bar{y}_0 + \bar{y}_1}{2}\end{aligned}$$

y_0 为投影后与两个类别相距
距离相等的点。

$y > \bar{y}_0$ x 属于第0类

$y < \bar{y}_0$ x 属于第1类

四、Fisher判别法应用举例

Python中的sklearn库提供了线性判别函数，可以直接调用。

```
class sklearn.discriminant_analysis.LinearDiscriminantAnalysis()
```

一些常用方法：

fit(self, X, y) 用于训练给定数据

predict(self, X) 用于预测新给出的X属于哪个类

四、Fisher判别法应用举例

例子

```
import numpy as np
```

```
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis
```

```
X = np.array([[-1, -1], [-2, -1], [-3, -2], [1, 1], [2, 1], [3, 2]])
```

```
y = np.array([1, 1, 1, 2, 2, 2])
```

```
clf = LinearDiscriminantAnalysis()
```


```
clf.fit(X, y)
```

```
clf.predict([[-0.8, -1]])
```

输出结果为1，即[-0.8,-1]点属于类别1

四、Fisher判别法应用举例

我们随机生成一些数据，蓝色红色属于两个不同类别。



左侧为原始数据，右侧为使用线性判别划分的数据，白色为分界线。