

大数据解析与应用导论

Introduction to Big Data Analytics and Application

授课教师: 赵春晖

第三章 判别分析

1.

基本原理

2.

距离判别

3.

Fisher判别

4.

贝叶斯判别

5.

SVM

一、Bayes判别的思想

贝叶斯方法的本质就是从结果推测出成因。

□ 比如你怀疑女神喜欢你，但你没有依据，所以你怀疑度比较低。有一天，女神给你带了早饭，这个证据会加重你对女神喜欢你的怀疑。

□ 如何量化证据和论断呢？贝叶斯提出什么叫“信”，什么叫“不信”，对某个假设的相信程度应该用一个概率来表示 $P(\text{假设})$ 。




Thomas Bayes
1702-1761

一、Bayes判别的思想

将贝叶斯思想用于判别分析，就得到贝叶斯判别。

- 贝叶斯判别法的前提条件是已经取得了对所关注对象相应的认识——**先验概率**。
- 根据新样本所包含的信息修正之前所获得的先验概率分布，获得新的**后验概率**。
- 利用新的后验概率分布进行各种**统计推断**




二、贝叶斯判别

- **贝叶斯判别规则**: 把某特征矢量 x 落入某类集群 θ 的条件概率当成分类判别函数 (概率判别函数), **条件概率最大** 的类为 x 所属的类别。
- 贝叶斯判别规则是以**错分概率或风险最小**为准则的判别规则。

$$P(\theta|x) = \frac{P(x|\theta)P(\theta)}{P(x)}$$

二、贝叶斯判别

- 贝叶斯公式是贝叶斯判别的基本工具，是以全概率法则为依据建立的。



条件概率

$$P(B|A) = \frac{P(AB)}{P(A)}$$

乘法定理

$$P(AB) = P(A)P(B|A)$$

全概率公式

$$P(A) = P(B_1)P(A|B_1) + P(B_2)P(A|B_2) + \cdots + P(B_n)P(A|B_n)$$

贝叶斯公式

$$P(B_i|A) = \frac{P(B_i)P(A|B_i)}{\sum_{j=1}^n P(B_j)P(A|B_j)}, \quad i = 1, 2, \dots, n.$$

三、贝叶斯判别实例

例1：办公室新来了一个雇员小王，小王是好人还是坏人大家都在猜测。按人们主观意识，一个人是好人或坏人的概率均为0.5。坏人总是要做坏事，好人总是做好事，偶尔也会做一件坏事，一般好人做好事的概率为0.9，坏人做好事的概率为0.2，一天，小王做了一件好事，小王是好人的概率有多大，你现在把小王判为何种人。

$$\begin{aligned} & P(\text{好人} / \text{做好事}) \\ &= \frac{P(\text{好人})P(\text{做好事} / \text{好人})}{P(\text{好人})P(\text{做好事} / \text{好人}) + P(\text{坏人})P(\text{做好事} / \text{坏人})} \\ &= \frac{0.5 \times 0.9}{0.5 \times 0.9 + 0.5 \times 0.2} = 0.82 \end{aligned}$$

$$\begin{aligned} & P(\text{坏人} / \text{做好事}) \\ &= \frac{P(\text{坏人})P(\text{做好事} / \text{坏人})}{P(\text{好人})P(\text{做好事} / \text{好人}) + P(\text{坏人})P(\text{做好事} / \text{坏人})} \\ &= \frac{0.5 \times 0.2}{0.5 \times 0.9 + 0.5 \times 0.2} = 0.18 \end{aligned}$$

0.82 > 0.18，判别结果：小王为好人

三、贝叶斯判别实例

例2：假定用血清甲胎蛋白法诊断肝癌，设 $C=\{\text{被检验者患有肝癌}\}$ ， $A=\{\text{被检验者被判断患有肝癌}\}$ 。已知

$$P(A|C) = 0.95, \quad P(\bar{A}|\bar{C}) = 0.90.$$

且在人群中患病的概率 $P(C)=0.0004$ ，现在若有一人被此检验法诊断为患有肝癌，求此人真正患有肝癌的概率 $P(C|A)$ 。

$$\begin{aligned} P(C|A) &= \frac{P(C)P(A|C)}{P(C)P(A|C) + P(\bar{C})P(A|\bar{C})} \\ &= \frac{0.0004 \times 0.95}{0.0004 \times 0.95 + 0.9996 \times 0.1} = 0.0038 \end{aligned}$$

因此，虽然检验法相当可靠，但是被诊断为肝癌的人实际患有肝癌的可能性并不大，这是一个值得思考的结果。

四、朴素贝叶斯

朴素贝叶斯分类法是基于**贝叶斯定理与特征条件独立假设**的分类方法。

朴素贝叶斯分类的任务：

每个数据样本用一个 n 维特征向量 $X = \{x_1, x_2, \dots, x_n\}$ 表示，分别描述 n 个特征 $A_1, A_2, \dots, A_n$ ，是样本的 n 个度量。假定有 m 个类 $C_1, C_2, \dots, C_m$ ，给定一个未知的数据样本 X ，分类器将预测 X 属于**具有最高后验概率（条件 X 下）**的类 C_i 。

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool	Normal	Strong	No
7	Overcast	Cool	Normal	Strong	Yes
8	Sunny	Mild	High	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
10	Rain	Mild	Normal	Weak	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Weak	Yes
14	Rain	Mild	High	Strong	No
15	Sunny	Cool	High	Strong	?

四、朴素贝叶斯

朴素贝叶斯的计算方法

$$P(C_i | X) = \frac{P(X | C_i)P(C_i)}{P(X)}$$

$P(X)$ 为常数



根本目标：找到使得 $P(X|C_i)*P(C_i)$ 最大的类别 C_i



类的先验概率 $P(C_i)=s_i/s$



朴素假设：假定属性值相互条件独立

$$P(X | C_i) = \prod_{k=1}^n P(x_k | C_i)$$

四、朴素贝叶斯

为什么“朴素”假设是可行的？

- 只要正确类的后验概率比其他类要高就可以得到正确的分类。所以即使概率估计不精确，一定程度上也不影响正确做出分类。
- 在数据预处理环节，通常会进行变量选择，高度相关的变量只保留其中一个，剩下的变量之间就接近于相互独立了。

四、朴素贝叶斯的应用

- 经典应用——**垃圾邮件过滤**：把邮件自动标记为垃圾邮件或正常邮件。



垃圾邮件内容不断创新，
也是蛮拼的.....



- 朴素贝叶斯模型会通过邮件中的诸多垃圾邮件**标志物**来判断邮件是否是垃圾邮件。这些标志物可能是词汇（例如是否有货币符号），也可能是其他特征（例如是否群发）

四、朴素贝叶斯的应用

- 计算**后验概率**，即在出现垃圾邮件标志物的前提下，邮件为垃圾邮件的可能性：

$$\Pr(\text{垃圾邮件}|\text{标志物}) = \frac{\Pr(\text{标志物}|\text{垃圾邮件})\Pr(\text{垃圾邮件})}{\Pr(\text{标志物})}$$

- 根据朴素贝叶斯假设，有：

$$\Pr(\text{标志物}|\text{垃圾邮件}) = \prod_i \Pr(\text{第}i\text{个标志物}|\text{垃圾邮件})$$

- 通过这种方式，避免了计算**多个联合分布**带来的高运算复杂度。

