

大数据解析与应用导论

Introduction to Big Data Analytics and Application

授课教师: 赵春晖

第三章 判别分析

1.

基本原理

2.

距离判别

3.

Fisher判别

4.


贝叶斯判别

5.

SVM

支持向量机 (SVM) 简介

分 类



支持向量机方法是建立在统计学习理论的VC维理论和结构风险最小原理基础上的，根据有限的样本信息在模型的复杂性（即对特定训练样本的学习精度，Accuracy）和学习能力（即无错误地识别任意样本的能力）之间寻求最佳折中，以期获得最好的推广能力（泛化能力）。

数据
数据



会分了

线性二分类问题

何谓线性可分？

以左图为例，在一个二维平面内，有两个类别的离散样本点，一条直线将两类样本分开。


如果一个线性函数，能将样本完全正确分开，这些数据即为线性可分的。

何谓超平面？

线性函数在一维空间为一个点，二维空间是一条直线，三维空间里是一个平面。如果不关注维数，线性函数被统称为——超平面。

线性二分类问题是用一个超平面将两类样本完全分开

关于分割超平面的思考



Any of these would be fine.....

.....but which one is the best?

分类精度?

模型泛化能力?

支持向量与间隔

问题的数学描述

- 假设给定一个特征空间上的训练数据集

$$\mathbf{T} = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), (\mathbf{x}_3, y_3) \dots (\mathbf{x}_N, y_N)\}$$

其中 $\mathbf{x}_i \in \mathbf{R}^n$, $y_i \in \{+1, -1\}$, $i = 1, 2, \dots, N$

- $\mathbf{x}_i$ 为第 i 个样本（若 $n > 1$, $\mathbf{x}_i$ 为向量）
- y_i 为 $\mathbf{x}_i$ 的类标签；+1 时为正例，-1 时为负例
- $(\mathbf{x}_i, y_i)$ 称为一个样本点
- 分割超平面表示为 $\mathbf{w} \cdot \mathbf{x} + b = 0$ （分类准确度高，泛化能力好）
其中 $\mathbf{w} = (w_1, w_2, \dots, w_n)$ 为超平面的法向量， b 是一个实数。



支持向量与间隔

支持向量的定义：

离超平面**最近**的几个训练样本点叫做**支持向量**

间隔的定义：

点到超平面的距离叫做**间隔**



支持向量与间隔

函数间隔：

$$\hat{\gamma}_i = y_i(\mathbf{w} \cdot \mathbf{x}_i + b)$$

乘以 y_i 是为了使间隔距离为非负数

用函数间隔来度量点到超平面的距离有什么问题？

点到直线的距离：

$$\frac{Ax_0 + By_0 + C}{\sqrt{A^2 + B^2}}$$

支持向量与间隔

几何间隔:

$$\gamma_i = y_i \left(\frac{\mathbf{w} \cdot \mathbf{x}_i + b}{\|\mathbf{w}\|} \right)$$

几何间隔与函数间隔关系:

$$\gamma_i = \frac{\hat{\gamma}_i}{\|\mathbf{w}\|}$$

最小几何间隔:

$$\gamma = \min_{i=1, 2, \dots, N} \gamma_i$$

线性可分支持向量机模型

如何使得超平面的泛化能力最优？

最大化最小几何间隔 $\max_{\mathbf{w}, b} \gamma$

如何使得超平面分类精度最优？

➤ 使得 y_i 与 $\mathbf{w} \cdot \mathbf{x}_i + b$ 同号

➤ 使得任意一点的几何距离大于等于支持向量的几何距离

$$\text{即 } y_i \left(\frac{\mathbf{w}}{\|\mathbf{w}\|} \cdot \mathbf{x}_i + \frac{b}{\|\mathbf{w}\|} \right) \geq \gamma$$

建模的目标：

- 1、尽可能使超平面分类准确；
- 2、尽可能使超平面的泛化能力更好。

线性可分支持向量机模型

SVM模型的表述:

$$\max_{\mathbf{w}, b} \gamma$$

$$s.t. \ y_i \left(\frac{\mathbf{w} \cdot \mathbf{x}_i + b}{\|\mathbf{w}\|} \right) \geq \gamma, i = 1, 2, \dots, N$$

将上述模型中的最小几何间隔改写成最小函数间隔:

$$\max_{\mathbf{w}, b} \hat{\gamma}$$

$$s.t. \ y_i (\mathbf{w} \cdot \mathbf{x}_i + b) \geq \hat{\gamma}, i = 1, 2, \dots, N$$

线性可分支持向量机模型

函数间隔的取值并不影响最优化问题的解，将 $\hat{\gamma} = 1$ 代入得：

$$\max_{\mathbf{w}, b} \frac{1}{\|\mathbf{w}\|}$$


$$s.t. \ y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, N$$

最大化 $\frac{1}{\|\mathbf{w}\|}$ 等价于最小化 $\frac{1}{2} \|\mathbf{w}\|^2$ ，进一步化简优化目标：

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$

$$s.t. \ y_i(\mathbf{w} \cdot \mathbf{x}_i + b) - 1 \geq 0, i = 1, 2, \dots, N$$

线性可分支持向量机模型



模型的求解其实仅仅与“**支持向量**”的分布有关，而**与其他训练点无关**，“支持向量”的分布决定了超平面的划分

模型求解目标

$$\min_{w,b} \frac{1}{2} \|w\|^2$$
$$s.t. \ y_i (w \cdot x_i + b) - 1 \geq 0, i = 1, 2, \dots, N$$