

大数据解析与应用导论

Introduction to Big Data Analytics and Application

授课教师: 赵春晖

第三章 判别分析

1.

基本原理

2.

距离判别

3.

Fisher判别

4.

贝叶斯判别

5.

SVM

线性可分支持向量机求解

线性可分支持向量机模型：

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$

$$s.t. \ y_i (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 \geq 0, i = 1, 2, \dots, N$$

目标函数是二次的

约束条件是线性不等式

凸优化问题

如何求解？

拉格朗日乘子法！！！！

线性可分支持向量机求解

拉格朗日乘子法

拉格朗日函数
$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^N \alpha_i (y_i (\mathbf{w} \cdot \mathbf{x}_i + b) - 1)$$

其中 α_i 是拉格朗日乘子且 $\alpha_i \geq 0$

□ 原问题是极小极大问题

$$\min_{\mathbf{w}, b} \max_{\alpha} L(\mathbf{w}, b, \alpha)$$

□ 原始问题的对偶问题，是极大极小问题

$$\max_{\alpha} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha)$$

线性可分支持向量机求解

□ 将拉格朗日函数 $L(\mathbf{w}, b, \alpha)$ 分别对 $\mathbf{w}, b$ 求偏导并令其等于0

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$$

$$\frac{\partial L}{\partial b} = 0 \Rightarrow 0 = \sum_{i=1}^N \alpha_i y_i$$

线性可分支持向量机求解

将上式带入拉格朗日函数中，可得：

$$\mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$$

$$0 = \sum_{i=1}^N \alpha_i y_i$$

$$\begin{aligned} L(\mathbf{w}, b, \alpha) &= \frac{1}{2} \|\mathbf{w}\|^2 - \alpha_i y_i (\mathbf{w} \cdot \mathbf{x}_i + b) + \sum_{i=1}^N \alpha_i \\ &= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j + \sum_{i=1}^N \alpha_i \\ &= \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \end{aligned}$$

线性可分支持向量机求解

求拉格朗日函数对 w 、 b 的极小，等同于求该函数对 α 的极大：

原始问题的对偶问题

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

$$\text{s.t.} \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, i = 1, 2, \dots, N$$

整理目标函数

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^N \alpha_i$$

$$\text{s.t.} \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, i = 1, 2, \dots, N$$

线性可分支持向量机求解

KKT条件:

$$\nabla_{\mathbf{w}} L = 0$$

$$\nabla_b L = 0$$

$$\nabla_{\alpha} L = 0$$

$$\alpha_i \geq 0$$

$$\alpha_i (y_i (\mathbf{w} \cdot \mathbf{x}_i + b) - 1) = 0$$

$$y_i (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 \geq 0$$

优化问题是强
对偶的!

当 $\alpha_i = 0$ 时, $y_i (\mathbf{w} \cdot \mathbf{x}_i + b) - 1$ 结果没有任何要求, 只要求样本被正确归类即可

当 $\alpha_i > 0$ 时,

$$b = y_i - \mathbf{w} \cdot \mathbf{x}_i \quad \text{将 } \mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \text{ 代入得}$$

$$b = y_j - \sum_{i=1}^N \alpha_i y_i (\mathbf{x}_i^T \mathbf{x}_j)$$

线性可分支持向量机求解

线性可分支持向量机学习算法步骤

□ 1、构造并求解约束最优化问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & \alpha_i \geq 0, i = 1, 2, \dots, N \end{aligned}$$

求得最优解 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$

关于 α_i 的求解方法这里就不再展开了，通常可以采用SMO算法求解。

线性可分支持向量机求解

□ 2、计算超平面参数

$$\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i$$

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i^T \mathbf{x}_j)$$


□ 3、求得分割超平面

$$\mathbf{w}^* \cdot \mathbf{x} + b^* = 0$$

□ 4、求得分类决策函数

$$f(x) = \text{sign}(\mathbf{w}^* \cdot \mathbf{x} + b^*)$$

软间隔支持向量机



存在异常点使得数据不是线性可分的怎么办？

引入软间隔支持向量机将间隔软化！

松弛变量的引入

- 若数据线性不可分，则增加松弛因子 $\xi_i > 0$ ，使函数间隔加上松弛变量大于等于1。这样，约束条件变成

$$y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 - \xi_i$$

- 优化目标

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i$$

线性软间隔支持向量机

□ 线性软间隔支持向量机模型

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i$$

$$s.t. \quad y_i (\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, N$$

$$\xi_i \geq 0, \quad i = 1, 2, \dots, N$$

□ 通过朗格朗日乘子法，可以整理得到对偶优化问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_i^T \mathbf{x}_j) - \sum_{i=1}^N \alpha_i$$

$$\sum_{i=1}^n \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N$$


核函数的引入

数据没法用超平面划分
怎么办？

核函数!!!

核函数的引入

采用核函数，可以将样本从原始空间映射到一个更高维的特征空间，从而用超平面实现线性划分



➤ 二维空间不可分的数据通过核函数映射到三维空间或许就可能用超平面划分了

核函数的引入

□ 常见的核函数

线性核

$$k(x, y) = x^T y + c$$

多项式核

$$k(x, y) = (ax^T y + c)^d$$

径向基核

$$k(x, y) = \exp(-\gamma \|x - y\|^2)$$

Sigmoid核

$$k(x, y) = \tanh(ax^T y + c)$$

拉普拉斯核

$$k(x, y) = \exp\left(-\frac{\|x - y\|}{\sigma}\right)$$

非线性支持向量机简介

直接定义高维映射函数？



计算开销太大

直接定义核函数 $K(x, y) = \phi(x) \cdot \phi(y)$

我们称 $K(x, y)$ 为核函数, $\phi(x) \cdot \phi(y)$ 为二者内积, 我们可以直接将线性支持向量机目标函数中的内积 $\mathbf{x}_i^T \mathbf{x}_j$ 用核函数 $K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$ 来代替。

□ 非线性支持向量机模型

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j) - \sum_{i=1}^N \alpha_i$$

$$\sum_{i=1}^N \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N$$


支持向量机的实现

□ 利用sklearn机器学习库中的SVM实现鸢尾花数据集分类

```
from sklearn.svm import SVC
from sklearn.datasets import load_iris
import matplotlib.pyplot as plt
import numpy as np
from sklearn.model_selection import train_test_split

if __name__ == "__main__":
    iris = load_iris()
    x, y = iris.data, iris.target
    x = x[:, :2]
    x -= np.mean(x, axis=0)
    x /= np.std(x, axis=0, ddof=1)
    X_train, X_test, y_train, y_test = train_test_split(x, y, test_size=0.3)
    clf = SVC(C=1, cache_size=2000, class_weight=None, coef0=0.0,
              decision_function_shape='ovr', degree=3, gamma=0.1,
              kernel='rbf', max_iter=-1, probability=False, random_state=None,
              shrinking=True, tol=0.001, verbose=False)

    clf.fit(X_train, y_train)
```



根据花萼长度、花萼宽度、花瓣长度、花瓣宽度之间的大系绘制的散点图，可以看出数据集是非线性的。

参考文献

1. Corinana Cortes, Vladimir Vapnik. Support-Vector Networks. Machine Learning, 20, 273-297, 1995
2. John C. Platt. Sequential Minimal Optimization: A Fast Algorithm for Training Support Vector Machines. 1998
3. Andrew W. Moore. Support Vector Machines, 2001
4. 李航, 统计学习方法, 清华大学出版社, 2012
5. 周志华. 机器学习 : = Machine learning[M]. 清华大学出版社, 2016.