

大数据解析与应用导论

Introduction to Big Data Analytics and Application

授课教师: 赵春晖

第二章 数据预处理及特征提取

1.

数据清洗

2.

数据转换

3.

主成分分析1

4.


主成分分析2

5.

实例应用

(一) 数据变换简介

- 数据变换主要是对数据进行规范化处理，将数据转换成适当的形式，以适用于挖掘任务及算法的需要



(二) 简单函数变换


- 简单函数变换是对原始数据进行某些数学函数变换，常用的变换包含平方、开方、取对数、差分运算等：

$$x' = x^2$$

$$x' = \sqrt{x}$$

$$x' = \log x$$

$$\nabla f(x_k) = f(x_{k+1}) - f(x_k)$$




简单的函数变换常用来将原始数据变换成易于处理的适当形式数据，例如：

- (1) 时间序列分析：简单的对数变换、差分运算；
- (2) 取值范围较为宽泛的分布：对数变换

(三) 数据归一化

- 数据归一化：**消除指标间量纲和取值范围差异**
- 常用的数据归一化方法：“最小-最大规范化”和“零-均值规范化”



$$x^* = \frac{x - \min}{\max - \min}$$


其中， $\min$ 为原始数据的最小值， $\max$ 为原始数据最大值；
通过对原始数据进行线性变换，使数据均落在 $[0, 1]$ 区间内
缺点：新数据的加入使得 $\min, \max$ 会发生变化。

$$x^* = \frac{x - \bar{x}}{\sigma}$$


其中， $\bar{x}$ 为原始数据的均值， σ 为原始数据的标准差；**将原始数据变换到均值为0，标准差为1的分布中。**
优点：适用于数据最大值、最小值未知情况，最为常用。

(四) 连续数据离散化

- 连续数据离散化：**将连续数据变换成分类属性**
- 连续数据离散化两个子任务：**①确定区间数；②如何将连续数据映射到各个区间内。**




(四) 连续数据离散化



(五) 属性构造

- 属性构造：**利用原有数据构造新的属性。**
- 通过构造新的属性，并加入到现有的属性集合中，属性构造能够提取更有用的信息，挖掘更深层次的模式，提升数据挖掘的效果。



(六) 数据变换小结

