

大数据解析与应用导论

Introduction to Big Data Analytics and Application

授课教师: 赵春晖

第二章 数据预处理及特征提取

1.

数据清洗

2.

数据转换

3.

主成分分析1


4.

主成分分析2

5.

实例应用

(一) 主成分分析简要回顾



收集到的
冗余数据

主成分分析
PCA

剔除冗余变量
化归到红球运动的x轴

(二) 算法求解与推导

我们现在以广泛用于机器学习的葡萄酒数据集为例，这份数据集包含来自3种不同起源的葡萄酒的共178条记录。13个属性是葡萄酒的13种化学成分，如下表所示。

1.Alcohol	8.Nonflavanoid phenols
2.Malic acid	9.Proanthocyanins
3.Ash	10.Color intensity
4.Alcalinity of ash	11.Hue
5.Magnesium	12.OD280/OD315 of diluted wines
6.Total phenols	13.Proline
7.Flavanoids	

葡萄酒数据集的13个指标

该问题中有 p 个指标($p=13$)，我们把这13个指标看作13个随机变量，记为 $X_1, X_2, \dots, X_{13}$ ，主成分分析就是要把这13个指标的问题，转变为讨论13个指标的线性组合的问题，而这些新的指标 $F_1, F_2, \dots, F_k$ ($k \leq p$)，按照保留主要信息量的原则充分反映原指标的信息，并且相互独立。

(二) 算法求解与推导

1.Alcohol	8.Nonflavanoid phenols
2.Malic acid	9.Proanthocyanins
3.Ash	10.Color intensity
4.Alcalinity of ash	11.Hue
5.Magnesium	12.OD280/OD315 of diluted wines
6.Total phenols	13.Proline
7.Flavanoids	

- 这份数据集包含来自3种不同起源的葡萄酒的共178条记录。13个属性是葡萄酒的13种化学成分。
- 记为原始数据矩阵 X ($m*n$) , m 为样本数, 本例中为178 ; n 为特征变量数, 本例中为13。下面将以该数据为例, 介绍PCA是如何完成数据降维的。

(二) 算法求解与推导

- 首先对数据进行 **零-均值规范化**，标准化处理的好处会在后面看到。

$$\tilde{x}_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j} \quad ; \quad i=1,2,\dots,m; \quad j=1,2,\dots,n$$
$$\bar{x}_j = \frac{1}{m} \sum_{i=1}^m x_{ij} \quad s_j = \sqrt{\frac{1}{m} \sum_{i=1}^m \left(x_{ij} - \bar{x}_j \right)^2}$$

➤ 标准化处理后的X的每个变量（每一列）的均值为0，方差为1。

- PCA的目标是寻找**负载矩阵U** 使得 $T = XU$ ，T为降维后的矩阵，即**主元矩阵**。要求：
降维后的**各个特征向量（T的列向量）**要**满足相互正交（线性无关）且尽可能多地表示原始数据信息（方差尽可能大）**。我们要做的工作就是寻找这个满足要求的**负载矩阵U**。

(二) 算法求解与推导

线性代数的知识给出**协方差为0的两个变量是不相关的**。因此我们的求解问题就转化为：**寻找矩阵U，使得主元矩阵T的各个列向量方差尽可能大，且协方差为0。**

□ 方差 $D(X) = E\{[X - E(X)]\}^2$

□ 协方差 $Cov(X, Y) = E[XY] - E[X]E[Y]$

- 记主元矩阵T的协方差矩阵为D， $D = T^T T / (m-1)$ ，**由于已经对原始数据X做了标准化处理，容易发现D的对角线元素恰好是每个主成分变量的方差，而其余位置的元素 D_{ij} 则为第i个变量与第j个变量的协方差。**
- 显然，我们的目标变得很清晰：**求解U矩阵，使得T的协方差矩阵为一个对角矩阵，且对角线元素按从大到小排列。**

(二) 算法求解与推导

PCA求解的推导过程简要如下。首先列出各主元的**目标函数和约束条件**：

$$t_i = Xu_i \quad \begin{aligned} &\max t_i^T t_i \\ &s. t. \begin{cases} t_i^T t_j = 0 \\ u_i^T u_i = 1 \end{cases} \end{aligned}$$

目标函数 $t_i^T t_i$ 可写作 $u_i^T X^T X u_i$ ，在求解单个主元 t_i 时，利用拉格朗日乘子法有：

$$\frac{\partial \varphi(u_i)}{\partial u_i} = 2X^T X u_i - 2\lambda u_i = 0$$

$$X^T X u_i = \lambda u_i$$

联想到**特征值分解公式**，从上式可看出 $S = X^T X$ ，S可看做原始数据矩阵X的协方差矩阵。由线性代数结论，若A是p阶实对称阵，则一定可以找到正交阵U，使其转换为对角矩阵 $U^T A U = \Lambda$ （原始数据X的协方差矩阵S是实对称矩阵，负载矩阵U为正交矩阵，则变换后的矩阵 $U^T X^T X U = T^T T = U^T S U$ 是对角矩阵，满足主元矩阵T的协方差矩阵对角的约束）

因此负载矩阵U的求解转化成了对S的特征值分解，S的特征值对应的特征向量即为U的列向量。


(三) 主元个数的选取

- 矩阵X的协方差矩阵S的特征值按从大到小排列后，数值越大的特征值所对应的方差越大，主元向量所包含的信息越多。
- 累积方差百分比 (Cumulative Percent Variance, 简称CPV) 是一种通过计算前k个主元的累积贡献率来确定主元个数的方法。

$$CPV_k = \frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^n \lambda_i} > ?$$

(三) 主元个数的选取

葡萄酒数据集中的主元个数选取



◆ 由图可知，用累积方差贡献率的方法，当解释率阈值设为90%时，求得主元个数 k 为8，将葡萄酒数据集数据集从13维降到了8维，后续可以利用降维后的数据进行下一步处理

$$\begin{array}{c} T = XU \\ \swarrow \quad \searrow \quad \nwarrow \\ (m \times k) \quad (m \times n) \quad (n \times k) \end{array}$$

本例中 $m=178$, $n=13$, $k=8$