

大数据解析与应用导论

Introduction to Big Data Analytics and Application

授课教师: 赵春晖

第四章 回归分析

1.

基本概念

2.

最小二乘回归

3.

岭回归

4.


主元回归

5.

偏最小二乘

4.1 基本概念

(1) 什么是线性模型(Linear model)?



典型的线性模型

样本: $\mathbf{x} \in R^n, \mathbf{x} = [x_1, x_2, \dots, x_n]^T$

参数: $\mathbf{w} = [w_1, w_2, \dots, w_n]^T \in R^n, b \in R$

线性模型: $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$

令: $\mathbf{x} = [x_1, x_2, \dots, x_n, 1]^T \in R^{n+1}$
 $\mathbf{w} = [w_1, w_2, \dots, w_n, b]^T \in R^{n+1}$

线性模型可简写为: $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$

4.1 基本概念


(2) 什么是回归(Regression)?

起源: 19世纪80年代, 英国统计学家弗朗西斯.高尔顿(Francis Galton)提出。

研究: 父代身高与子代身高之间的关系。

结论: 子代的身高有向族群平均身高“回归” 的趋势。

回归模型: 从**输入**变量到**输出**变量之间的**映射函数**，等价于**函数拟合**。



弗朗西斯.高尔顿




身高的回归

4.1 基本概念

(3) 什么是线性回归模型？

有训练样本： $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$

其中： $x_i \in R^d, y_i \in R, i = 1, 2, \dots, n$



线性回归模型：学习一个线性模型 $f(x)$ ，使得 $f(x)$ 与 y 尽可能接近，
则线性模型 $f(x) = w^T x$ 称为线性回归模型

线性回归分析：利用线性回归模型来对自变量（可以是向量）和因变量之间关系进行建模的，称为线性回归分析

4.1 基本概念

(4) 测评指标:

训练误差(Training error):


$$R_{\text{emp}}(\hat{f}) = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{f}(x_i))$$

其中n是学习系统输入的训练样本数目;

测试误差(Test error):

$$e_{\text{lest}} = \frac{1}{n'} \sum_{i=1}^{n'} L(y_i, \hat{f}(x_i))$$

其中n'是预测系统输入的测试样本数目;



4.1 基本概念

(5) 回归中的拟合效果:


欠拟合(Underfitting):

模型过于简单，对训练数据拟合效果差，模型偏差大；


过拟合(Overfitting):

模型过于复杂，对训练数据的拟合过于充分，模型方差大；


欠拟合
Underfitting



最佳拟合
Appropriate capacity



过拟合
Overfitting




● 训练样本

● 测试样本

4.1 基本概念

(6) 例子：多项式曲线拟合



如何用多项式曲线来拟合这些点？

某函数的图像上采集了十个点： $(x_1, y_1), (x_2, y_2), \dots, (x_{10}, y_{10})$

4.1 基本概念

(6) 例子：多项式曲线拟合

多项式函数： $f(x, \mathbf{a}) = a_0 + a_1x + a_2x^2 + \cdots + a_Mx^M = \sum_{j=1}^M a_jx^j$

记： $\mathbf{x} = [1, x, x^2, \dots, x^M]^T$, $\mathbf{a} = [a_0, a_1, a_2, \dots, a_M]^T$

则 $f(x, \mathbf{a})$ 可以写成： $f(x, \mathbf{a}) = \mathbf{a}^T \mathbf{x}$ ，是一个（广义）线性模型。

因此，用 $f(x, \mathbf{a})$ 拟合 $(x_1, y_1), (x_2, y_2), \dots, (x_{10}, y_{10})$ ，是一个线性回归问题。

4.1 基本概念

(6) 例子：多项式曲线拟合

问题：如何确定多项式系数向量 $\mathbf{a} = [a_0, a_1, a_2, \dots, a_M]^T$?

选择不同阶数时的拟合结果：

