

大数据解析与应用导论

Introduction to Big Data Analytics and Application

授课教师: 赵春晖

第四章 回归分析

1.

基本概念

2.

最小二乘回归

3.

岭回归

4.

主元回归

5.

偏最小二乘

4.3 岭回归分析

(1) 最小二乘回归的局限性

数据的多重共线性：自变量之间存在线性相关的情况，例如 $x_3 = x_1 + x_2$ 、 $x_2 = 2x_1$ ；

当存在上述情况时，有 $|x^T x| \approx 0$ ，此时由最小二乘回归方法得到的参数方差很大，可能出现**本末倒置**的情况。

例如 $y = 10 + 2x_1 + 3x_2 + \epsilon$ ，其中 x_1 与 x_2 高度线性相关， ϵ 是正态分布噪声，由最小二乘法得到的拟合函数为：

$$y = 11.27 + 0.5x_1 + 3.7x_2$$

	1	2	3	4	5
x_1	1.1	1.4	1.7	1.7	1.8
x_2	1.1	1.5	1.8	1.7	1.9
ϵ	0.8	-0.5	0.4	-0.5	0.2
y	16.3	16.8	19.2	18	19.5

4.3 岭回归分析

(2) 岭回归分析的定义

岭回归分析（Ridge Regression）是一种专用于多重共线性数据分析的有偏估计回归方法，是最小二乘法的改良版。

对于回归问题： $X\beta = y$

最小二乘回归的参数估计： $\beta = (X^T X)^{-1} X^T y$

岭回归分析的参数估计： $\beta(\lambda) = (X^T X + \lambda I)^{-1} X^T y$

$\lambda I = \begin{bmatrix} \lambda & 0 & 0 \\ 0 & \lambda & 0 \\ 0 & 0 & \lambda \end{bmatrix}$

由于加上了单位矩阵
I 其对角线全一，像
一条山岭一样，就叫
做岭回归算法。

4.3 岭回归分析

(3) 岭回归分析的数学基础

岭回归分析的优化目标函数：


$$\operatorname{argmin}_{\beta} \| \mathbf{X} \cdot \beta - \mathbf{Y} \|^2 + \lambda \| \beta \|^2$$

对上述函数求偏导令其等于0得到参数估计的结果：

$$\beta(\lambda) = \left(X^T X + \lambda I \right)^{-1} X^T y$$

结论：

引入二次项参数 $\lambda \| \beta \|^2$ 作为正则惩罚项；模型的参数估计效果取决于参数值 λ 。




岭回归与最小二乘回归对比


4.3 岭回归分析

(4) 岭参数的选择——岭迹图法


岭迹图： β 随着 λ 变化的图像，状如山岭，所以得名为岭迹图。



(a)



(b)



(c)


多种多样的岭迹图

4.3 岭回归分析

(4) 岭参数的选择——岭迹图法

岭迹法选择 k 值的一般原则是：

- 各回归系数的岭估计基本稳定；
- 用最小二乘估计时符号不合理的回归系数，其岭估计的符号变得合理；
- 残差平方和在适当范围内波动；
- 回归系数没有不合乎物理意义的值；



稳定的岭迹图

4.3 岭回归分析

(4) 岭参数的选择——方差扩大因子法

方差扩大因子 $c(\lambda)$ 反映数据多重共线性的**严重程度**。其定义如下：

根据回归系数的协方差阵进行化简可以得到，方差扩大因子与回归系数协方差之间的联系。

$$D[\hat{\beta}(\lambda)] = \text{cov}(\hat{\beta}(\lambda), \hat{\beta}(\lambda)) = \sigma^2 (X'X + \lambda I)^{-1} X'X (X'X + \lambda I)^{-1} = \sigma^2 c(\lambda)$$

$$\text{其中： } c(\lambda) = (X'X + \lambda I)^{-1} X'X (X'X + \lambda I)^{-1}$$

利用交叉验证法选择合适的 λ ，使得求解出的**方差扩大因子尽可能小**，或者设定合适阈值限制方差扩大因子的增大，避免岭回归出现较大偏差。


4.3 岭回归分析

(5) 岭回归的应用举例：

UCI糖尿病数据集：来自美国国家糖尿病和消化肾脏疾病研究所，包括糖尿病指数，BMI身体质量指数，年龄，以及6个血清测量值等9个属性。

因变量：糖尿病指数

自变量：年龄、性别、体质指数(BMI)、平均血压(BP)及六个血清测量值(S1-S6)




4.3 岭回归分析

(5) 岭回归的应用举例：

由图可知：

- 回归参数随着 λ 的增长趋于平稳；
- 回归参数没有出现符号变异；
- 喇叭形的岭迹图说明数据中存在共线性情况；
- 选择喇叭口处的 $\lambda=0.01$ 作为合适范围，方差小，参数基本稳定；



糖尿病数据集的岭迹图

4.3 岭回归分析

(5) 岭回归的应用举例：


$$c(\lambda) = \left(X'X + \lambda I \right)^{-1} X'X \left(X'X + \lambda I \right)^{-1}$$

- 利用交叉验证法将原始数据集随机等分为k部分；
- 每次控制方差扩大因子不大于10，降低共线性风险；

$$c(\lambda) \leq 10$$

- 进行k重交叉验证取平均值，去主观性，得到 λ 的精确值为：

$$\lambda = 0.0135$$



4.3 岭回归分析

(5) 岭回归的应用举例：

根据上述算法得到完整的模型回归参数如右表所示：

模型如下：

$$Y=-323.11+6.21\text{BMI}+0.93\text{BP}-0.49\text{S1}+0.21\text{S2}+0.03\text{S3}+4.21\text{S4}+51.69\text{S5}+0.38\text{S6}$$

回归参数的解释为BMI身体指数每增加1个单位，患糖尿病的风险指数增加6.21个单位。



特征量	回归参数
截距	-323.11
(S1)	-0.49
(S2)	0.21
(S3)	0.03
(S4)	4.21
(S5)	51.69
(S6)	0.38
BMI	6.21
BP	0.93

4.3 岭回归分析


(6) 岭回归的优缺点总结：

优点：

- 通过引入二次惩罚项缓解数据**多重共线性**的问题；
- 具有一定的**参数收缩**的作用；

缺点：

- 主观地由岭迹图判断多重共线性数据，可能导致回归效果不佳；
- 区别于LASSO，没有稀疏化选择变量的能力；



由于二次惩罚项的优化边界是圆形，岭回归优化解通常不在坐标轴上，所以很少出现系数稀疏（等于0）的情况，也就是没有变量选择功能。