

大数据解析与应用导论

Introduction to Big Data Analytics and Application

授课教师: 赵春晖

第四章 回归分析

1.

基本概念

2.

最小二乘回归

3.

岭回归

4.

主元回归

5.

偏最小二乘

4.5 主元回归分析

(1) 主元回归分析的背景





大数据时代回归分析面临的困难


数据多重共线性

维数灾难

特征复杂多变



维数灾难






4.5 主元回归分析

(2) 主元回归分析基本流程

主成分：包含较多信息投影方向，从数据角度来讲就是**方差波动较大的方向**。**主成分之间相互正交**。

主成分选择：

1. 先选择方差最大的作为第一主成分；
2. 找到与其正交的方差第二大投影方向作为第二主成分；
3. 以此类推，直到方差中包含足够的信息；



4.5 主元回归分析

(2) 主元回归分析基本流程

➤ 利用主成分特征进行回归分析

☆ 原始回归模型 $Y = X\beta + \epsilon$

其中X是标准化后的原始样本矩阵

☆ 主元回归模型 $Y = Z\alpha + \epsilon = X\beta^* + \epsilon$

其中 $\Gamma_k = (\gamma_1, \gamma_2, \dots, \gamma_k)$ 是对应X的协方差阵前k个特征值的特征向量

$Z = X\Gamma_k$ 是降维后的数据矩阵, α 为对提取出的主元进行回归的系数;

经过拟合推导后可得, 在主元回归中, 对于自变量X的回归系数如下式所示:

$$\beta^* = \Gamma_k \alpha = \Gamma_k \Lambda_k^{-1} Z_k' Y$$

原始数据

特征提取

主成分分析

主成分

主元回归模型

4.5 主元回归分析

(3) 岭回归与主元回归分析的对比

数据多重共线性问题

岭回归分析

$$\beta(\lambda) = \left(\underline{X^T X} + \lambda I \right)^{-1} X^T y$$

从**原始数据**入手，针对系数矩阵无法求逆加入一次惩罚项；

弊端：

A. 冗余的数据被重复计算，**运算效率低**；

B. 区分不出重点特征，**抓不住主要信息**；

主元回归分析

$$\beta^* = \Gamma_k \alpha = \Gamma_k \Lambda_k^{-1} \underline{Z_k'} Y$$

从**数据重组**入手，先进行**特征提取**，去除重复的共线性信息，同时降低维数，提高回归模型运算效率；



5.5 主元回归分析

(5) 例子——中国民航客运量：

为了研究我国民航客运量的变化趋势及其成因，我们以民航客运量作为因变量 y ，以国民收入、消费额、铁路客运量、民航航线里程、来华旅游入境人数为影响民航客运量的主要因素。——数据来源《应用回归分析（第四版）》何晓群

符号说明：

- y ——客运量（万人）
- x_1 ——国民收入（亿元）
- x_2 ——消费额（亿元）
- x_3 ——铁路客运量（万人）
- x_4 ——民航航线里程（万公里）
- x_5 ——来华旅游入境人数（万人）



5.5 主元回归分析

(5) 例子——中国民航客运量：

总方差解释						
成分	总计	初始特征值 方差百分比	累积 %	成分	初始特征值 方差百分比	累积 %
1	3.991	79.826	79.826	1	3.991	79.826
2	.932	18.641	98.468	2	.932	98.468
3	.065	1.303	99.771	3	.065	99.771
4	.011	.224	99.995	4	.011	99.995
5	.000	.005	100.000	5	.000	100.000

前两个主成分的
累积方差贡献率
达到98%以上

提取方法：主成分分析法。

客运量回归模型：

$$Y=1159.124+468.899$$

$$*PC1-192.530*PC2$$

表3. 利用主元建立的线性回归模型

主元自变量	β
截距	1159.124
PC1	468.899
PC2	-192.530

表2. 前两个主成分投影后的结果

PC1	PC2
-2.58	-1.43
-2.31	-1.01
-2.00	-0.55
-1.77	-0.30
-1.59	0.06
-1.35	0.58
-0.94	0.92
-0.47	1.04
-0.10	0.70
0.47	0.95
1.19	1.77
1.16	0.78
1.17	-0.82
1.81	-0.96
2.96	-0.99
4.34	-0.74

5.5 主元回归分析

(6) 主元回归的优缺点总结：

优点：

- 实现多维数据的降维处理，提高运算速度；
- 特征组合可一定程度地解决数据多重共线性的问题；

缺点：

- 无监督方法，对提取出的主成分合理性缺少解释