

大数据解析与应用导论

Introduction to Big Data Analytics and Application

授课教师: 赵春晖

第四章 回归分析

1.

基本概念

2.

最小二乘回归

3.

岭回归

4.

主元回归

5.

偏最小二乘

4.5 偏最小二乘回归

(1) 为什么提出偏最小二乘回归？

- 案例：现在想要通过汽油的光谱分析结果，预测其辛烷含量。一个经典的数据集是：有**60个**汽油样本，每个样本包含其光谱分析结果，即在**401个**不同波长处的光谱强度值，作为自变量（ 60×401 ）；以及其辛烷含量（ 60×1 ），作为因变量。
- 问题：**自变量之间的多重相关性**；样例很少，**少于变量的维度**。如何解决？

偏最小二乘（Partial least-square method, PLS）！

- $PLS \approx OLS + PCA + CCA$ 综合全面，经典融合。

4.5 偏最小二乘回归

(1) 为什么提出偏最小二乘回归？

- PLS最先产生于化学领域，在利用分光镜来预测化学样本的组成时，作为解释变量的**红外区反射光谱的波长常有成百上千**，往往超过化学样本的个数，所造成的多重相关性使得人们很难利用传统的最小二乘法。
- 基于这个应用的需要，1983年首次提出了PLS回归方法并首先在化工领域取得了广泛的应用。

4.5 偏最小二乘回归

(2) 基本原理

- 设有 q 个因变量 $\{y_1, \dots, y_q\}$ 和 p 个自变量 $\{x_1, \dots, x_p\}$ 。为了研究因变量和自变量的统计关系, 我们观测了 n 个样本点, 由此构成了自变量与因变量的数据表 $X_{n \times p}$ 和 $Y_{n \times q}$ 。
- 偏最小二乘回归分别在 X 与 Y 中提取出潜变量 t_1 和 u_1 (也就是说, t_1 是 $x_1, x_2, \dots, x_p$ 的线性组合, u_1 是 $y_1, y_2, \dots, y_q$ 的线性组合)。在提取这两个潜变量时, 为了回归分析的需要, 有下列两个要求:
 - (1) t_1 和 u_1 应尽可能大地携带他们各自数据表中的变异信息;
 - (2) t_1 与 u_1 的相关程度尽可能大。

4.5 偏最小二乘回归

(3) 目标函数

其中: $t_1 = E_0 w_1$ $\|w_1\| = 1$ $u_1 = F_0 c_1$ $\|c_1\| = 1$

t_1 和 u_1 应尽可能大地携带他们各自数据表中的变异信息



$$\text{Var}(t_1), \text{Var}(u_1) \rightarrow \max$$

t_1 和 u_1 相关程度最大



$$r(t_1, u_1) \rightarrow \max$$

$$r_{ij} = \frac{\text{COV}(X_i, Y_j)}{\sqrt{D(X_i)}\sqrt{D(Y_j)}} \rightarrow \text{COV}(t_1, u_1) = \sqrt{D(t_1)}\sqrt{D(u_1)}r(t_1, u_1) \rightarrow \max$$

4.5 偏最小二乘回归

(4) 求解步骤

- ① 对 X, Y 进行数据标准化处理，得到 E_0, F_0
- ② 求解符合要求的潜变量 t_1 和 u_1
- ③ 建立 t_1, u_1 与原自变量，因变量之间的回归
- ④ 继续求潜变量，直到满足要求
- ⑤ 推导因变量之于自变量的回归表达式

4.5 偏最小二乘回归

(5) 算法推导

$$\max(w_1^T E_0^T F_0 c_1) \quad s.t. \quad \begin{cases} w_1^T w_1 = 1 \\ c_1^T c_1 = 1 \end{cases} \quad \longrightarrow \quad \text{拉格朗日乘子法}$$

$$s = w_1^T E_0^T F_0 c_1 - \lambda_1 (w_1^T w_1 - 1) - \lambda_2 (c_1^T c_1 - 1)$$

对 s 求 $w_1, c_1, \lambda_1, \lambda_2$ 的偏导:

$$\frac{\partial s}{\partial w_1} = E_0^T F_0 c_1 - 2\lambda_1 w_1 = 0 \quad (1)$$

$$\frac{\partial s}{\partial \lambda_1} = -(w_1^T w_1 - 1) = 0 \quad (3)$$

$$\frac{\partial s}{\partial c_1} = F_0^T E_0 w_1 - 2\lambda_2 c_1 = 0 \quad (2)$$

$$\frac{\partial s}{\partial \lambda_2} = -(c_1^T c_1 - 1) = 0 \quad (4)$$

$$\longrightarrow \quad 2\lambda_1 = 2\lambda_2 = w_1^T E_0^T F_0 c_1$$

4.5 偏最小二乘回归

(5) 算法推导

$$\text{记 } \theta_1 = 2\lambda_1 \rightarrow \theta_1 = w_1^T E_0^T F_0 c_1$$



$$\begin{cases} E_0^T F_0 F_0^T E_0 w_1 = \theta_1^2 w_1 \\ F_0^T E_0 E_0^T F_0 c_1 = \theta_1^2 c_1 \end{cases} \rightarrow$$

- w_1 是矩阵 $E_0^T F_0 F_0^T E_0$ 最大特征值的单位特征向量
- c_1 是矩阵 $F_0^T E_0 E_0^T F_0$ 最大特征值的单位特征向量

最小二乘重构 E_0, F_0

$$\begin{aligned} E_0 &= t_1 p_1^T + \boxed{E_1} \\ F_0 &= t_1 r_1^T + \boxed{F_1} \\ F_0 &= u_1 q_1^T + \boxed{F_1'} \end{aligned}$$




$$p_1 = \frac{E_0^T t_1}{\|t_1\|^2} \quad r_1 = \frac{F_0^T t_1}{\|t_1\|^2} \quad q_1 = \frac{F_0^T u_1}{\|u_1\|^2}$$

$$\text{其中: } t_1 = E_0 w_1 \quad \|w_1\| = 1 \quad u_1 = F_0 c_1 \quad \|c_1\| = 1$$

4.5 偏最小二乘回归

(5) 算法推导

用 E_1 和 F_1 取代 E_0 和 F_0 ，重复上述步骤，直到满足要求



$$E_0 = t_1 p_1^T + t_2 p_2^T + \cdots + t_A p_A^T$$

$$F_0 = t_1 r_1^T + t_2 r_2^T + \cdots + t_A r_A^T + F_{A+1}$$

小结：

- 能在自变量存在多重相关性的条件下进行建模
- 允许样本点个数少于自变量个数
- 考虑了X和Y的相关关系，结果更加可靠

4.5 偏最小二乘回归

(6) 潜变量个数的确定——交叉有效性

SSE: *Sum of Squares for Error*

PRESS: *predicted residual sum of squares*

- 使用 $n - 1$ 个样本点， h 个潜变量建模。求排除样本点的预测误差平方。对每一个 $i = 1, 2, \dots, n$ ，重复上述测试，求预测误差平方和。

y_j 和 Y 的预测误差平方和定义如下：

$$PRESS_{hj} = \sum_{i=1}^n (y_{ij} - y_{hj(-i)})^2$$
$$PRESS_h = \sum_{j=1}^p PRESS_{hj}$$

- 使用所有样本点，拟合含 $h-1$ 个潜变量的回归方程，定义 y_j 和 Y 的预测误差平方和定义如下：

$$SSE_{(h-1)j} = \sum_{i=1}^n (y_{ij} - y_{hji})^2$$
$$SSE_{h-1} = \sum_{j=1}^p SS_{(h-1)j}$$

$$\frac{PRESS_h}{SSE_{h-1}} \leq 0.95^2$$


增加潜变量 h 是有效的！

4.5 偏最小二乘回归

(7) 实际应用：

- 案例：现在想要通过汽油的光谱分析结果，预测其辛烷含量。
- 一个经典的数据集是：有60个汽油样本，每个样本包含其光谱分析结果，即在401个不同波长处的光谱强度值，作为自变量（ 60×401 ）；以及其辛烷含量（ 60×1 ），作为因变量。


图示为60个
不同辛烷含
量的汽油样
品的光谱分
析结果：



4.5 偏最小二乘回归

(7) 实际应用：


- 进行偏最小二乘回归，获得一个具有10个PLS潜变量和一个因变量的PLS回归模型
- 因变量Y中被解释的方差百分比和PLS潜变量数量的关系如右图所示。



4.5 偏最小二乘回归

(7) 实际应用：

- 利用两个PLS潜变量进行回归，并拟合具有两个主潜变量的主元回归（PCR）模型。两种方法的模型预测值对实际值的结果如图所示。



4.5 偏最小二乘回归

(8) 小结

- 偏最小二乘回归是一种多因变量对多自变量的回归建模方法。特别当各变量集合内部存在较程度的相关性时，用偏最小二乘回归进行回归建模分析，比对逐个因变量做多元回归更加有效，其结论更加可靠，整体性更强。
- 在建模的同时实现了数据结构的简化，可以在二维平面上对多维数据的特性进行观察，图形功能强大。
- 因此，许多统计分析专家称PLS为第二代回归分析方法。