第五章. 矩阵特征值的数值方法.

1. 特征值的估计与扰动.

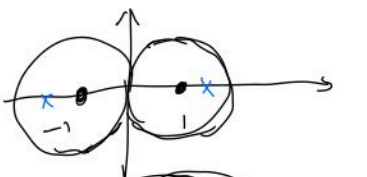
① 特征值的估计:

定理1: 圆盘定理 (Gershgorin)

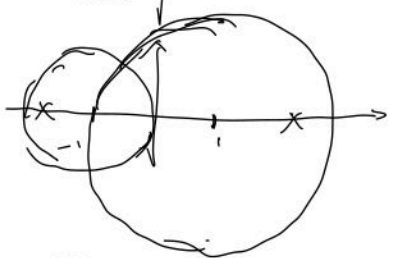
设 $A \in \mathbb{C}^{n\times n}$, 则 A 的任何特征值 $\lambda \in \bigcup_{i=1}^{n} D_i$, 其中

$$D_i = \{ z \mid |z - a_{ii}| \le r_i,\ r_i = \sum_{\substack{j=1 \\ j\neq i}}^{n} |a_{ij}|,\ z \in \mathbb{C} \},\ i = 1, 2, 3, \cdots, n$$

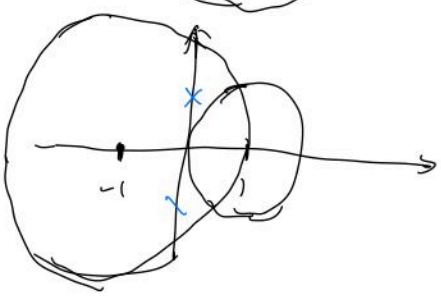
例: $A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \Rightarrow \lambda(A) = \pm\sqrt{2}$



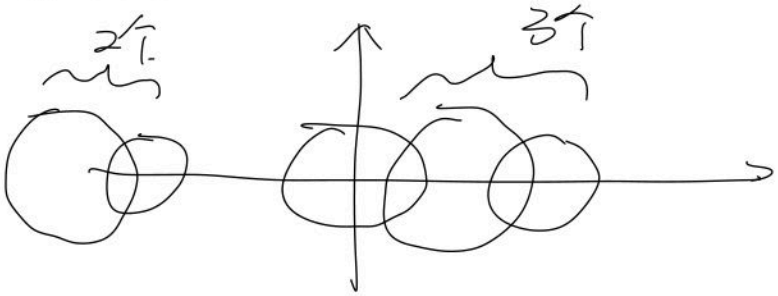
$A = \begin{bmatrix} 1 & 2 \\ 1 & -1 \end{bmatrix} \Rightarrow \lambda(A) = \pm\sqrt{3}$



$A = \begin{bmatrix} 1 & -1 \\ 2 & -1 \end{bmatrix} \Rightarrow \lambda(A) = \pm i$



定理2: 在对应 A 的 n 个圆盘中, 若有 m 个圆盘构成一个连通区域 S, 且 S 与其他 $n-m$ 个圆盘严格分离, 则 S 中恰好有 A 的 m 个特征值 (重特征值按代数重数计算)



推论：孤立的圆盘中只有A的一个特征值.

若 $B=\mathrm{diag}(b_1,b_2,\cdots,b_n)$ 此时 A 与 $B^{-1}AB$ 有相同特征值.

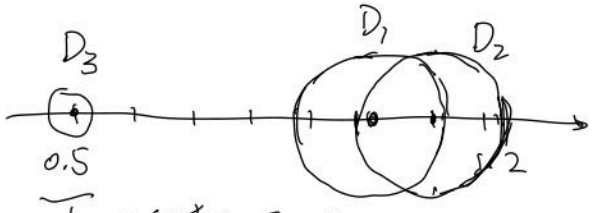
$A\vec{x}=\lambda\vec{x}$ $\quad B^{-1}AB\vec{y}=\lambda'\vec{y}\to A(B\vec{y})=\lambda'\cdot B\vec{y}$

若取 $\vec{x}=B\vec{y}$. $\quad a=\lambda'$

对于 $B^{-1}AB$，其圆盘半径为：$\sum_{\substack{j=1\\ j\neq i}}^{n}\left|\frac{a_{ij}\cdot b_j}{b_i}\right|$，此时，可以选择适当的 B，使某个圆盘半径减少，方便估计特征值分布.

例：$A=\begin{bmatrix}1 & 0.03 & 0.1\\ 0.03 & 1.1 & 0.1\\ 0.01 & 0.02 & 0.5\end{bmatrix}$ $\quad \lambda(A)=[0.9923,\ 1.1127,\ 0.4950]$

$D_1=\{z\mid|z-1|\le 0.13\}$ $\quad D_2=\{z\mid|z-1.1|\le 0.13\}$, $D_3=\{z\mid|z-0.5|\le 0.03\}$



↳ 1个特征值 ↳ 2个特征值

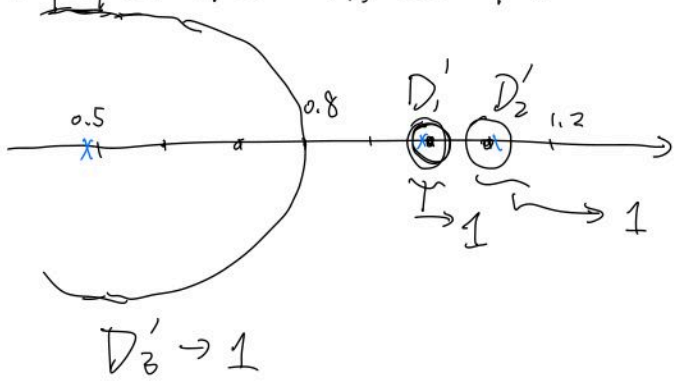
若 $B=\begin{bmatrix}1 & & \\ & 1 & \\ & & 0.1\end{bmatrix}$ $\quad B^{-1}=\begin{bmatrix}1 & & \\ & 1 & \\ & & 10\end{bmatrix}$

$$\Rightarrow B^{-1}AB=\begin{bmatrix}1 & & \\ & 1 & \\ & & 10\end{bmatrix}\begin{bmatrix}1 & 0.03 & 0.1\\ 0.03 & 1.1 & 0.1\\ 0.01 & 0.02 & 0.5\end{bmatrix}\begin{bmatrix}1 & & \\ & 1 & \\ & & 0.1\end{bmatrix}$$

$$=\begin{bmatrix}1 & 0.03 & 0.1\\ 0.03 & 1.1 & 0.1\\ 0.1 & 0.2 & 5\end{bmatrix}\begin{bmatrix}1 & & \\ & 1 & \\ & & 0.1\end{bmatrix}$$

$$=\begin{bmatrix}1 & 0.03 & 0.01\\ 0.03 & 1.1 & 0.01\\ 0.1 & 0.2 & 0.5\end{bmatrix}$$

$\Rightarrow D_1' = \{z \mid |z-1| \le 0.04\}$, $D_2' = \{z \mid |z-1.1| \le 0.04\}$, $D_3' = \{z \mid |z-0.5| \le 0.3\}$



② 特征值的扰动.

定理3: 设 μ 是 $A+E \in C^{n\times n}$ 的特征值, 且 $X \in C^{n\times n}$, $X^{-1}AX = D = \mathrm{diag}(\lambda_1, \cdots, \lambda_n)$

则 $\min_{\lambda \in \sigma(A)} |\lambda - \mu| \le \|X^{-1}\|_p \cdot \|X\|_p \cdot \|E\|_p$.

2. 幂法与反幂法.

2.1 幂法:

设 $A \in R^{n\times n}$, A 可对角化, 即存在 n 个线性无关向量 $\vec{x_1}, \cdots, \vec{x_n}$ 满足

$$A\vec{x_i} = \lambda_i \vec{x_i}$$

$\forall \vec{v}^{(0)} \in R^n$, $\vec{v}^{(0)} = \alpha_1\vec{x_1} + \alpha_2\vec{x_2} + \cdots + \alpha_n\vec{x_n}$

若 $\alpha_1\vec{x_1} \neq \vec{0}$ 则有:

$$A\vec{v}^{(0)} = A(\alpha_1\vec{x_1} + \alpha_2\vec{x_2} + \cdots + \alpha_n\vec{x_n})$$
$$= \alpha_1\lambda_1\vec{x_1} + \alpha_2\lambda_2\vec{x_2} + \cdots + \alpha_n\lambda_n\vec{x_n}$$

设 $\vec{v}^{(k)} = A\vec{v}^{(k-1)}$:

$$\vec{v}^{(k+1)} = A\vec{v}^{(k)} = A^{k+1}\cdot\vec{v}^{(0)} = \alpha_1\lambda_1^{k+1}\vec{x_1} + \alpha_2\lambda_2^{k+1}\cdot\vec{x_2} + \cdots + \alpha_n\lambda_n^{k+1}\cdot\vec{x_n}$$
$$= \lambda_1^{k+1}\left(\alpha_1\vec{x_1} + \left(\frac{\lambda_2}{\lambda_1}\right)^{k+1}\cdot\alpha_2\vec{x_2} + \cdots + \left(\frac{\lambda_n}{\lambda_1}\right)^{k+1}\cdot\alpha_n\vec{x_n}\right)$$

若 $\left|\frac{\lambda_i}{\lambda_1}\right| < 1$ (λ_1 为按模最大的单特征值)

$\lim_{k\to\infty} \vec{v}^{(k+1)} \to \lambda_1^{k+1} \cdot \alpha_1 \vec{x}_1 \Rightarrow$ 趋向于 λ_1 特征向量方向.

• 幂法流程：若定 $\vec{v}^{(0)} \in \mathbb{R}^n$

① $\vec{z}^{(k+1)} = A\vec{v}^{(k)}$

② $\vec{v}^{(k+1)} = \vec{z}^{(k+1)} / \text{sgn}(p) \cdot \|\vec{z}^{(k+1)}\|_\infty$

☆ $\text{sgn}(p) = \begin{cases} 1, & p>0 \\ -1, & p<0 \\ 0, & p=0 \end{cases}$

p 为 $\vec{z}^{(k+1)}$ 中按绝对值最大的元素.

☆使 $\vec{v}^{(k)}$ 中最大分量总为1.

若能收敛，则 $A\vec{v}^{(k)} = \vec{z}^{(k+1)} = \text{sgn}(p) \cdot \|\vec{z}^{(k+1)}\|_\infty \cdot \vec{v}^{(k+1)}$

$\Rightarrow A\vec{v} = \underbrace{\text{sgn}(p) \cdot \|\vec{z}^{(k+1)}\|_\infty}_{\hookrightarrow \lambda_1} \cdot \vec{v}$

• 幂法收敛速度：$\lambda_1 = \text{sgn}(p) \cdot \|\vec{z}^{(k+1)}\|_\infty$

☆ $\lambda_1^k = \text{sgn}(p) \cdot \|\vec{z}^{(k)}\|_\infty$

$$\vec{z}^{(k+1)} = A \cdot \vec{v}^{(k)} = A \cdot \frac{\vec{z}^{(k)}}{\lambda_1^k} = \frac{A \cdot (A\vec{v}^{(k-1)})}{\lambda_1^k} = \frac{1}{\lambda_1^k} \cdot A^2 \cdot \vec{v}^{(k-1)}$$

$$= \frac{1}{\lambda_1^k \lambda_1^{k-1}} A^2 \cdot \vec{z}^{(k-1)} \cdots = \frac{1}{\lambda_1^k \lambda_1^{k-1} \cdots \lambda_1^1} A^k \cdot \vec{v}^{(1)}$$

$$= \frac{1}{\lambda_1^k \cdot \lambda_1^{k-1} \cdots \lambda_1^1 \cdot \lambda_1^0} \cdot A^{k+1} \cdot \vec{v}^{(0)}$$

$$= \frac{1}{\lambda_1^k \cdots \lambda_1^0} \cdot \left(\alpha_1 (\lambda_1)^{k+1} \cdot \vec{x}_1 + \alpha_2 (\lambda_2)^{k+1} \cdot \vec{x}_2 + \cdots + \alpha_n (\lambda_n)^{k+1} \cdot \vec{x}_n \right)$$

$$\Rightarrow \frac{|\lambda_1^{k+1} - \lambda_1|}{|\lambda_1^k - \lambda_1|} \leq k \cdot \left|\frac{\lambda_2}{\lambda_1}\right| \Rightarrow \text{线性收敛}.$$

2.2 反幂法：应用到 A^{-1} 上的幂法。

A 特征值：$\lambda_1, \lambda_2, \cdots, \lambda_n$

A^{-1} ：$\lambda_1^{-1}, \lambda_2^{-1}, \cdots, \lambda_n^{-1}$

对于 $B = A^{-1}$，利用幂法流程计算 $\Rightarrow$ B 按模最大的特征值

$\Rightarrow$ A 按模最小 - - - - -

$$\vec{z}^{(k+1)} = B\vec{v}^{(k)}$$
$$\vec{v}^{(k+1)} = \vec{z}^{(k+1)} / sgn(p)\cdot \|\vec{z}^{(k+1)}\|_\infty$$

$\Leftrightarrow$

$$A\vec{z}^{(k+1)} = \vec{v}^{(k)}$$
$$\vec{v}^{(k+1)} = \vec{z}^{(k+1)} / sgn(p)\cdot \|\vec{z}^{(k+1)}\|_\infty$$

2.3 幂迭代的加速。

- 原点位移：

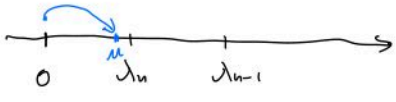
考虑 $A \in R^{n\times n}$ 的特征值为 $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \cdots \geq |\lambda_{n-1}| > |\lambda_n|$

此时 $A - \mu I$（$\mu \in R$ 为给定量）的特征值：$\lambda_1 - \mu, \lambda_2 - \mu, \cdots, \lambda_n - \mu$

$\Rightarrow (A-\mu I)^{-1}$ 特征值 $(\lambda_1-\mu)^{-1}, (\lambda_2-\mu)^{-1}, \cdots, (\lambda_n-\mu)^{-1}$

若 μ 非常靠近 λ_n，则 $(\lambda_n-\mu)^{-1}$ 较大

此时，对于 $A-\mu I$ 用幂法收敛速度取决于：$\left|\frac{\lambda_n-\mu}{\lambda_{n-1}-\mu}\right|$



原始幂法收敛速度取决于 $\left|\frac{\lambda_n}{\lambda_{n-1}}\right|$

原点位移后 - - - - - $\left|\frac{\lambda_n-\mu}{\lambda_{n-1}-\mu}\right|$ ✓

- Rayleigh 商迭代：

Rayleigh 商：$\lambda = \frac{\vec{v}^T A\vec{v}}{\vec{v}^T\vec{v}}$ $(\vec{v}\in R^n, \vec{v}\neq\vec{0})$

（若 $\vec{v}$ 为特征向量，Rayleigh 商 $\to$ 特征值）

★ 考虑特征值方程 $\vec{x}\cdot\lambda = A\vec{x}$ 其中 λ 为待求量，$\vec{x}$ 为已知量，

此方程为线性方程组

若此时 $\vec{x}$ 不为特征向量，$\Rightarrow \vec{x}\cdot\lambda = A\vec{x}$ 为一个最小二乘问题 $\quad \vec{c}\to A\vec{x}$

利用法方程 $\Rightarrow \vec{x}^T\cdot\vec{x}\cdot\lambda = \vec{x}^T A\vec{x}$ （$B\vec{y}=\vec{c} \Rightarrow B^TB\vec{y} = B^T\vec{c}$，$B\to\vec{x}$，$\vec{y}\to\lambda$）

$$\Rightarrow \lambda = \frac{\vec{x}^T A \vec{x}}{\vec{x}^T \cdot \vec{x}}$$

□ Rayleigh商是特征值的最优近似.

令 $\lambda(\vec{x}) = \frac{\vec{x}^T A \vec{x}}{\vec{x}^T \vec{x}}$，$\lambda_1$ 与 $\vec{v}_1$ 组成为 A 的特征值与对应的特征向量.

$$\lambda(\vec{x}) = \lambda(\vec{v}_1) + (\vec{x}-\vec{v}_1)^T \cdot \nabla\lambda(\vec{v}_1) + O(\|\vec{x}-\vec{v}_1\|_2^2)$$

此时对于 $\nabla\lambda(\vec{x}) = \nabla\left(\frac{\vec{x}^T A \vec{x}}{\vec{x}^T \vec{x}}\right) = \frac{\nabla(\vec{x}^T A\vec{x})\cdot(\vec{x}^T\vec{x}) - (\vec{x}^T A\vec{x})\cdot\nabla(\vec{x}^T\vec{x})}{(\vec{x}^T\vec{x})^2}$

$$= \frac{2A\vec{x}\cdot(\vec{x}^T\vec{x}) - \vec{x}^T A\vec{x}\cdot 2(I\vec{x})}{(\vec{x}^T\vec{x})^2} = \frac{2}{\vec{x}^T\vec{x}}\left(A\vec{x} - \frac{\vec{x}^T A\vec{x}}{\vec{x}^T\vec{x}}\cdot\vec{x}\right)$$

$$= \frac{2}{\vec{x}^T\vec{x}}\left(A\vec{x} - \lambda(\vec{x})\cdot\vec{x}\right) \Rightarrow \nabla\lambda(\vec{v}_1) = \vec{0}$$

$$\Rightarrow \lambda(\vec{x}) = \lambda(\vec{v}_1) + O(\|\vec{x}-\vec{v}_1\|_2^2) \Rightarrow \lambda(\vec{x}) - \lambda_1 = O(\|\vec{x}-\vec{v}_1\|_2^2)$$

对于取文为迭代步数得到的 $\vec{v}^{(k)} \Rightarrow \|\vec{v}^{(k)} - \vec{v}_1\|_2 = O(|\frac{\lambda_2}{\lambda_1}|^k)$

$$\Rightarrow \lambda(\vec{v}^{(k)}) - \lambda_1 = O(|\frac{\lambda_2}{\lambda_1}|^{2k})$$

- 加速算法1：

给定 $\vec{v}^{(0)} \in \mathbb{R}^n$.

① $\vec{z}^{(k+1)} = A\vec{v}^{(k)}$

② $\vec{v}^{(k+1)} = \vec{z}^{(k+1)} / \|\vec{z}^{(k+1)}\|_2$

③ $\lambda^{(k+1)} = (\vec{v}^{(k+1)})^T \cdot A\vec{v}^{(k+1)}$

- 加速算法2：Rayleigh商 + 反幂法 + 原点位移.

给定 $\vec{v}^{(0)} \in \mathbb{R}^n$，$(\|\vec{v}^{(0)}\|_2 = 1)$

① $\lambda^{(k)} = [\vec{v}^{(k)}]^T \cdot A\vec{v}^{(k)}$

② 求解 $(A - \lambda^{(k)}I)\cdot\vec{z}^{(k+1)} = \vec{v}^{(k)}$

③ $\vec{v}^{(k+1)} = \vec{z}^{(k+1)} / \|\vec{z}^{(k+1)}\|_2$

2.4 基于幂迭代的收缩方法：

是否可以对于矩阵，将其一个已知的特征值变为0，同时不改变其他特征值.

☆ 特征值问题 $\Rightarrow$ 特征多项式求根 $(x-\lambda_1)(x-\lambda_2)\cdots(x-\lambda_n) = 0$

$\downarrow \lambda_1 = 0$ $\Downarrow$

$x(x-\lambda_2)\cdots(x-\lambda_n) = 0$

考虑一个事实：$\vec{v}_i$ 为 A 关于 λ_i 特征向量

$\vec{w}_j$ 为 A^T 关于 λ_j 特征向量 $(\lambda_i \neq \lambda_j)$

$A\vec{v}_i = \lambda_i\vec{v}_i \Rightarrow \vec{v}_i^T A^T = \lambda_i\cdot\vec{v}_i^T \Rightarrow \vec{v}_i^T A^T\vec{w}_j = \lambda_i\cdot\vec{v}_i^T\cdot\vec{w}_j \Rightarrow \lambda_j\vec{v}_i^T\vec{w}_j = \lambda_i\cdot\vec{v}_i^T\vec{w}_j$

$\Rightarrow \vec{v}_i^T\cdot\vec{w}_j = 0 \Rightarrow A$ 与 A^T 关于不同特征值的特征向量正交.

对于矩阵亏损 $B = A - \lambda_1\vec{v}_1\cdot\vec{x}^T \Rightarrow B\vec{v}_1 = A\vec{v}_1 - \lambda_1\vec{v}_1\cdot\vec{x}^T\vec{v}_1 = \lambda_1\vec{v}_1 - \lambda_1\vec{v}_1\cdot\vec{x}^T\vec{v}_1$

$= \lambda_1\vec{v}_1(1 - \vec{x}^T\vec{v}_1)$

若 $\vec{x}^T \cdot \vec{v}_1 = 1$，则 $B\vec{v}_1 = 0$。B有特征值 0，

对于B的其他特征值：

$$B^T\vec{u}_i = (A - \lambda_1 \vec{v}_1 \vec{x}^T)^T \cdot \vec{u}_i = A^T\vec{u}_i - \lambda_1 \vec{x} \underbrace{\vec{v}_1^T \cdot \vec{u}_i}_{0} = \lambda_i \vec{u}_i$$

☆ B的其他特征值与A非1的特征值相同，

考虑B的特征向量与A的特向量的关系：

B特征向量：$\underbrace{\vec{u}_1, \vec{u}_2, \cdots, \vec{u}_n}_{n-1个}$，$\vec{v}_1$（A第1个特征向量）

假设 $\vec{v}_i = \alpha\vec{u}_i + \beta\vec{v}_1 \quad (i = 2, 3, \cdots, n)$

$$\Rightarrow B\vec{v}_i = (A - \lambda_1\vec{v}_1\vec{x}^T)\vec{v}_i = A\vec{v}_i - \lambda_1\vec{v}_1\vec{x}^T\vec{v}_i$$

$$= A\vec{v}_i - \lambda_1\vec{v}_1\vec{x}^T(\alpha\vec{u}_i + \beta\vec{v}_1)$$

$$= A\vec{v}_i - \alpha\lambda_1\vec{v}_1\vec{x}^T\vec{u}_i - \beta\lambda_1\vec{v}_1\underbrace{\vec{x}^T\vec{v}_1}$$

$$= A\vec{v}_i - \alpha\lambda_1\vec{v}_1\vec{x}^T\vec{u}_i - \beta\lambda_1\vec{v}_1$$

又由于 $B\vec{v}_i = B(\alpha\vec{u}_i + \beta\vec{v}_1) = \alpha B\vec{u}_i + \beta B\vec{v}_1 = \alpha\lambda_i\vec{u}_i$

$$\Rightarrow A\vec{v}_i - \alpha\lambda_i\vec{u}_i - \alpha\lambda_1(\vec{x}^T\vec{u}_i)\vec{v}_1 - \beta\lambda_1\vec{v}_1 = 0 \quad \text{若 } \vec{v}_i \text{ 为 } A \text{ 特征向量}$$

$$\Rightarrow \lambda_i(\alpha\vec{u}_i + \beta\vec{v}_1) - \alpha\lambda_i\vec{u}_i - \alpha\lambda_1(\vec{x}^T\vec{u}_i)\vec{v}_1 - \beta\lambda_1\vec{v}_1 = 0$$

$$\Rightarrow \beta\lambda_i\vec{v}_1 - \alpha\lambda_1(\vec{x}^T\vec{u}_i)\vec{v}_1 - \beta\lambda_1\vec{v}_1 = 0$$

$$\Rightarrow [\beta(\lambda_i - \lambda_1) - \alpha\lambda_1(\vec{x}^T\vec{u}_i)]\vec{v}_1 = 0$$

☆ 可以取 $\beta = \lambda_1(\vec{x}^T\vec{u}_i)$，$\alpha = \lambda_i - \lambda_1$，此时等式严格成立。

$$\Rightarrow \vec{v}_i = (\lambda_i - \lambda_1)\vec{u}_i + \lambda_1(\vec{x}^T\vec{u}_i)\cdot\vec{v}_1$$

$$\Rightarrow \vec{u}_i = \frac{1}{\lambda_i - \lambda_1}\cdot\vec{v}_i - \frac{\lambda_1(\vec{x}^T\vec{u}_i)}{\lambda_i - \lambda_1}\cdot\vec{v}_1$$

☆ 特定 $\vec{x}$ 向量选取方法：Wielandt Deflation

$$\vec{x} = \frac{1}{\lambda_1 V_{1,k}}[a_{k1}, a_{k2}, \cdots, a_{kn}]^T$$

其中 $V_{1,k}$ 为 $\vec{v}_1$ 的 k 分量，a_{ki} 为 A 的 ki 元素（A矩阵第 k 行选取出来）

理论上 k 可以任意选取，一般选取 $\vec{v}_1$ 中 0 元素对应的元素。

$$\vec{x}^T\vec{v}_1 = \frac{1}{\lambda_1 \cdot V_{1,k}}\underbrace{[a_{k1}, a_{k2}, \cdots, a_{kn}]\vec{v}_1}_{\rightarrow A\vec{v}_1 \text{的第 } k \text{ 行对应的结果，即为 } \lambda_1 \cdot V_{1,k}} \quad (A\vec{v}_1 = \lambda_1\vec{v}_1)$$

$$= \frac{1}{\lambda_1 V_{1,k}} \cdot a_1 V_{1,k} = 1$$

例：$A = \begin{bmatrix} 11 & -6 & 4 & -2 \\ 4 & 1 & 0 & 0 \\ -9 & 9 & -6 & 5 \\ -6 & 6 & -6 & 7 \end{bmatrix}$，计算A特征值。

① 利用幂法. $\lambda_1 = 5$, $\vec{v_1} = [1, 1, 0, 0]^T$

② 对于 $\vec{v_1}$ 取 $V_{1,k} = 1$, $k = 1 \Rightarrow \vec{x} = \frac{1}{5\times 1}[11, -6, 4, -2]^T$ ← A的第1行.

$$\Rightarrow B = A - \lambda_1 \vec{v_1}\vec{x}^T = \begin{bmatrix} 11 & -6 & 4 & -2 \\ 4 & 1 & 0 & 0 \\ -9 & 9 & -6 & 5 \\ -6 & 6 & -6 & 7 \end{bmatrix} - 5\begin{bmatrix} 1 \\ 1 \\ 0 \\ 0 \end{bmatrix}\frac{1}{5}[11, -6, +4, -2]$$

$$= \begin{bmatrix} 11 & -6 & 4 & -2 \\ 4 & 1 & 0 & 0 \\ -9 & 9 & -6 & 5 \\ -6 & 6 & -6 & 7 \end{bmatrix} - \begin{bmatrix} 11 & -6 & 4 & -2 \\ 11 & -6 & 4 & -2 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ -7 & 7 & -4 & 2 \\ -9 & 9 & -6 & 5 \\ -6 & 6 & -6 & 7 \end{bmatrix}$$

考虑 $B' = \begin{bmatrix} 7 & -4 & 2 \\ 9 & -6 & 5 \\ 6 & -6 & 7 \end{bmatrix}$ 利用幂法 $\lambda_2 = 4$, $\vec{u_2}' = [0, 1/2, 1]^T$

$\Rightarrow \vec{u_2} = [0, 0, 1/2, 1]^T$

↳ 由于 $k=1$. 要减第一个式.

$\Rightarrow \vec{r_2} = (\lambda_2 - \lambda_1)\vec{u_2} + \lambda_1(\vec{x}^T\vec{u_2})\vec{v_1}$

③ ...

- 其他收缩方法:

利用相似变换, 使 $A \to B = \begin{bmatrix} \lambda_1 & m \\ 0 & B_1 \end{bmatrix}$, 另外特征值为 $\lambda_2, \lambda_3, \cdots, \lambda_n$.

$$B = MAM^{-1} = \begin{bmatrix} \lambda_1 & m \\ 0 & B_1 \end{bmatrix}$$

$A\vec{v_1} = \lambda_1\vec{v_1}$, $\|\vec{v_1}\|_2 = 1$.

☆ $MAM^{-1}\vec{e_1} = \lambda_1\vec{e_1} \Rightarrow AM^{-1}\vec{e_1} = \lambda_1 M^{-1}\vec{e_1} \Rightarrow M^{-1}\vec{e_1} = \vec{v_1} \Rightarrow \vec{e_1} = M\vec{v_1}$

M 为 Householder 变换.

3. QR迭代.

3.1 QR迭代的方法.

迭代算法: $A_k = Q_k R_k$: 对 A_k 进行QR分解, 得到 Q_k, R_k } $k = 0, 1, 2, \cdots$

计算 $A_{k+1} := R_k \cdot Q_k$ 变换顺序矩阵相乘

k迭代.

性质: ① $A_{k+1} = R_k Q_k = (Q_k^T Q_k) R_k Q_k = Q_k^T (Q_k R_k) Q_k = Q_k^T A_k Q_k$ (I, A_k)

$= Q_k^T Q_{k-1}^T A_{k-1} Q_{k-1} Q_k = \cdots$

$= Q_k^T Q_{k-1}^T \cdots Q_0^T A_0 Q_0 \cdots Q_{k-1} Q_k$ Def: $\breve{Q}_k = Q_0 Q_1 \cdots Q_k$

$= \breve{Q}_k^T A_0 \breve{Q}_k = \breve{Q}_k^T A \breve{Q}_k$

② Def: $\breve{R}_k = R_k R_{k-1} \cdots R_1 \cdot R_0$

$\breve{Q}_k \breve{R}_k = Q_0 \cdots Q_k R_k \cdots R_0 = Q_0 \cdots Q_{k-1} A_k R_{k-1} \cdots R_0$ ($Q_k R_k \to A_k$, $Q_0 \cdots Q_{k-1} \to \breve{Q}_{k-1}$)

$= \breve{Q}_{k-1} A_k R_{k-1} \cdots R_0 = \breve{Q}_{k-1} \breve{Q}_{k-1}^T A \breve{Q}_{k-1} R_{k-1} \cdots R_0$ ($A_k \to \breve{Q}_{k-1}^T A \breve{Q}_{k-1}$, $\breve{Q}_{k-1} \breve{Q}_{k-1}^T \to I$)

$= A \breve{Q}_{k-1} \cdot R_{k-1} \cdots R_0 = A \breve{Q}_{k-1} \cdot \breve{R}_{k-1} = A \cdot A \breve{Q}_{k-2} \cdot \breve{R}_{k-2} = \cdots$ ($R_{k-1} \cdots R_0 \to \breve{R}_{k-1}$)

$= A^{k+1}$

QR迭代收敛性质: ($A_{k+1} = \breve{Q}_k^T A_k \breve{Q}_k$, $\breve{Q}_k \cdot \breve{R}_k = A^{k+1}$

设 $A \in \mathbb{R}^{n \times n}$ 有 n 个相异的特征值. 对于A对角化: $A = X \Lambda Y = X \Lambda X^{-1}$

考虑对于 X, Y 分别做QR分解及LU分解. $X = Q_X R_X$, $Y = L_Y U_Y$

$\Lambda = \mathrm{diag}(\lambda_1, \lambda_2, \cdots, \lambda_n)$

$\Rightarrow A^{k+1} = X \Lambda^{k+1} \cdot Y = Q_X R_X \Lambda^{k+1} \cdot L_Y \cdot U_Y = Q_X R_X \Lambda^{k+1} \cdot L_Y \cdot \Lambda^{-(k+1)} \cdot \Lambda^{k+1} \cdot U_Y$

对于 $\Lambda^{k+1} \cdot L_Y \cdot \Lambda^{-(k+1)}$, 其 (i,j) 元素: $l_{ij} \left(\frac{\lambda_i}{\lambda_j}\right)^{k+1}$ $(i > j)$ 下三角矩阵.

若 $|\lambda_1| > |\lambda_2| > \cdots > |\lambda_n| \Rightarrow \left|\frac{\lambda_i}{\lambda_j}\right| < 1 \ (i \neq j) \Rightarrow \lim_{k \to \infty} \left(\frac{\lambda_i}{\lambda_j}\right)^{k+1} = 0$

$\Rightarrow \lim_{k\to\infty}\left[\Lambda^{k+1}\cdot L_Y\cdot\Lambda^{-(k+1)}\right]=D=\mathrm{diag}(l_{11},l_{22},\cdots,l_{nn})$

若 $Y=L_Y\cdot U_Y$ 为 Doolittle 分解，此时 L_Y 为单位下三角 $\Rightarrow D=I$.

设 $\Lambda^{k+1}L_Y\Lambda^{-(k+1)}=I+E_k$ 为单位阵的误差，k 很大时 E_k 每个元素都很小

$\Rightarrow A^{k+1}=Q_xR_x(I+E_k)\cdot\Lambda^{k+1}U_Y=Q_x(I+R_xE_kR_x^{-1})\underline{R_x\Lambda^{k+1}U_Y}$

$=Q_k\underbrace{(I+R_xE_kR_k^{-1})}_{\hookrightarrow Q_ER_E}\underbrace{(R_x\Lambda^{k+1}U_Y)}_{\hookrightarrow \text{上三角}}=Q_kQ_E\cdot\underbrace{(R_ER_x\Lambda^{k+1}U_Y)}_{\hookrightarrow \text{上三角}}$

当 E_k 很小时，$Q_E\to I$.　　令 $W=R_ER_x\Lambda^{k+1}\cdot U_Y$

$=Q_x\cdot Q_E\cdot\underbrace{(D_W\cdot D_W^{-1})}_{D_W\text{为对角阵，对角元为}+1\text{ or }-1.}W=\underbrace{(Q_xQ_E\cdot D_W)}_{\downarrow\overline{Q}_k}\cdot\underbrace{(D_W^{-1}\cdot W)}_{\hookrightarrow\text{设为一个正上三角阵}\ \overline{R}_k}$

$=\overline{Q}_k\cdot\overline{R}_k=\breve{Q}_k\cdot\breve{R}_k$

此时由 QR 分解唯一性：$\overline{Q}_k=\breve{Q}_k$，　$\overline{R}_k=\breve{R}_k$

$\Rightarrow A_{k+1}=\breve{Q}_k^TA\breve{Q}_k=(Q_xQ_E\cdot D_W)^T\cdot A(Q_xQ_ED_W)$

$=D_W^TQ_E^TQ_x^T\underbrace{(Q_xR_x\Lambda(Q_xR_x)^{-1})}_{X\Lambda X^{-1}}(Q_xQ_ED_W)$

$=D_W^T\underbrace{Q_E^T}_{\text{几乎为}I}\cdot R_x\Lambda R_x^{-1}\underbrace{Q_E}_{\text{几乎为}I}D_W$

$R_x\Lambda R_x^{-1}=\begin{bmatrix}\lambda_1 & * & \cdots & *\\ 0 & \lambda_2 & \cdots & *\\ \vdots & \vdots & \ddots & \vdots\\ 0 & 0 & \cdots & \lambda_n\end{bmatrix}$ 为上三角阵，其对角元为 $\lambda_1,\lambda_2,\cdots\lambda_n$

$\Rightarrow A_{k+1}$ 收敛于上三角矩阵，其对角元收敛于 $\lambda_1,\lambda_2,\cdots,\lambda_n$

2. 实用 QR 迭代算法（二阶段算法）

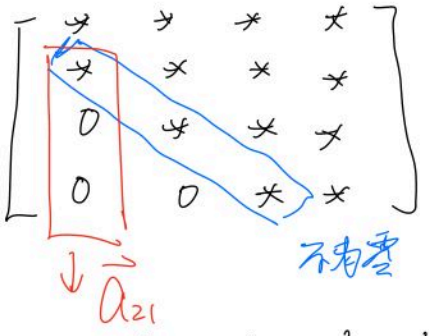
$A\xrightarrow[O(n^3)]{\text{上 Hessenberg 化}}$ 上 Hessenberg 矩阵 $\xrightarrow[O(n^3)]{\text{隐式 QR 迭代}}$ 上三角矩阵.

每步 QR 迭代运算量 $O(n^2)$

① 上 Hessenberg 化：

若H为上Hessenberg矩阵，则其元素 h_{ij} 满足 $h_{ij}=0\ (i>j+1)$

$$H=\begin{bmatrix} * & * & * & * \\ * & * & * & * \\ 0 & * & * & * \\ 0 & 0 & * & * \end{bmatrix}$$



对A矩阵，将其转化为上 Hessenberg 矩阵，同时不改变特征值。

上 Hessenenberg 化过程：

① 实现 $A_1=Q_1AQ_1^T$ （Q_1 为正交阵）

令 $Q_1=\begin{bmatrix} I_1 & \\ & H_1 \end{bmatrix}$，$I_1=[1]\in R^{1\times 1}$，$H_1\in R^{(n-1)\times(n-1)}$ 为 Householder 矩阵。

$$A_1=Q_1AQ_1^T=\begin{bmatrix} I_1 & \\ & H_1 \end{bmatrix}\begin{bmatrix} a_1 & \vec{a}_{12}^T \\ \vec{a}_{21} & A_{22} \end{bmatrix}\begin{bmatrix} I_1^T & \\ & H_1^T \end{bmatrix}$$

$$=\begin{bmatrix} a_1 & \vec{a}_{12}^T \\ H_1\vec{a}_{21} & H_1A_{22} \end{bmatrix}\begin{bmatrix} I_1 & \\ & H_1 \end{bmatrix}=\begin{bmatrix} a_1 & \vec{a}_{12}^T H_1 \\ H_1\vec{a}_{21} & H_1A_{22}H_1 \end{bmatrix}$$

其中 $H_1\vec{a}_{21}=(\alpha_1,\underbrace{0,0,\cdots,0}_{(n-1)\text{个元素}})^T$ H_1 为 Householder 矩阵

② 实现 $A_2=Q_2A_1Q_2^T$ 令 $Q_2=\begin{bmatrix} I_2 & \\ & H_2 \end{bmatrix}$ $I_2=\begin{bmatrix} 1 & \\ & 1 \end{bmatrix}\in R^{2\times 2}$

$H_2\in R^{(n-2)\times(n-2)}$

$$A_2=Q_2A_1Q_2^T=\begin{bmatrix} I_2 & \\ & H_2 \end{bmatrix}\begin{bmatrix} A_{11}' & A_{12}' \\ A_{21}' & A_{22}' \end{bmatrix}\begin{bmatrix} I_2 & \\ & H_2 \end{bmatrix}$$

$$= \begin{bmatrix} A_{11}^1 & A_{12}^1 H_2 \\ H_2 A_{21}^1 & H_2 A_{22}^1 H_2 \end{bmatrix}$$

此时 $A_{21}^1 = \begin{bmatrix} 0 & * \\ 0 & * \\ \vdots & \vdots \\ 0 & * \end{bmatrix}$ $(n-2)$个元素，此时 A_{21}^1 第1列全为零.

其中 $H_2 A_{21}^1 = \begin{bmatrix} 0 & * \\ 0 & * \\ \vdots & \vdots \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & \alpha_2 \\ 0 & 0 \\ \vdots & \vdots \\ 0 & 0 \end{bmatrix}$ H_2为$(n-2)$维Householder矩阵.

以上过程进行 $n-2$ 步，即得到上Hessenberg矩阵.

$$\star\ Q_k A_{k-1} Q_k^T = \begin{bmatrix} I_k & \\ & H_n \end{bmatrix} \begin{bmatrix} A_{11}^{k-1} & A_{12}^{k-1} \\ A_{21}^{k-1} & A_{22}^{k-1} \end{bmatrix} \begin{bmatrix} I_k & \\ & H_k \end{bmatrix}$$

$$= \begin{bmatrix} A_{11}^{k-1} & A_{12}^{k-1} \\ H_k A_{21}^{k-1} & H_k A_{22}^{k-1} \end{bmatrix} \begin{bmatrix} I_k & \\ & H_k \end{bmatrix}$$ ① 第一步

$$= \begin{bmatrix} A_{11}^{k-1} & A_{12}^{k-1} H_k \\ H_k A_{21}^{k-1} & H_k A_{22}^{k-1} \cdot H_k \end{bmatrix}$$ ② 第二步

A_{11}^{k-1}：k行 k列；$A_{12}^{k-1} H_k$：k行 $n-k$列；$H_k A_{21}^{k-1}$：$n-k$行 k列；$H_k A_{22}^{k-1} \cdot H_k$：$n-k$行 $n-k$列

$H_k = I - \beta_k \vec{v}_k \vec{v}_k^T$

第一步中 $H_k A_{21}^{k-1}$ 只用计算 A_{21}^{k-1} 最后一列，并得到 β_k, $\vec{v}_k$

$$H_k A_{22}^{k-1} = A_{22}^{k-1} - \beta_k \vec{v}_k \left(\vec{v}_k^T A_{22}^{k-1} \right)$$

运算量 $O((n-k)^2)$ 得到行向量

运算量 $O((n-k)^2)$ 得到 $(n-k)$维矩阵

运算量 $O((n-k)^2)$

第二步中 $A_{12}^{k-1} H_k = A_{12}^{k-1} \left(I - \beta_k \vec{v}_k \vec{v}_k^T \right)$

$= A_{12}^{k-1} - \beta_k (A_{12}^{k-1}) \vec{V}_k \cdot \vec{V}_k^T$

$O(k(n-k))$ 得到 k 维列向量.

$O(k(n-k))$ 得 $k \times (n-k)$ 矩阵.

$O(k(n-k))$

$(H_2 A_{22}^{k-1}) H_2 = H_2 A_{22}^{k-1} - \beta_k (H_2 A_{22}^{k-1} \vec{V}_k) \cdot \vec{V}_k^T$

单运算量 $O((n-k)^2)$

- 上 Hessenberg 分解算法流程.

给定 A.

循环 $k = 1 \to n-2$.

$\vec{t} = A(k+1:n, k)$ # A 中第 k+1 至第 n 行, 第 k 列元素

$\vec{V} = \vec{t} - \|t\|_2 \vec{e}_1$ # $\vec{e}_1 = (\underbrace{1, 0, \cdots, 0}_{n-k-1})^T$

$\vec{V} = \vec{t}$, $V_1 = V_1 - \|t\|_2$

$\beta = 2 / \vec{V}^T \vec{V}$

$A(k+1:n, k:n) = H_k A(k+1:n, k:n)$

$= A(k+1:n, k:n) - \beta \vec{V} (\vec{V}^T \cdot A(k+1:n, k:n))$

计算 $H_k [A_{21}^{k-1} \quad A_{22}^{k-1}]$ ①

$A(1:n, k+1:n) = A(1:n, k+1:n) \cdot H_k$

$= A(1:n, k+1:n) - \beta_k (A(1:n, k+1:n) \vec{V}) \cdot \vec{V}^T$

计算 $\begin{bmatrix} A_{12}^{k-1} \\ H_k A_{22}^{k-1} \end{bmatrix} \cdot H_k$ ②

$Q(k+1:n, 1:n) = H_k Q(k+1:n, 1:n) = \cdots$

循环结束

运算量 $\sum_{k=1}^{n-1}\left[(n-k+1)\times 2(n-k)+2(n-k)\times(n-k+1)+n\times 2(n-k)\right.$

$\left.+2n\times(n-k)+n\times 2(n-k)+2n\times(n-k)\right]$

$\longrightarrow O(n^3)$

② 照片QR迭代

定理：$A\in R^{n\times n}$ 为非奇异上Hessenberg矩阵，$A=QR$，则 $A'=RQ$ 也为上Hessenberg矩阵.

证明. $A=QR \Rightarrow Q=AR^{-1}$ $\Rightarrow$ Q第j列为A前j列线性组合.

☆ $Q=[\vec{q}_1,\cdots,\vec{q}_n]=[\vec{a}_1,\vec{a}_2\cdots,\vec{a}_n]\begin{bmatrix} r_{11}' & r_{12}' & r_{13}' & \cdots \\ 0 & r_{22}' & r_{23}' & \cdots \\ 0 & 0 & r_{33}' & \cdots \\ \vdots & \vdots & \vdots & \end{bmatrix}$

$\Rightarrow$ Q为上Hessenberg矩阵.

$\Rightarrow A'=RQ$，则 A' 第j列为R前 j+1 列线性组合.

即 A' 为上Hessenberg矩阵.

☆ 上Hessenberg矩阵的QR迭代不改变上Hessenberg性质.

对于上Hessenberg矩阵的QR分解相对容易很多.

- 隐式QR计算：以 $A \in R^{5\times5}$ 为例。

$$A = \begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & 0 & \times & \times & \times \\ 0 & 0 & 0 & \times & \times \end{bmatrix}$$

① 构造 $G_1^T = \begin{bmatrix} c_1 & s_1 & & \\ -s_1 & c_1 & & \\ & & I_3 & \end{bmatrix}$ 其中 c_1, s_1 为特定选取。G_1 为 Givens 变换矩阵。

使 $G_1^T A = \begin{bmatrix} \times & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & 0 & \times & \times & \times \\ 0 & 0 & 0 & \times & \times \end{bmatrix}$ 计算中只考虑第1,2行元素 $O(n)$

为保持特征值不变：

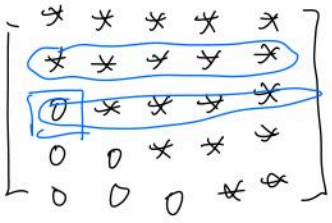
$$A^{(1)} = G_1^T A G_1 = \begin{bmatrix} \times & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & 0 & \times & \times & \times \\ 0 & 0 & 0 & \times & \times \end{bmatrix} \begin{bmatrix} c_1 & -s_1 & & \\ s_1 & c_1 & & \\ & & I_3 & \end{bmatrix}$$

$$= \begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ + & \times & \times & \times & \times \\ 0 & 0 & \times & \times & \times \\ 0 & 0 & 0 & \times & \times \end{bmatrix}$$

$O(n)$ 第1,2列做线性组合

+：凸起（bulge）破坏原为上Hessenberg性质。

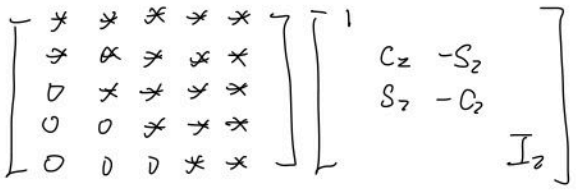
② 构造 $G_2^T = \begin{bmatrix} 1 & & & & \\ & c_2 & -s_2 & & \\ & s_2 & c_2 & & \\ & & & I_2 & \end{bmatrix}$，$G_2$ 为 Givens 变换矩阵。

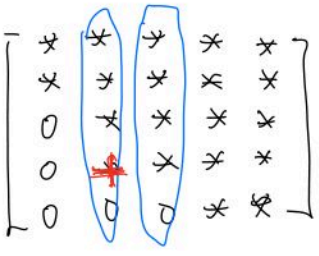
使 $G_2^T A^{(1)} =$ 

计算不考虑第2,3行元素变化

$O(n)$

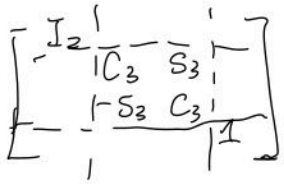
为保持特征值不变.

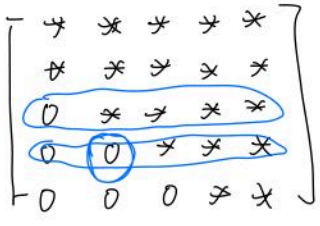
$A^{(2)} = G_2^T A^{(1)} \cdot G_2 =$ 

$=$ 

↓ 第2,3列做线性组合.

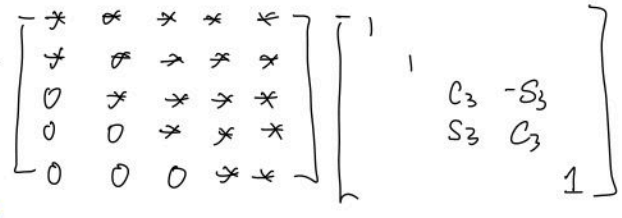
计算量 $O(n)$

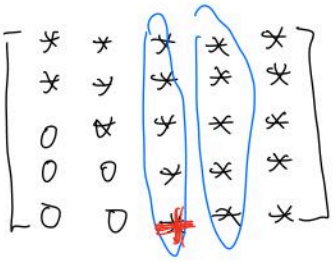
③ 构造 $G_3^T =$  , G_3^T 为 Givens 变换矩阵

使 $G_3^T A^{(2)} =$ 

计算中第3,4行元素变化

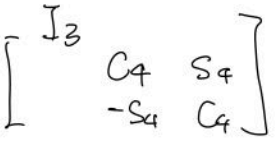
$O(n)$

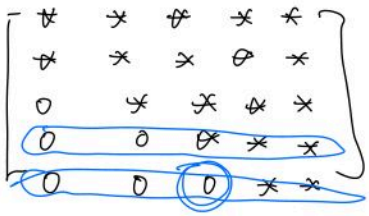
$A^{(3)} = G_3^T A^{(2)} \cdot G_3 =$ 

$=$ 

↓ 计算中第3,4列的线性组合

$O(n)$

④ 构造 $G_4^T =$  , G_4^T 为 Givens 变换

使 $G_4^T A^{(3)} =$ 

计算中只考虑第4.5行元素变化

$O(n)$

$$\Rightarrow A^{(4)} = G_4^T A^{(3)} G_4 = \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ 0 & * & * & * & * \\ 0 & 0 & * & * & * \\ 0 & 0 & 0 & * & * \end{bmatrix} \begin{bmatrix} I_{3} & & & \\ & 1 & & \\ & & c_4 & -s_4 \\ & & s_4 & c_4 \end{bmatrix}$$

$$= \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ 0 & * & * & * & * \\ 0 & 0 & * & * & * \\ 0 & 0 & 0 & * & * \end{bmatrix}$$

↙ 计算中第4.5列线性组合

$O(n)$

$A^{(4)}$ 中没有出现，保持上Hessenberg性质，

$A \longrightarrow A^{(4)} = G_4^T G_3^T G_2^T G_1^T A G_1 G_2 G_3 G_4$

与A特征值相同。

对比常规QR与隐式QR：

常规：$A = QR$，$A' = RQ = Q^T A Q$　$\tilde{Q} = Q$

隐式：$A^{(4)} = G_4^T G_3^T G_2^T G_1^T A G_1 G_2 G_3 G_4$

↓

$= \tilde{G}_1^T A \tilde{G}_1$　其中 $G_1 G_2 G_3 G_4 = \tilde{G}_1$

计算量 $O(n^2)$

□隐式Q定理：设 $A \in R^{n\times n}$ 为不可约上Hessenberg矩阵，存在 $P_1 = U^T A U$，

$P_2 = V^T A V$，其中 U, V 为正交矩阵，P_1, P_2 均为上Hessenberg矩阵，

若 U 第1列与 V 第1列相同（$\vec{u}_1 = \vec{v}_1$）则必存在对角阵 D，

（D 的对角元为1或-1），使 $U = VD$，$P_1 = D P_2 D$。

⊗ 若标准QR与隐式QR若 $\tilde{Q}$ 与 $\tilde{C}_1$ 第1列相同，则得到的结果最多相差符号.

在标准QR中，由于 $A = QR \Rightarrow \vec{a}_1 = \vec{q}_1 \cdot m \Rightarrow \vec{q}_1 = \begin{bmatrix} a_{11} \\ a_{21} \\ 0 \\ \vdots \\ 0 \end{bmatrix} / \sqrt{a_{11}^2 + a_{21}^2}$

即 $\tilde{C}$ 第1列 $\vec{q}_1$

在隐式QR中，$\tilde{C}_1 = C_1 C_2 C_3 C_4 = \begin{bmatrix} -C_1 & +S_1 & & \\ -S_1 & C_1 & & \\ & & I_3 & \end{bmatrix} \begin{bmatrix} 1 & & & \\ & C_2 & S_2 & \\ & -S_2 & C_2 & \\ & & & I_2 \end{bmatrix} \cdots$

即 $\tilde{C}_1$ 第1列 $\vec{q}_1 = \begin{bmatrix} -C_1 \\ -S_1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$

由于隐式QR第①步中 $C_1^T A$ 使 A 第1列 $\Rightarrow \begin{bmatrix} * \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$

$$\begin{bmatrix} -C_1 & -S_1 \\ +S_1 & C_1 \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} = \begin{bmatrix} C_1 a_{11} - S_1 a_{21} & \cdots \\ S_1 a_{11} + C_1 a_{21} & \cdots \end{bmatrix}$$

其中 $S_1 a_{11} + C_1 a_{21} = 0$ 且 $S_1^2 + C_1^2 = 1$

则 $C_1 = a_{11} / \sqrt{a_{11}^2 + a_{21}^2}$，$S_1 = -a_{21} / \sqrt{a_{11}^2 + a_{21}^2}$

$$\Rightarrow \vec{q}_1 = [a_{11}, a_{21}, 0, 0, 0]^T / \sqrt{a_{11}^2 + a_{21}^2} = \vec{q}_1$$

$\Rightarrow \tilde{C}_1$ 与 $\tilde{Q}$ 第1列相同，满足隐式Q定理

$\Rightarrow A$ 与 $A^{(4)}$ 几乎相同，最多相差符号.

$\Rightarrow$ 隐式QR计算完全可以代替标准QR，且计算量更小.

- 带位移的QR迭代.

$$A_k = Q_k R_k + \sigma_k I$$ QR分解针对 $A_k - \sigma_k I$ 计算.

$$A_{k+1} = R_k Q_k + \sigma_k I = (Q_k^T Q_k) R Q_k + \sigma_k I$$
$$= Q_k^T (Q_k R_k) Q_k + \sigma_k I = Q_k^T A_k Q_k$$

- 双重步QR步代.