COURSE NOTES · DIGITAL EDITION

计算方法与优化

课堂手写笔记电子整理版

本讲义按五份课堂手写笔记整理，整理定义、定理、推导、算法与例题，并重绘原稿中的数学示意图。

文中“原稿第 × 页”均指相应原 PDF 的页码。标有【补全】的文字为依据上下文和数学知识补入的解释；标有【校正】的文字说明对公式下标、符号或条件的修正。重绘曲线与数据点用于表达原图的数学关系，不视作原始实验数据。

5 份原稿 · 53 页手写笔记
公式规范排版 · 图形重新绘制 · 按原稿页码定位

内容目录

右侧为 PDF 合订本的起始页码

1. LU 分解 3

2. 迭代法与收敛性 6

3. 线性方程组与梯度法 13

4. 最小二乘 22

5. 非线性方程 38

阅读提示：目录可点击跳转。正文中的补全与校正标记用于核对原稿；未标记的推导以原稿可辨内容为基础，统一了排版与符号写法。

LU 分解

原稿：CM+Opt_LU.pdf，共 2 页。

1 分解形式与计算顺序

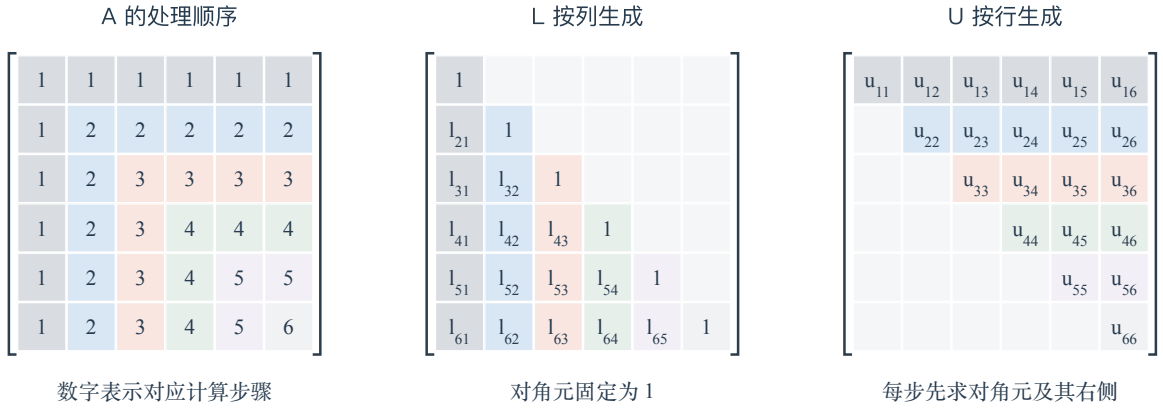
（原稿第 1 页）设 $A=(a_{ij})\in\mathbb{R}^{n\times n}$，将它分解为

$$A=LU,$$

其中 $L=(l_{ij})$ 为单位下三角矩阵，$U=(u_{ij})$ 为上三角矩阵：

$$L=\begin{pmatrix}1 & 0 & \cdots & 0\\ l_{21} & 1 & \cdots & 0\\ \vdots & \vdots & \ddots & \vdots\\ l_{n1} & l_{n2} & \cdots & 1\end{pmatrix},\qquad U=\begin{pmatrix}u_{11} & u_{12} & \cdots & u_{1n}\\ 0 & u_{22} & \cdots & u_{2n}\\ \vdots & \vdots & \ddots & \vdots\\ 0 & 0 & \cdots & u_{nn}\end{pmatrix}.$$

计算顺序为：先算 U 的第 1 行，再算 L 的第 1 列；然后算 U 的第 2 行、L 的第 2 列；依次进行到第 n 步。这是 Doolittle 分解的计算方式。



LU 分解的逐行逐列计算顺序

图中相同颜色对应同一步：从矩阵左上角向右下角推进，每一步先求上三角矩阵的一行，再求下三角矩阵的一列。

2 元素关系与递推公式

（原稿第 1 页）由 $A=LU$，第一步有

$$a_{1j}=u_{1j}\quad(j=1,\dots,n),\qquad a_{i1}=l_{i1}u_{11}\quad(i=2,\dots,n).$$

第 k 步，将已经求出的前 $k-1$ 步结果代入矩阵乘法，得到

$$a_{kj} = \sum_{s=1}^{k-1} l_{ks}u_{sj} + u_{kj}, \qquad j = k, \dots, n,$$

$$a_{ik} = \sum_{s=1}^{k-1} l_{is}u_{sk} + l_{ik}u_{kk}, \qquad i = k+1, \dots, n.$$

因此，递推公式为

$$\boxed{u_{kj} = a_{kj} - \sum_{s=1}^{k-1} l_{ks}u_{sj}, \qquad j = k, \dots, n,}$$

$$\boxed{l_{ik} = \frac{a_{ik} - \sum_{s=1}^{k-1} l_{is}u_{sk}}{u_{kk}}, \qquad i = k+1, \dots, n.}$$

【校正】原稿第 1 页一般式中，第二个求和的下标存在混写；按矩阵乘法应为 $l_{is}u_{sk}$。第 2 页的递推式与这一写法一致。

3 各步展开

（原稿第 1 – 2 页）

第 1 步

$$u_{1j} = a_{1j} \quad (j = 1, \dots, n), \qquad l_{i1} = \frac{a_{i1}}{u_{11}} \quad (i = 2, \dots, n).$$

第 2 步

$$u_{2j} = a_{2j} - l_{21}u_{1j} \quad (j = 2, \dots, n),$$

$$l_{i2} = \frac{a_{i2} - l_{i1}u_{12}}{u_{22}} \quad (i = 3, \dots, n).$$

此时使用已知的 L 的第 1 列与 U 的第 1 行。

第 3 步

$$u_{3j} = a_{3j} - \sum_{s=1}^{2} l_{3s}u_{sj} \quad (j = 3, \dots, n),$$

$$l_{i3} = \frac{a_{i3} - \sum_{s=1}^{2} l_{is}u_{s3}}{u_{33}} \quad (i = 4, \dots, n).$$

此时使用已知的 L 的第 1、2 列与 U 的第 1、2 行。

第 k 步

使用 L 的前 $k-1$ 列和 U 的前 $k-1$ 行，按上述一般公式先求 u_{kj}，再求 l_{ik}。

第 n 步

$$u_{nn} = a_{nn} - \sum_{s=1}^{n-1} l_{ns} u_{sn}.$$

此时没有新的严格下三角元素需要计算。

4 适用条件与线性方程组求解

【补全】以上是不选主元的 LU 分解过程，除法步骤要求相应主元 $u_{kk} \neq 0$。若各阶顺序主子式均不为零，则存在唯一的单位下三角 L 与非奇异上三角 U 使 $A = LU$。实际数值计算常结合选主元，以降低误差放大，写为 $PA = LU$。

【补全】用分解结果解 $Ax = b$ 时，先作前代，再作回代：

$$Ly = b, \qquad Ux = y.$$

$$y_i = b_i - \sum_{j=1}^{i-1} l_{ij} y_j \quad (i = 1, \dots, n),$$

$$x_i = \frac{y_i - \sum_{j=i+1}^{n} u_{ij} x_j}{u_{ii}} \quad (i = n, n-1, \dots, 1).$$

若使用 $PA = LU$，则第一步改为 $Ly = Pb$。

线性迭代法的收敛性

可约矩阵与对角占优

（原稿第 1 – 2 页）

设 $A \in \mathbb{R}^{n\times n}$。若存在排列矩阵 P，使

$$P^{T} A P = \begin{bmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{bmatrix}, \qquad A_{11} \in \mathbb{R}^{r\times r},\quad 1 \le r < n,$$

则称 A 为**可约矩阵**；否则称为**不可约矩阵**。

分块形式的含义是：若

$$M = \begin{bmatrix} M_{11} & M_{12} \\ 0 & M_{22} \end{bmatrix}, \qquad x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

则

$$Mx = \begin{bmatrix} M_{11}x_1 + M_{12}x_2 \\ M_{22}x_2 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}.$$

第二组方程不依赖第一组未知量。

等价地，令 $W = \{1, 2, \dots, n\}$。A 可约当且仅当存在两个非空、不相交的集合 S, T，满足 $S \cup T = W$，且

$$a_{ij} = 0, \qquad i \in S,\ j \in T.$$

【补全】原稿未写明两集合非空；这一条件是可约定义所必需的。

对角占优的约定。 按行定义：

$$|a_{ii}| \ge \sum_{j \ne i} |a_{ij}|, \qquad i = 1, \dots, n.$$

每行均为严格不等式时称严格对角占优。本章的“不可约弱对角占优”指矩阵不可约、每行满足上述不等式，且至少有一行严格成立。【补全】仅有不可约与所有行弱不等式，不能保证非奇异。

非奇异性定理

若 A 严格对角占优，或不可约弱对角占优，则 A 非奇异。

严格对角占优的证明。 反设 A 奇异，则存在非零向量 v 使 $Av = 0$。令 $x = v / \|v\|_{\infty}$，选取 i 使 $|x_i| = \|x\|_{\infty} = 1$。由第 i 行方程得

$$a_{ii} x_i = -\sum_{j \ne i} a_{ij} x_j.$$

从而

$$|a_{ii}| = |a_{ii}x_i| \le \sum_{j\neq i} |a_{ij}|\,|x_j| \le \sum_{j\neq i} |a_{ij}|,$$

与严格对角占优矛盾。

不可约弱对角占优的证明。【补全原稿留白】 仍取 $\|x\|_\infty = 1$，令 $S = \{i : |x_i| = 1\}$。若 $S \neq W$，则对每个 $i \in S$，

$$|a_{ii}| \le \sum_{j\neq i} |a_{ij}|\,|x_j| \le \sum_{j\neq i} |a_{ij}| \le |a_{ii}|.$$

各步必须取等号，因此 $i \in S, j \notin S$ 时必有 $a_{ij} = 0$，这与不可约性矛盾。所以 $S = W$。取对角严格占优的那一行，又由上式得到矛盾。因此 $Ax = 0$ 只有零解。

对称矩阵的正定性推论

若 $A = A^T$、$a_{ii} > 0$，且 A 严格对角占优或不可约弱对角占优，则 A 正定。

证明。 实对称矩阵的特征值均为实数。若有特征值 $\lambda \le 0$，则

$$C = A - \lambda I, \qquad c_{ii} = a_{ii} - \lambda \ge a_{ii} > 0,$$

而非对角元素不变，故 C 仍严格对角占优或不可约弱对角占优。由上一结论 $\det C \neq 0$，与 λ 为特征值矛盾。所以所有特征值均为正，A 正定。

Jacobi 与 Gauss–Seidel 迭代的收敛条件

（原稿第 2 – 3 页）

统一采用分裂

$$A = D - L - U,$$

其中 $D = \operatorname{diag}(a_{11}, \dots, a_{nn})$，$L, U$ 分别为 A 的严格下、上三角部分的相反数。Jacobi（简称 J）和 Gauss – Seidel（简称 GS）迭代分别为

$$x^{k+1} = B_J x^k + D^{-1} b, \qquad B_J = D^{-1}(L + U),$$

$$x^{k+1} = B_{GS} x^k + (D - L)^{-1} b, \qquad B_{GS} = (D - L)^{-1} U.$$

对一般定常迭代 $x^{k+1} = Bx^k + g$，对任意初值收敛的充要条件为 $\rho(B) < 1$，其中 ρ 为谱半径。

对角占优条件下的收敛定理

若 A 严格对角占优或不可约弱对角占优，则 J 和 GS 迭代均收敛。

J 迭代的证明。 若 $B_J v = \lambda v$，反设 $|\lambda| \ge 1$。有

$$B_J - \lambda I = D^{-1}(L + U - \lambda D).$$

令 $C = L + U - \lambda D$，则

$$c_{ii} = -\lambda a_{ii}, \qquad c_{ij} = -a_{ij} \quad (i \neq j).$$

因此 C 仍严格对角占优或不可约弱对角占优，必非奇异，从而 $\det(B_J - \lambda I) \neq 0$，矛盾。故 $|\lambda| < 1$。

GS 迭代的证明。【补全原稿仅列出的分解】

$$B_{GS} - \lambda I = (D - L)^{-1}\big[U - \lambda(D - L)\big].$$

若 $|\lambda| \geq 1$，令 $C = U - \lambda(D - L)$，则

$$\begin{aligned} |c_{ii}| &= |\lambda|\,|a_{ii}|, \\ \sum_{j \neq i} |c_{ij}| &= |\lambda| \sum_{j<i} |a_{ij}| + \sum_{j>i} |a_{ij}| \\ &\leq |\lambda| \sum_{j \neq i} |a_{ij}| \leq |c_{ii}|. \end{aligned}$$

严格性及非对角零元结构相应保留，故 C 非奇异，产生同样矛盾。于是 $\rho(B_{GS}) < 1$。

对称矩阵的进一步结论

1. 若 $A = A^T$ 且 $a_{ii} > 0$，则 **J 迭代收敛，当且仅当 A 与 $2D - A$ 都正定。**
2. 若 A 对称正定，则 **GS 迭代收敛。**
3. 若 $A = A^T$、$\det A \neq 0$、$a_{ii} > 0$，且 GS 迭代收敛，则 A 正定。

【补全第一条的说明】令 $H = D^{-1/2} A D^{-1/2}$，则 B_J 与 $I - H$ 相似。$\rho(B_J) < 1$ 等价于 H 的特征值都落在 $(0, 2)$，亦即 H 与 $2I - H$ 均正定；通过合同变换，等价于 A 与 $2D - A$ 均正定。

一维模型问题

（原稿第 4 – 5 页；原编号 2.2.4）

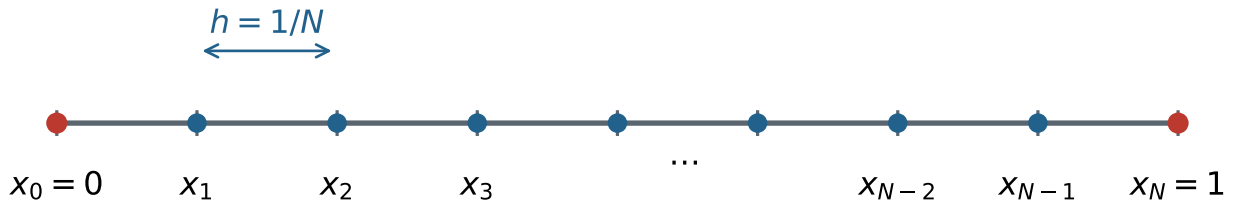
一维 Poisson 方程的离散化

考虑齐次 Dirichlet 边界条件下的方程

$$\begin{cases} -u''(x) = f(x), & 0 < x < 1, \\ u(0) = u(1) = 0. \end{cases}$$

取均匀网格

$$x_i = ih, \qquad i = 0, 1, \ldots, N, \qquad h = 1/N.$$



一维区间的均匀网格与内部未知节点

令 $u_i \approx u(x_i)$，$f_i = f(x_i)$。利用中心差分近似

$$\frac{u(x_{i+1}) - 2u(x_i) + u(x_{i-1})}{h^2} \approx u''(x_i).$$

Taylor 展开。 若 u 足够光滑，

$$u(x_i + h) = u(x_i) + hu'(x_i) + \frac{h^2}{2}u''(x_i) + \frac{h^3}{6}u'''(x_i) + O(h^4),$$
$$u(x_i - h) = u(x_i) - hu'(x_i) + \frac{h^2}{2}u''(x_i) - \frac{h^3}{6}u'''(x_i) + O(h^4).$$

相加可得

$$\frac{u(x_{i+1}) - 2u(x_i) + u(x_{i-1})}{h^2} = u''(x_i) + O(h^2).$$

【校正】原稿红字以截断至二阶的展开写出了较弱的 $O(h)$ 估计；利用奇次项相消，在 $u \in C^4$ 等适当光滑条件下，标准中心差分的截断误差为 $O(h^2)$。

差分方程为

$$-u_{i-1} + 2u_i - u_{i+1} = h^2 f_i, \qquad i = 1, \dots, N-1,$$

其中 $u_0 = u_N = 0$。因此

$$\begin{bmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -1 & 2 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_{N-2} \\ u_{N-1} \end{bmatrix} = h^2 \begin{bmatrix} f_1 \\ f_2 \\ \vdots \\ f_{N-2} \\ f_{N-1} \end{bmatrix}.$$

【校正】此处统一以 N 表示区间数，未知量为 $N-1$ 个；原稿个别矩阵下标混用了 n, N。方程 $u'' = -f$ 移项后，右端为正的 $h^2 f_i$。

该三对角矩阵对称，内部行为弱对角占优，首末行严格占优，并且不可约。因此它非奇异且正定，J 与 GS 迭代均收敛。

非线性右端的迭代线性化

对

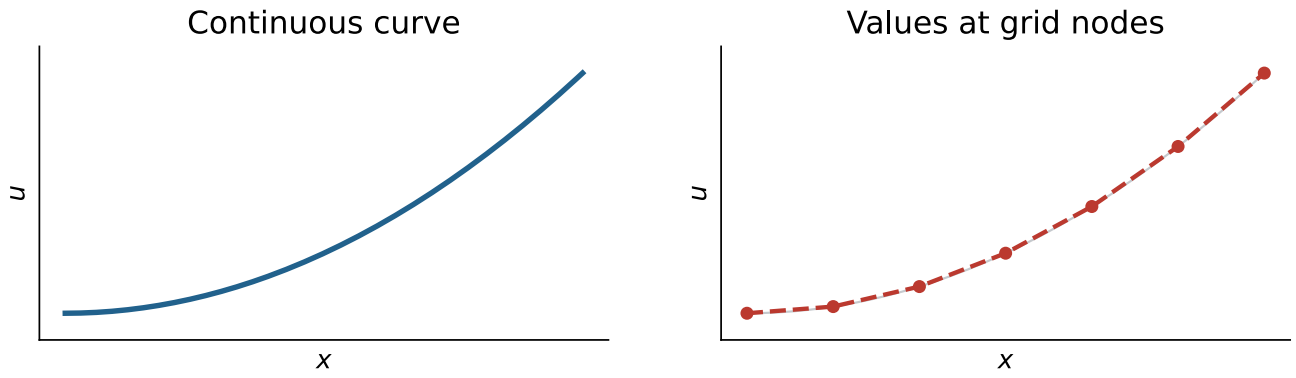
$$\begin{cases} -u''(x) = f(u(x)), \\ u(0) = u(1) = 0, \end{cases}$$

给定 u^k，以旧迭代值计算右端，求解

$$\begin{cases} -(u^{k+1})''(x) = f(u^k(x)), \\ u^{k+1}(0) = u^{k+1}(1) = 0. \end{cases}$$

离散后，每一步需求解同一三对角系数矩阵 T 的线性方程组：

$$T \begin{bmatrix} u_1^{k+1} \\ u_2^{k+1} \\ \vdots \\ u_{N-1}^{k+1} \end{bmatrix} = h^2 \begin{bmatrix} f(u_1^k) \\ f(u_2^k) \\ \vdots \\ f(u_{N-1}^k) \end{bmatrix}, \qquad k = 0, 1, \dots.$$



连续曲线与离散节点的示意重绘，节点间连线只表示离散近似

【补全】这是固定点迭代的构造；非线性外层迭代是否收敛还需对 f 等作进一步假设，不能仅由 T 正定推出。

例题 J 与 GS 不存在一般的收敛包含关系

（原稿第 5 – 6 页；原编号 2.2.5）

给定

$$A_1 = \begin{bmatrix} 2 & -1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & -2 \end{bmatrix}, \qquad A_2 = \begin{bmatrix} 1 & 2 & -2 \\ 1 & 1 & 1 \\ 2 & 2 & 1 \end{bmatrix}.$$

证明：对 A_1，J 不收敛而 GS 收敛；对 A_2，J 收敛而 GS 不收敛。这里“不收敛”指不具有对任意初值收敛的性质。

第一组矩阵

$$D_1=\begin{bmatrix}2&0&0\\0&1&0\\0&0&-2\end{bmatrix},\quad L_1=\begin{bmatrix}0&0&0\\-1&0&0\\-1&-1&0\end{bmatrix},\quad U_1=\begin{bmatrix}0&1&-1\\0&0&-1\\0&0&0\end{bmatrix}.$$

于是

$$B_{J,1}=D_1^{-1}(L_1+U_1)=\begin{bmatrix}0&1/2&-1/2\\-1&0&-1\\1/2&1/2&0\end{bmatrix}.$$

其特征多项式为

$$\det(\lambda I-B_{J,1})=\lambda\left(\lambda^2+\frac{5}{4}\right),$$

故特征值为 $0,\pm\frac{\sqrt{5}}{2}\mathrm{i}$，$\rho(B_{J,1})=\sqrt{5}/2>1$，J 不收敛。

另一方面，

$$B_{GS,1}=(D_1-L_1)^{-1}U_1=\begin{bmatrix}0&1/2&-1/2\\0&-1/2&-1/2\\0&0&-1/2\end{bmatrix}.$$

$$\det(\lambda I-B_{GS,1})=\lambda\left(\lambda+\frac{1}{2}\right)^2,$$

所以 $\rho(B_{GS,1})=1/2<1$，GS 收敛。

相应的分量迭代格式。 对 $A_1x=b$，J 迭代为

$$\begin{aligned}x_1^{k+1}&=\tfrac{1}{2}(x_2^k-x_3^k+b_1),\\x_2^{k+1}&=-x_1^k-x_3^k+b_2,\\x_3^{k+1}&=\tfrac{1}{2}(x_1^k+x_2^k-b_3).\end{aligned}$$

GS 迭代为

$$\begin{aligned}x_1^{k+1}&=\tfrac{1}{2}(x_2^k-x_3^k+b_1),\\x_2^{k+1}&=-x_1^{k+1}-x_3^k+b_2,\\x_3^{k+1}&=\tfrac{1}{2}(x_1^{k+1}+x_2^{k+1}-b_3).\end{aligned}$$

【校正】原稿 GS 第二行右端误写为 b_3，应为 b_2。

第二组矩阵

$$D_2=I,\quad L_2=\begin{bmatrix}0&0&0\\-1&0&0\\-2&-2&0\end{bmatrix},\quad U_2=\begin{bmatrix}0&-2&2\\0&0&-1\\0&0&0\end{bmatrix}.$$

【补全原稿未完成的计算】

$$B_{J,2}=\begin{bmatrix}0&-2&2\\-1&0&-1\\-2&-2&0\end{bmatrix},\qquad \det(\lambda I-B_{J,2})=\lambda^3.$$

故 $\rho(B_{J,2})=0<1$，J 收敛；事实上 $B_{J,2}^{3}=0$，精确算术中至多三步消去初始误差。

$$B_{GS,2}=\begin{bmatrix}0 & -2 & 2\\ 0 & 2 & -3\\ 0 & 0 & 2\end{bmatrix},\qquad \det(\lambda I-B_{GS,2})=\lambda(\lambda-2)^{2}.$$

故 $\rho(B_{GS,2})=2>1$，GS 不收敛。

迭代展开与矩阵几何级数

（原稿第 6 – 7 页）

由 $x^{k+1}=Bx^{k}+g$ 逐次代入，

$$\begin{aligned}x^{k+1}&=B(Bx^{k-1}+g)+g\\&=B^{3}x^{k-2}+B^{2}g+Bg+g\\&=B^{k+1}x^{0}+\sum_{i=0}^{k}B^{i}g.\end{aligned}$$

【校正】原稿末式求和下标写为 $i=1$，应从 $i=0$ 开始，才能包含末项 g。

核心结论是

$$\lim_{k\to\infty}B^{k}=0\quad\Longleftrightarrow\quad\rho(B)<1.$$

并且

$$(I-B)(I+B+B^{2}+\cdots+B^{k})=I-B^{k+1}.$$

因此当 $\rho(B)<1$ 时，

$$\sum_{i=0}^{\infty}B^{i}=(I-B)^{-1},\qquad x^{k}\longrightarrow x^{*}=(I-B)^{-1}g.$$

线性方程组的梯度法

等价变分问题

（原稿第 1 – 2 页；原编号 2.3）

从弹簧平衡到能量最小化

弹簧的平衡方程为 $kx = b$。弹性势能为 $\frac{1}{2}kx^2$，外力势能为 $-bx$，总势能

$$E(x) = \frac{1}{2}kx^2 - bx.$$

当 $k > 0$ 时，使能量最小的条件为

$$E'(x) = kx - b = 0,$$

恰好得到原平衡方程。这说明求平衡方程可以等价地转化为求能量最小值。

对称正定线性方程组的二次能量

设 $A \in \mathbb{R}^{n\times n}$ 为对称正定矩阵，$b = (b_1, \dots, b_n)^T$，$x = (x_1, \dots, x_n)^T$。对方程组 $Ax = b$，定义二次函数

$$\varphi(x) = \frac{1}{2}x^T A x - b^T x = \frac{1}{2}\sum_{i,j=1}^{n} a_{ij}x_i x_j - \sum_{i=1}^{n} b_i x_i.$$

【补全】原稿简称“正定”，后续求导和共轭梯度理论均使用 $A = A^T$，此处明确为对称正定。

该函数具有以下性质：

$$\nabla \varphi(x) = Ax - b,$$

$$\varphi(x + \alpha y) = \varphi(x) + \alpha (Ax - b)^T y + \frac{\alpha^2}{2} y^T A y,$$

若 $Ax^* = b$，则

$$\varphi(x^*) = -\frac{1}{2}(x^*)^T A x^* = -\frac{1}{2} b^T x^*.$$

梯度公式的证明。 记 Kronecker 符号 $\delta_{ik} = \partial x_i / \partial x_k$，则

$$\begin{aligned}
\frac{\partial \varphi}{\partial x_k} &= \frac{1}{2}\sum_{i,j} a_{ij}(x_j \delta_{ik} + x_i \delta_{jk}) - \sum_i b_i \delta_{ik} \\
&= \frac{1}{2}\sum_j a_{kj} x_j + \frac{1}{2}\sum_i a_{ik} x_i - b_k \\
&= \sum_j a_{kj} x_j - b_k = (Ax - b)_k.
\end{aligned}$$

其中最后一步使用了对称性 $a_{ik} = a_{ki}$。例如 $g(x_1, x_2) = x_1$ 时，$\partial g/\partial x_1 = 1$、$\partial g/\partial x_2 = 0$。

沿直线展开。

$$\begin{aligned}\varphi(x+\alpha y) &= \frac{1}{2}(x+\alpha y)^T A(x+\alpha y) - b^T(x+\alpha y)\\ &= \varphi(x) + \frac{\alpha}{2}(y^T Ax + x^T Ay) - \alpha b^T y + \frac{\alpha^2}{2} y^T Ay\\ &= \varphi(x) + \alpha(Ax-b)^T y + \frac{\alpha^2}{2} y^T Ay.\end{aligned}$$

对固定 $x, y \neq 0$，$\varphi(x+\alpha y)$ 是关于 α 的开口向上的二次函数，因为 $y^T Ay > 0$。

极小值性质。 对任意 x，令 $y = x - x^*$，由上述展开及 $Ax^* = b$ 得

$$\varphi(x) = \varphi(x^*) + \frac{1}{2}(x-x^*)^T A(x-x^*).$$

所以

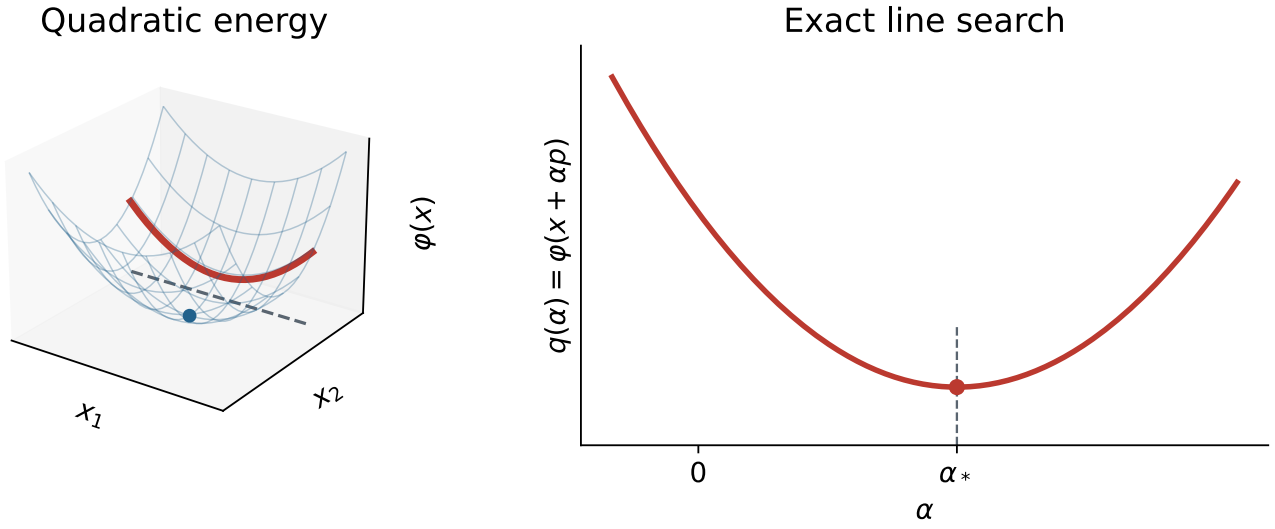
$$\varphi(x) - \varphi(x^*) = \frac{1}{2}\|x-x^*\|_A^2 \geq 0, \qquad \|v\|_A = \sqrt{v^T Av},$$

且仅在 $x = x^*$ 时取等号。

定理。 A 对称正定时，x^* 是 $Ax = b$ 的解，当且仅当

$$\varphi(x^*) = \min_{x \in \mathbb{R}^n} \varphi(x).$$

因此，求解对称正定线性方程组，等价于求一个严格凸二次函数的唯一极小点。



二次能量曲面与沿指定方向的直线搜索，红色曲线为曲面上的截线

精确线搜索与残差

（原稿第 2 页）

线搜索法产生序列 $\{x_k\}$，使 $\varphi(x_k)$ 逐步趋向最小值。已知 x_k，选择非零搜索方向 p_k，在直线 $x_k+\alpha p_k$ 上求

$$\alpha_k=\arg\min_{\alpha\in\mathbb{R}}\varphi(x_k+\alpha p_k),\qquad x_{k+1}=x_k+\alpha_k p_k.$$

利用二次展开，

$$\varphi(x_k+\alpha p_k)=\varphi(x_k)+\alpha(Ax_k-b)^Tp_k+\frac{\alpha^2}{2}p_k^TAp_k.$$

对 α 求导并置零，得

$$\boxed{\alpha_k=\frac{(b-Ax_k)^Tp_k}{p_k^TAp_k}}.$$

定义残差

$$r_k=b-Ax_k=A(x^*-x_k),$$

则

$$\alpha_k=\frac{r_k^Tp_k}{p_k^TAp_k},\qquad \varphi(x_{k+1})=\varphi(x_k)-\frac{(r_k^Tp_k)^2}{2p_k^TAp_k}.$$

残差递推为

$$r_{k+1}=b-A(x_k+\alpha_kp_k)=r_k-\alpha_kAp_k.$$

精确线搜索还给出正交性质

$$p_k^Tr_{k+1}=p_k^Tr_k-\alpha_kp_k^TAp_k=0.$$

即新残差与刚刚使用的搜索方向正交。

最速下降法

（原稿第 3 – 4 页）

最速下降法（Steepest Descent，SD）在每一步取负梯度方向。

$$-\nabla\varphi(x_k)=b-Ax_k=r_k.$$

若采用单位方向 $p_k=r_k/\|r_k\|_2$，则相应最优步长为

$$\alpha_k=\frac{r_k^Tr_k}{r_k^TAr_k}\,\|r_k\|_2.$$

方向不必归一化。直接取 $p_k = r_k$，即可写成

$$\boxed{\alpha_k = \frac{r_k^T r_k}{r_k^T A r_k}, \qquad x_{k+1} = x_k + \alpha_k r_k}.$$

SD 基本算法

选择 $x_0 \in \mathbb{R}^n$、容差 $\varepsilon > 0$ 和最大迭代次数 $N_{\max}$，计算 $r_0 = b - A x_0$。对 $k = 0, 1, \dots, N_{\max} - 1$：

1. 若 $\|r_k\|_2 \le \varepsilon$，则停止。
2. 计算 $\alpha_k = (r_k^T r_k) / (r_k^T A r_k)$。
3. 更新 $x_{k+1} = x_k + \alpha_k r_k$。
4. 更新 $r_{k+1} = b - A x_{k+1}$，或使用递推 $r_{k+1} = r_k - \alpha_k A r_k$。

【校正】原稿以 $\mathrm{err} = 1$ 起步，末尾先增加 k 再引用残差，容易导致停止量与当前解不一致。这里明确在每步开头检查当前残差，且在初值已为解时直接停止，避免 $0/0$。

多项式估计引理

设 A 的特征值为 $0 < \lambda_1 \le \cdots \le \lambda_n$，$P(t)$ 为实系数多项式，则

$$\|P(A)x\|_A \le \max_{1 \le i \le n} |P(\lambda_i)| \, \|x\|_A, \qquad x \in \mathbb{R}^n.$$

证明。 取 A 的标准正交特征向量组 $e_1, \dots, e_n$，写成 $x = \sum_i \beta_i e_i$。因为 $A e_i = \lambda_i e_i$，有

$$\begin{aligned} \|P(A)x\|_A^2 &= x^T P(A)^T A P(A) x \\ &= \sum_{i} \lambda_i \beta_i^2 P(\lambda_i)^2 \\ &\le \max_i |P(\lambda_i)|^2 \sum_i \lambda_i \beta_i^2 \\ &= \max_i |P(\lambda_i)|^2 \|x\|_A^2 . \end{aligned}$$

开平方即得结论。这里 $P(A)^T = P(A)$，因为 A 对称且多项式系数为实数。

SD 收敛估计

最速下降法产生的迭代满足

$$\boxed{\|x_k - x^*\|_A \le \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^{k} \|x_0 - x^*\|_A}.$$

证明。 由能量误差恒等式以及精确线搜索最小化性质，对任意实数 α，

$$\begin{aligned} \|x_k - x^*\|_A &\le \|x_{k-1} + \alpha r_{k-1} - x^*\|_A \\ &= \|(I - \alpha A)(x_{k-1} - x^*)\|_A \\ &\le \max_i |1 - \alpha \lambda_i| \, \|x_{k-1} - x^*\|_A . \end{aligned}$$

利用引理的最后一步取 $P(t)=1-\alpha t$。因此

$$\|x_k-x^*\|_A \le \min_{\alpha\in\mathbb{R}} \max_i |1-\alpha\lambda_i|\,\|x_{k-1}-x^*\|_A.$$

由于 $|1-\alpha\lambda|$ 对 λ 是凸函数，在 $[\lambda_1,\lambda_n]$ 上最大值由端点取得：

$$\max_i |1-\alpha\lambda_i| = \max\{|1-\alpha\lambda_1|, |1-\alpha\lambda_n|\}.$$

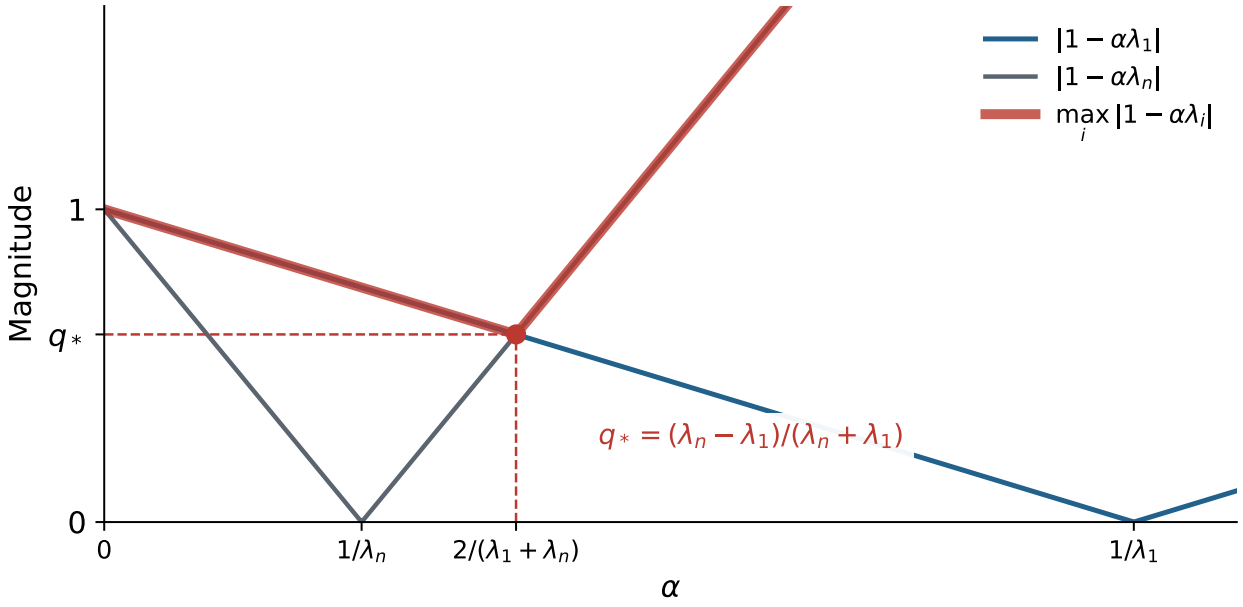
最优平衡条件为

$$1-\alpha\lambda_1 = -(1-\alpha\lambda_n),$$

故

$$\alpha = \frac{2}{\lambda_1+\lambda_n}, \qquad \min_\alpha \max_i |1-\alpha\lambda_i| = \frac{\lambda_n-\lambda_1}{\lambda_n+\lambda_1}.$$

重复应用单步估计即得结论。



两端特征值对应绝对值函数的上包络，最小点位于二者平衡处

【补全】上述 $2/(\lambda_1+\lambda_n)$ 是用于证明统一最坏情形界的常数步长，并不意味着 SD 实际每一步的精确线搜索步长都相同。

共轭梯度法的构造

（原稿第 5 – 6 页）

共轭梯度法（Conjugate Gradient，CG）通过改变搜索方向提高 SD 的收敛速度。回顾线搜索的迭代展开：

$$x_{k+1} = x_k + \alpha_k p_k = x_0 + \sum_{i=0}^{k} \alpha_i p_i.$$

若先取 $x_0 = 0$，则

$$x_{k+1} \in \operatorname{span}\{p_0, \dots, p_k\}, \qquad x_k \in \operatorname{span}\{p_0, \dots, p_{k-1}\}.$$

关于张成空间的例子

原稿举例：

$$p_0 = (1,0,0,0)^T, \quad p_1 = (1,1,0,0)^T, \quad p_2 = (1,1,1,0)^T.$$

则 $x_3 = (1,2,4,0)^T$ 属于 $\operatorname{span}\{p_0, p_1, p_2\}$，例如

$$x_3 = -p_0 - 2p_1 + 4p_2.$$

进一步取 $p_3 = (2,3,1,0)^T$，$x_4 = (4,3,1,0)^T$ 仍属于 $\operatorname{span}\{p_0, p_1, p_2, p_3\}$。

【补全】这个例子说明线性组合与张成空间，但 p_3 并未增加维数，因为四个向量的第四分量都为零。CG 中非零共轭方向线性无关，才可保证迭代空间逐步增维。

为何要求共轭

考虑 $x = y + \alpha p_k$，其中 $y \in \operatorname{span}\{p_0, \dots, p_{k-1}\}$。有

$$\begin{aligned}\varphi(y + \alpha p_k) &= \varphi(y) + \alpha (Ay - b)^T p_k + \frac{\alpha^2}{2} p_k^T A p_k \\ &= \varphi(y) + \alpha (Ay)^T p_k + \frac{\alpha^2}{2} p_k^T A p_k - \alpha b^T p_k.\end{aligned}$$

在扩大的空间中最小化，需要同时处理 y 与 α。困难来自耦合项 $\alpha (Ay)^T p_k$。若构造 p_k，使

$$(Ay)^T p_k = 0, \qquad \forall y \in \operatorname{span}\{p_0, \dots, p_{k-1}\},$$

则两个变量的最小化可以分开进行。

写 $y = \sum_{i=0}^{k-1} \beta_i p_i$，则

$$(Ay)^T p_k = y^T A p_k = \sum_{i=0}^{k-1} \beta_i p_i^T A p_k.$$

因此上述条件等价于

$$p_i^T A p_k = 0, \qquad i = 0, \dots, k-1.$$

定义。 若一组非零向量 $p_0, \dots, p_m$ 满足

$$p_i^T A p_j = 0, \qquad i \neq j,$$

则称它们为 A **共轭向量组**，也称在 A 内积下正交。

当 $A = I$ 时，A 共轭就是普通正交。若 $A = G^T G$，则

$$p_i^T A p_j = (G p_i)^T (G p_j),$$

所以 p_i, p_j 的 A 共轭等价于变换后向量 $G p_i, G p_j$ 的欧氏正交。

递推构造搜索方向

因为精确线搜索给出 $p_{k-1}^T r_k = 0$，设

$$p_k = r_k + \beta_{k-1} p_{k-1}.$$

要求 $p_{k-1}^T A p_k = 0$，即

$$p_{k-1}^T A(r_k + \beta_{k-1} p_{k-1}) = 0,$$

得到

$$\boxed{\beta_{k-1} = -\frac{r_k^T A p_{k-1}}{p_{k-1}^T A p_{k-1}}}.$$

以 $p_0 = r_0$ 起步，由此构造的 CG 序列在精确算术中满足

$$r_i^T r_j = 0 \quad (i \neq j), \qquad p_i^T A p_j = 0 \quad (i \neq j).$$

【补全】这些性质依赖整个 CG 递推与对称正定性；不能只凭单个相邻正交条件就断言任意历史向量均正交。

CG 算法与系数的等价公式

（原稿第 7 – 8 页）

在 $x_0 = 0$ 的推导中，x_k 位于旧方向张成的空间，故 $x_k^T A p_k = 0$，此时可写

$$\alpha_k = \frac{b^T p_k}{p_k^T A p_k}.$$

一般初值下，应使用精确线搜索公式

$$\alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}.$$

由 $p_k = r_k + \beta_{k-1} p_{k-1}$ 与 $r_k^T p_{k-1} = 0$，有

$$r_k^T p_k = r_k^T r_k,$$

从而得到通用的 CG 步长

$$\boxed{\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}}.$$

【校正】$b^T p_k$ 形式不可无条件用于任意非零初值；用 $r_k^T r_k$ 的算法式不受这一限制。

由残差方程

$$r_{k+1} = r_k - \alpha_k A p_k, \qquad A p_k = \frac{r_k - r_{k+1}}{\alpha_k},$$

以及 $r_{k+1}^T r_k = 0$、$p_k^T r_{k+1} = 0$，有

$$\begin{aligned}
\beta_k &= -\frac{r_{k+1}^T A p_k}{p_k^T A p_k} \\
&= -\frac{r_{k+1}^T (r_k - r_{k+1})}{p_k^T (r_k - r_{k+1})} \\
&= \frac{r_{k+1}^T r_{k+1}}{p_k^T r_k} \\
&= \boxed{\frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}}.
\end{aligned}$$

CG 算法流程

给定 $x_0 \in \mathbb{R}^n$，计算

$$r_0 = b - A x_0, \qquad p_0 = r_0.$$

若 $\|r_0\|_2 \le \varepsilon$，直接停止。否则，对 $k = 0, 1, \dots, N_{\max} - 1$ 依次执行：

$$\begin{aligned}
q_k &= A p_k, \\
\alpha_k &= \frac{r_k^T r_k}{p_k^T q_k}, \\
x_{k+1} &= x_k + \alpha_k p_k, \\
r_{k+1} &= r_k - \alpha_k q_k.
\end{aligned}$$

若 $\|r_{k+1}\|_2 \le \varepsilon$，停止并输出 x_{k+1}；否则计算

$$\beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}, \qquad p_{k+1} = r_{k+1} + \beta_k p_k.$$

【校正】原稿流程中 err 未在循环中明确更新；这里补上停止判断。缓存 $q_k = A p_k$ 可避免在步长与残差更新中重复计算矩阵向量乘积。

CG 的子空间最优性与收敛速度

（原稿第 8 页）

在 $x_0 = 0$ 的记号下，定义

$$\Omega_k = \operatorname{span}\{p_0, p_1, \dots, p_k\}.$$

CG 的各步满足

$$\begin{aligned}
x_1 &= \arg\min_{x \in \Omega_0} \varphi(x), \\
x_2 &= \arg\min_{x \in \Omega_1} \varphi(x), \\
&\vdots \\
x_n &= \arg\min_{x \in \Omega_{n-1}} \varphi(x).
\end{aligned}$$

在未提前收敛时，共轭方向线性无关，故 $\dim \Omega_k = k+1$，且

$$\Omega_0 \subset \Omega_1 \subset \cdots \subset \Omega_{n-1} = \mathbb{R}^n.$$

因此在**精确算术**中，CG 至多 n 步得到 $x_n = x^*$；也可能更早得到精确解。

【补全】任意初值 x_0 时，把上述线性空间改为仿射空间

$$x_0 + \operatorname{span}\{p_0, \dots, p_k\}.$$

有限精度计算中的舍入误差会破坏严格正交性，因此实际不保证恰在 n 步结束。

误差估计。 对称正定矩阵的二范数条件数为

$$\kappa_2(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\lambda_n}{\lambda_1}.$$

CG 迭代满足

$$\boxed{\|x_k - x^*\|_A \le 2\left(\frac{\sqrt{\kappa_2(A)}-1}{\sqrt{\kappa_2(A)}+1}\right)^k \|x_0 - x^*\|_A}.$$

原稿以此与 SD 的估计比较。两种收敛因子分别可写为

$$q_{CG} = \frac{1-\sqrt{\lambda_1/\lambda_n}}{1+\sqrt{\lambda_1/\lambda_n}}, \qquad q_{SD} = \frac{1-\lambda_1/\lambda_n}{1+\lambda_1/\lambda_n}.$$

当条件数较大时，CG 的理论收敛因子明显更有利。

预条件共轭梯度法的思想

（原稿第 9 页）

CG 的收敛速度受系数矩阵的条件数影响。预处理的目标，是把原方程 $Ax = b$ 变为等价系统，使新矩阵的条件数显著降低。

【补全】为保留 CG 所需的对称正定结构，选取对称正定预条件矩阵 M，令

$$\tilde{A} = M^{-1/2} A M^{-1/2}, \qquad \tilde{b} = M^{-1/2} b, \qquad y = M^{1/2} x.$$

则原方程等价于

$$\tilde{A} y = \tilde{b}.$$

期望 $\kappa_2(\tilde{A}) \ll \kappa_2(A)$，同时与 M 有关的求解代价较低。原稿本页仅给出“降低条件数”的思路，未展开预条件 CG 的具体算法。

最小二乘法

1 最小二乘问题与法方程

（原稿第 1 – 2 页）

1.1 从非方阵方程组出发

此前讨论的线性方程组 $Ax = b$ 中，$A \in \mathbb{R}^{n\times n}$。若 $A \in \mathbb{R}^{m\times n}$ 且 $m \neq n$，方程组可能没有精确解。例如

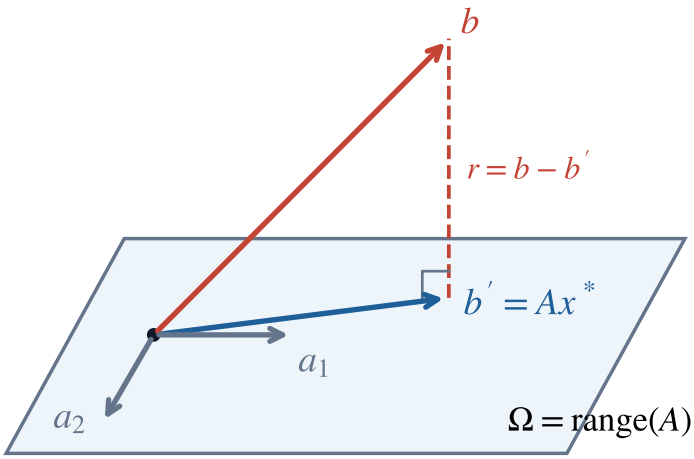
$$\begin{cases} x_1 + x_2 = 2, \\ x_1 + 2x_2 = 3, \\ x_1 - x_2 = -1. \end{cases}$$

记

$$a_1 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \qquad a_2 = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}, \qquad b = \begin{bmatrix} 2 \\ 3 \\ -1 \end{bmatrix}.$$

则问题是寻找 x_1, x_2，使 $x_1 a_1 + x_2 a_2$ 尽量接近 b。所有线性组合构成子空间 $\Omega = \operatorname{span}\{a_1, a_2\}$；我们求

$$\min_{x_1, x_2} \| b - x_1 a_1 - x_2 a_2 \|_2^2.$$



最小二乘的正交投影：b 在列空间上的投影为 b′ ，残差与列空间垂直

相容性。 如果存在 x^* 使 $Ax^* = b$，则称方程组相容。

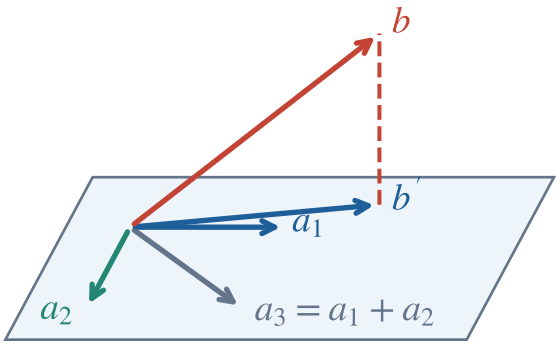
最小二乘解。 若 x^* 使 $\|b - Ax\|_2^2$ 达到最小，则称 x^* 为 $Ax = b$ 的最小二乘解。

存在性与唯一性定理。 对任意 A 和 b，最小二乘解总存在；解唯一的充要条件为

$$\operatorname{null}(A) = \{0\},$$

即 A 的列向量线性无关，或 $\mathrm{rank}(A)=n$。若存在非零 $z\in\mathrm{null}(A)$，则 $A(x^*+z)=Ax^*$，因此最小二乘解不唯一。即使坐标 x^* 不唯一，拟合向量 Ax^* 仍是唯一的正交投影。

$$A(x+z)=Ax \quad (z\in\mathrm{null}(A))$$



列向量相关时，投影仍唯一，但投影的系数表示可不唯一

1.2 法方程的微分推导

定义

$$g(x)=\|b-Ax\|_2^2=\sum_{i=1}^{m}\left(b_i-\sum_{j=1}^{n}a_{ij}x_j\right)^2.$$

对 x_k 求偏导并令其为零：

$$\frac{\partial g}{\partial x_k}=2\sum_{i=1}^{m}a_{ik}\left(\sum_{j=1}^{n}a_{ij}x_j-b_i\right)=0,\qquad k=1,\dots,n.$$

因此

$$\sum_{i=1}^{m}\sum_{j=1}^{n}a_{ik}a_{ij}x_j=\sum_{i=1}^{m}a_{ik}b_i.$$

令 $C=A^T$，则 $c_{ki}=a_{ik}$。交换求和次序得

$$\sum_{j=1}^{n}\left(\sum_{i=1}^{m}c_{ki}a_{ij}\right)x_j=\sum_{i=1}^{m}c_{ki}b_i.$$

这正是 $(CA)x=Cb$，即**法方程**

$$\boxed{A^TAx=A^Tb}.$$

【补全】由于 g 是凸二次函数，上式不仅是必要条件，也是最小二乘解的充分条件。若 A 列满秩，则 A^TA 对称正定，法方程有唯一解。

1.3 几何推导

（原稿第 3 页）

设 $b = b' + b_\perp$，其中 $b' \in \Omega = \mathrm{range}(A)$，$b_\perp \perp \Omega$。对于任意 $Ax \in \Omega$，

$$\|b - Ax\|_2^2 = \|b_\perp\|_2^2 + \|b' - Ax\|_2^2.$$

所以最佳拟合向量满足 $Ax^* = b'$。以 $A = [a_1, a_2]$ 为例，有

$$(b - a_1x_1 - a_2x_2)^T a_1 = 0, \qquad (b - a_1x_1 - a_2x_2)^T a_2 = 0.$$

即

$$\begin{bmatrix} a_1^T a_1 & a_1^T a_2 \\ a_2^T a_1 & a_2^T a_2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} a_1^T b \\ a_2^T b \end{bmatrix}.$$

一般地，残差 $r = b - Ax^*$ 与 A 的每个列向量正交：

$$A^T(b - Ax^*) = 0 \quad \Longleftrightarrow \quad A^T A x^* = A^T b.$$

2 数据拟合的最小二乘模型

（原稿第 3 – 4 页）

向量逼近 $b \approx \sum_j x_j a_j$ 对应于函数拟合 $y(t) \approx \sum_j c_j f_j(t)$。给定数据 (t_i, y_i) 和基函数 $f_1, \dots, f_n$，令

$$g(t) = \sum_{j=1}^{n} c_j f_j(t), \qquad F_{ij} = f_j(t_i).$$

则系数由

$$\min_{c} \sum_{i=1}^{m} \left(y_i - \sum_{j=1}^{n} c_j f_j(t_i) \right)^2 = \min_{c} \|y - Fc\|_2^2$$

确定，法方程为 $F^T F c = F^T y$。

二次多项式拟合例题

选择 $g(t) = a + bt + ct^2$ 拟合下列数据。

i	1	2	3	4	5
t_i	0	1	2	3	4
y_i	4	7	12	39	54

【辨读说明】原稿第 4 页最后两个观测值按字形识读为 $39, 54$；图形只用于解释拟合，不作为反推观测值的依据。

若要求 $y_i = a + bt_i + ct_i^2$ 对所有 i 同时成立，通常得到不相容方程组。取

$$f_1(t) = 1, \quad f_2(t) = t, \quad f_3(t) = t^2,$$

$$y = \begin{bmatrix} 4 \\ 7 \\ 12 \\ 39 \\ 54 \end{bmatrix}, \quad u = \begin{bmatrix} a \\ b \\ c \end{bmatrix}, \quad F = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \\ 1 & 4 & 16 \end{bmatrix}.$$

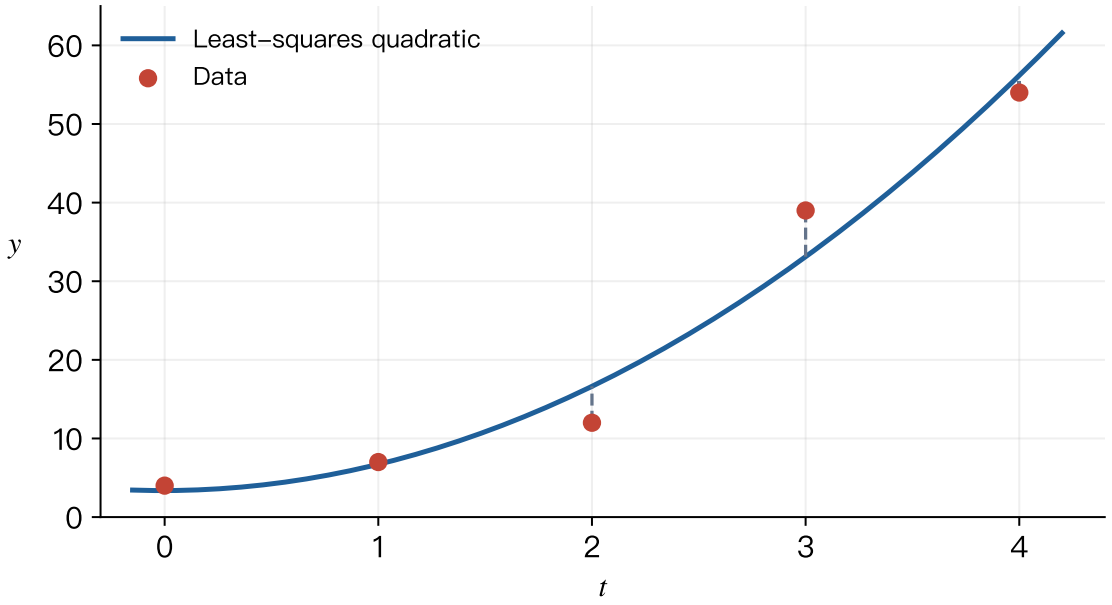
于是求解 $F^T F u = F^T y$。

【补全】代入上述识读数据，法方程为

$$\begin{bmatrix} 5 & 10 & 30 \\ 10 & 30 & 100 \\ 30 & 100 & 354 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} 116 \\ 364 \\ 1270 \end{bmatrix},$$

解为

$$a = \frac{118}{35}, \qquad b = \frac{2}{35}, \qquad c = \frac{23}{7}.$$



二次最小二乘拟合：散点为观测值，曲线为拟合多项式，虚线为残差

原稿旁注还列出指数模型 ae^{-bt}。这提醒我们可以选用不同的拟合函数；当参数非线性进入模型时，问题一般不再是上述线性最小二乘问题。【补全】例如 b 也未知时，ae^{-bt} 对参数 (a, b) 非线性。

3 初等变换与正交变换

（原稿第 5 – 8 页）

3.1 初等变换矩阵和 Gauss 变换

原稿将一类初等变换写成

$$E(u, v, \sigma) = I - \sigma u v^T.$$

Gauss 变换取 $\sigma = -1$、$v = e_j$，并令

$$u^T = (0, \dots, 0, l_{j+1,j}, l_{j+2,j}, \dots, l_{nj}),$$

其中前 j 个分量为零，则

$$L_j = I + u e_j^T.$$

该矩阵除第 j 列对角线以下的元素为 $l_{i,j}$ 外，其余部分与单位阵相同。乘以向量或矩阵时，它把第 j 行的倍数加到后续各行。【补全】若 $l_{i,j}$ 定义为通常的正消元乘子，实际消元矩阵写作 $I - u e_j^T$；此处沿用原稿的加号定义。

3.2 Householder 变换

给定非零向量 v，取 $u = v$、$\sigma = 2/(v^T v)$，定义

$$H = I - \frac{2 v v^T}{v^T v} = I - 2 w w^T, \qquad w = \frac{v}{\|v\|_2}.$$

v 称为 Householder 向量，w 是其单位化形式。

基本性质。

$$H^T = H, \qquad H^T H = I, \qquad H^2 = I, \qquad H^{-1} = H.$$

H 的特征值为 -1 和 1，其中 -1 对应方向 w，1 对应 $w^{\perp}$；当维数为 n 时，它们的重数分别为 1 和 $n-1$，所以 $\det(H) = -1$。

证明对称性只需转置；正交性由 $w^T w = 1$ 得

$$H^T H = (I - 2 w w^T)^2 = I - 4 w w^T + 4 w (w^T w) w^T = I.$$

3.3 Householder 变换的反射意义

（原稿第 5 – 6 页）

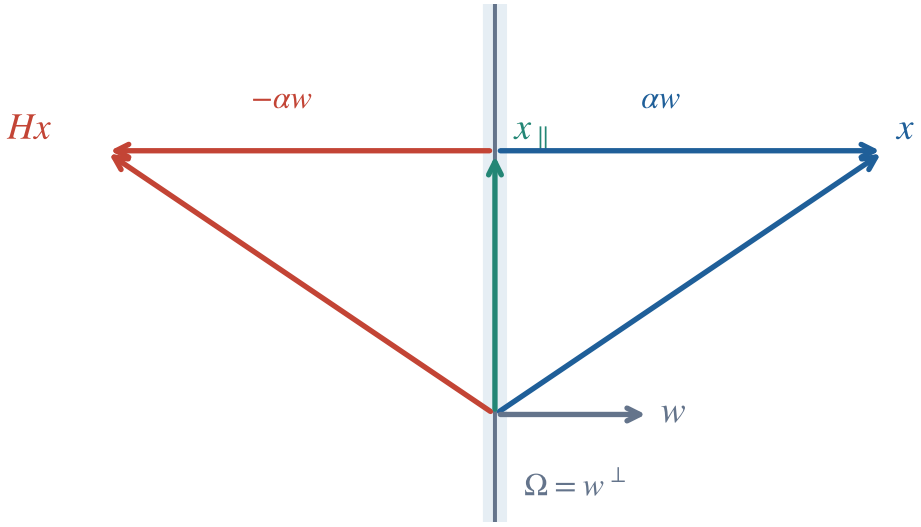
把 x 分解为

$$x = x_{\parallel} + \alpha w, \qquad x_{\parallel} \perp w.$$

则

$$H x = (I - 2 w w^T)(x_{\parallel} + \alpha w) = x_{\parallel} - \alpha w.$$

因此 x 与 Hx 关于超平面 $\Omega = w^{\perp}$ 镜面对称。原稿采用 $x = \beta u + \alpha w$、$u \perp w$ 的记号，得到同一结论 $Hx = \beta u - \alpha w$。



Householder 反射的二维截面：平行于镜面的分量不变，法向分量反号

由几何意义直接得到特征向量：若 $p \parallel w$，则 $Hp = -p$；若 $p^T w = 0$，则 $Hp = p$。方程 $w^T p = 0$ 是 n 个未知量中的一个独立线性约束，其解空间维数为 $n - 1$。

3.4 把向量变换到指定方向

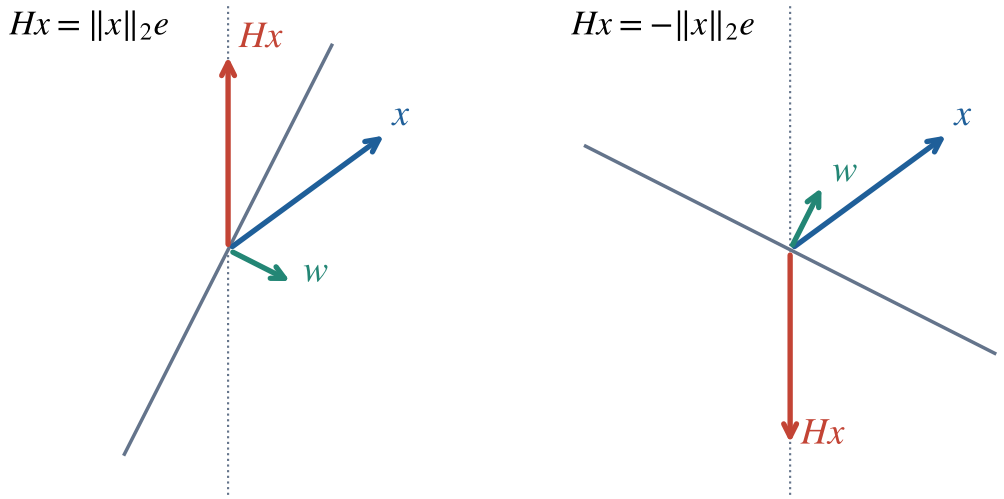
给定 $x \in \mathbb{R}^n$ 和单位向量 e，可以使 $Hx = \|x\|_2 e$ 或 $Hx = -\|x\|_2 e$。

当相应分母非零时，分别取

$$w_- = \frac{x - \|x\|_2 e}{\|x - \|x\|_2 e\|_2}, \qquad H_- = I - 2 w_- w_-^T,$$

$$w_+ = \frac{x + \|x\|_2 e}{\|x + \|x\|_2 e\|_2}, \qquad H_+ = I - 2 w_+ w_+^T.$$

于是 $H_- x = \|x\|_2 e$、$H_+ x = -\|x\|_2 e$。



将同一向量反射到指定轴的正向或反向，两个镜面分别对应两种符号选择

【补全】若 $x = 0$，可直接取恒等变换；若候选 Householder 向量为零，改用另一符号，或在已经达到目标时跳过变换。数值实现通常选择避免相近数相减的符号。

3.5 Givens 变换

（原稿第 6 – 8 页）

e_i 表示第 i 个坐标单位向量，$e_i e_j^T$ 只有第 (i,j) 个元素为 1。Givens 变换定义为

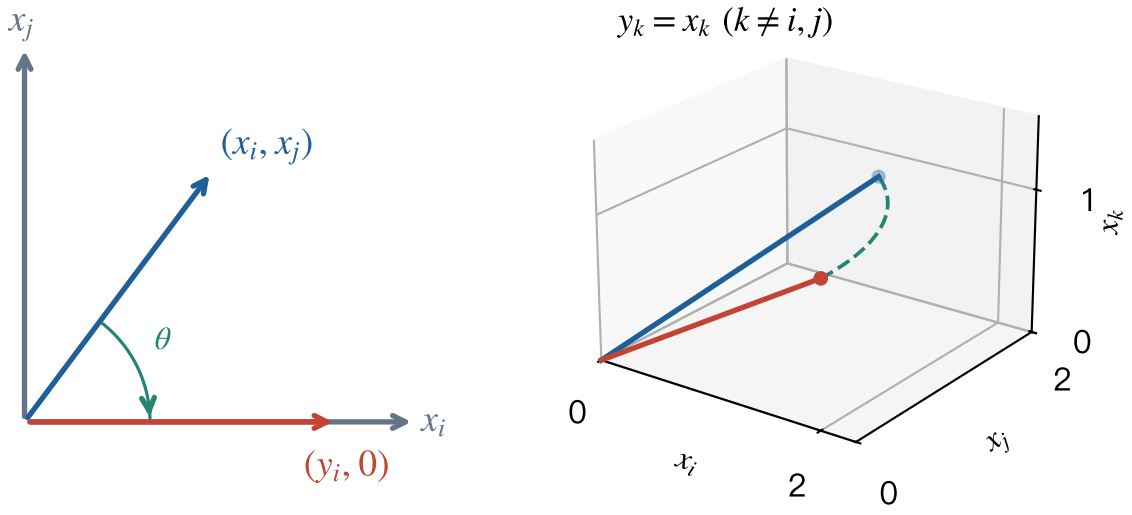
$$G = I + (\cos\theta - 1)(e_i e_i^T + e_j e_j^T) + \sin\theta(e_i e_j^T - e_j e_i^T).$$

除第 i, j 行、列的交叉部分外，G 与单位阵相同；对应的 2×2 块为

$$\begin{bmatrix} c & s \\ -s & c \end{bmatrix}, \qquad c = \cos\theta, \quad s = \sin\theta.$$

对于 $y = Gx$，

$$y_i = cx_i + sx_j, \qquad y_j = -sx_i + cx_j, \qquad y_k = x_k \quad (k \neq i, j).$$



Givens 旋转只改变所选两个坐标：左图为坐标平面内旋转，右图示意第三坐标保持不变

【校正】按本节的矩阵符号约定，在横轴为第 i 坐标、纵轴为第 j 坐标的通常坐标系中，正 θ 对应顺时针旋转；原稿小图的箭头方向与此约定不完全一致，重绘图按公式统一。

若要消去 x_j，在 $(x_i, x_j) \neq (0,0)$ 时取

$$c = \frac{x_i}{\sqrt{x_i^2 + x_j^2}}, \qquad s = \frac{x_j}{\sqrt{x_i^2 + x_j^2}},$$

便得 $y_i = \sqrt{x_i^2 + x_j^2}$、$y_j = 0$。两者均为零时可取 $c = 1, s = 0$。

Householder 与 Givens 都是正交变换，因此保持欧氏长度。例如

$$\|Hx\|_2^2 = x^T H^T H x = x^T x = \|x\|_2^2.$$

Householder 可一次将一个向量的多个分量化为零；一次 Givens 旋转通常消去其中一个指定分量。

4 QR 分解与 Gram–Schmidt 正交化

（原稿第 8 – 9 页）

4.1 简化 QR 分解

给定 $A \in \mathbb{R}^{m \times n}$，$m \geq n$。寻找列正交的 $Q \in \mathbb{R}^{m \times n}$ 和上三角矩阵 $R \in \mathbb{R}^{n \times n}$，使

$$A = QR, \qquad Q^T Q = I_n.$$

若 A 列满秩，并要求 $r_{ii} > 0$，则此简化 QR 分解唯一。

【校正】原稿这一处混用实数域、复数域以及 $\mathbb{C}^n$、$\mathbb{C}^m$。这里按实数情形统一：每列 $q_i \in \mathbb{R}^m$。复数情形把转置改为共轭转置 Q^*，相应要求 $Q^* Q = I_n$。

设 $A=[a_1,\dots,a_n]$、$Q=[q_1,\dots,q_n]$，则

$$a_i=\sum_{k=1}^{i} q_k r_{ki},\qquad q_j^T q_k=\delta_{jk}.$$

两边左乘 q_j^T 得

$$r_{ji}=q_j^T a_i\qquad (j\le i).$$

4.2 Gram—Schmidt 递推公式

第 1 步：

$$r_{11}=\|a_1\|_2,\qquad q_1=\frac{a_1}{r_{11}}.$$

第 2 步：

$$r_{12}=q_1^T a_2,\quad r_{22}=\|a_2-r_{12}q_1\|_2,\quad q_2=\frac{a_2-r_{12}q_1}{r_{22}}.$$

第 3 步：

$$r_{13}=q_1^T a_3,\quad r_{23}=q_2^T a_3,\quad r_{33}=\|a_3-r_{13}q_1-r_{23}q_2\|_2,$$

$$q_3=\frac{a_3-r_{13}q_1-r_{23}q_2}{r_{33}}.$$

【校正】原稿第 9 页第 3 步个别下标写成 a_2，按该步实际正交化对象统一为 a_3。

第 i 步：

$$r_{ji}=q_j^T a_i\quad (j=1,\dots,i-1),\qquad v_i=a_i-\sum_{j=1}^{i-1} r_{ji}q_j,$$

$$r_{ii}=\|v_i\|_2,\qquad q_i=v_i/r_{ii}.$$

4.3 经典 GS 与修正 GS 的计算流程

经典 Gram – Schmidt（CGS）。对 $i=1,\dots,n$，先令 $v=a_i$；对 $j=1,\dots,i-1$ 依次计算

$$r_{ji}=q_j^T a_i,\qquad v\leftarrow v-r_{ji}q_j;$$

内循环结束后取 $r_{ii}=\|v\|_2$、$q_i=v/r_{ii}$。其中每次投影系数都由原始列 a_i 计算。

修正 Gram – Schmidt（MGS）。仍先令 $v=a_i$，但内循环改成

$$r_{ji}=q_j^T v,\qquad v\leftarrow v-r_{ji}q_j.$$

即每次投影使用已更新的剩余向量。最后同样取 $r_{ii}=\|v\|_2$、$q_i=v/r_{ii}$。

【补全】两种算法在精确算术下等价，但浮点运算中 MGS 通常更能保持正交性。上述无列交换的流程假设 A 列满秩；若 $r_{ii}=0$，不能继续直接相除。

5 用 Householder 变换计算 QR 分解

（原稿第 10 – 13 页）

5.1 逐列消去的构造

以 $A \in \mathbb{R}^{5\times 4}$ 为例。令 $A_0 = A$。首先构造 H_1 使第一列变成 $\|a_1\|_2 e_1$（也可取负号），则

$$A_1 = H_1 A = \begin{bmatrix} * & * & * & * \\ 0 & * & * & * \\ 0 & * & * & * \\ 0 & * & * & * \\ 0 & * & * & * \end{bmatrix} = \begin{bmatrix} r_{11} & * \\ 0 & \widetilde{A}_1 \end{bmatrix}, \qquad \widetilde{A}_1 \in \mathbb{R}^{4\times 3}.$$

对 $\widetilde{A}_1$ 的第一列构造四维反射 $\widetilde{H}_2$，嵌入

$$H_2 = \begin{bmatrix} 1 & 0 \\ 0 & \widetilde{H}_2 \end{bmatrix}, \qquad A_2 = H_2 A_1 = \begin{bmatrix} * & * & * & * \\ 0 & * & * & * \\ 0 & 0 & * & * \\ 0 & 0 & * & * \\ 0 & 0 & * & * \end{bmatrix}.$$

这一步不改变已处理的第一列。若 $\widetilde{H}_2 = I - 2\widetilde{w}_2\widetilde{w}_2^T$，把 $\widetilde{w}_2$ 顶部补一个零，记为 w_2，则 $H_2 = I - 2w_2w_2^T$。

第三步嵌入 $H_3 = \mathrm{diag}(I_2, \widetilde{H}_3)$，得

$$A_3 = H_3 A_2 = \begin{bmatrix} * & * & * & * \\ 0 & * & * & * \\ 0 & 0 & * & * \\ 0 & 0 & 0 & * \\ 0 & 0 & 0 & * \end{bmatrix}.$$

一般地，第 k 步取

$$H_k = \begin{bmatrix} I_{k-1} & 0 \\ 0 & \widetilde{H}_k \end{bmatrix}, \qquad \widetilde{H}_k \in \mathbb{R}^{(m-k+1)\times(m-k+1)},$$

使 $A_k = H_k A_{k-1}$ 的第 k 列对角线以下全部为零。若 $m = n$，最后一次必要的消元是第 $n-1$ 步；若 $m > n$，通常需要第 n 步。

5.2 从消元结果得到完整与简化 QR

记所需变换次数为 s，则

$$A_s = H_s H_{s-1} \cdots H_1 A = \begin{bmatrix} R_1 \\ 0 \end{bmatrix}.$$

由于 $H_i^{-1} = H_i^T = H_i$，

$$A = H_1 H_2 \cdots H_s \begin{bmatrix} R_1 \\ 0 \end{bmatrix}.$$

令

$$Q_f = H_1 H_2 \cdots H_s \in \mathbb{R}^{m\times m}, \qquad R_f = \begin{bmatrix} R_1 \\ 0 \end{bmatrix} \in \mathbb{R}^{m\times n}.$$

则 $Q_f^T Q_f = I_m$，$A = Q_f R_f$ 是完整 QR 分解。原稿通过乘积中的 $H_i^T H_i = I$ 逐一消去，证明了 Q_f 的正交性。

若 $Q_f = [q_1, \ldots, q_m] = [Q_1, Q_2]$，其中 Q_1 含前 n 列，则

$$A = Q_1 R_1, \qquad Q_1 \in \mathbb{R}^{m\times n}, \quad R_1 \in \mathbb{R}^{n\times n}$$

就是简化 QR 分解。逐列写出仍为 $a_i = \sum_{j=1}^{i} q_j r_{ji}$。

5.3 不显式形成反射矩阵的实现

每一步把尾部反射写为

$$\widetilde{H}_k = I - 2 w_k w_k^T = I - \beta_k v_k v_k^T, \qquad \beta_k = \frac{2}{v_k^T v_k}.$$

v_k 可按比例归一化，使其首分量为 1；相应地重新计算 β_k。只存储 v_k 和 β_k，不存储 H_k 或 $\widetilde{H}_k$。

处理第 k 列时，先由当前子列 $A(k:m, k)$ 构造 v_k, β_k，然后更新尾部矩阵：

$$A(k:m, k:n) \leftarrow A(k:m, k:n) - \beta_k v_k \big(v_k^T A(k:m, k:n) \big).$$

可把 R_1 存在原矩阵的上三角部分，把各个 v_k 除首分量外的元素存在相应列对角线下方。这样，已知为零的位置被用于存储反射信息，首分量 1 不必重复存储。

【补全】实用构造可取 $\alpha = -\operatorname{sign}(z_1)\|z\|_2$、$v = z - \alpha e_1$，其中约定 $\operatorname{sign}(0) = 1$。若 $z = 0$，跳过反射；若某列已经达到目标，也可直接保留。此符号选择用于减少消减误差，不改变 QR 的基本思路。

6 Householder QR 例题

（原稿第 14 页）

对

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 3 & 2 \\ 2 & 0 & 1 \end{bmatrix}$$

进行 QR 分解。第一列为 $z = (1, 0, 2)^T$，取

$$v_1 = z - \|z\|_2 e_1 = \begin{bmatrix} 1 - \sqrt{5} \\ 0 \\ 2 \end{bmatrix}.$$

于是

$$H_1 = I - \frac{2 v_1 v_1^T}{v_1^T v_1} = \begin{bmatrix} 1/\sqrt{5} & 0 & 2/\sqrt{5} \\ 0 & 1 & 0 \\ 2/\sqrt{5} & 0 & -1/\sqrt{5} \end{bmatrix},$$

$$A_1 = H_1 A = \begin{bmatrix} \sqrt{5} & 2/\sqrt{5} & \sqrt{5} \\ 0 & 3 & 2 \\ 0 & 4/\sqrt{5} & \sqrt{5} \end{bmatrix}.$$

第二步对尾部向量 $z_2 = (3, 4/\sqrt{5})^T$ 构造反射。它的长度为 $\sqrt{61/5}$，取

$$v_2 = \begin{bmatrix} 3 - \sqrt{61/5} \\ 4/\sqrt{5} \end{bmatrix}, \qquad \widetilde{H}_2 = I_2 - \frac{2 v_2 v_2^T}{v_2^T v_2}, \qquad H_2 = \operatorname{diag}(1, \widetilde{H}_2).$$

原稿将 $\widetilde{H}_2$ 和 A_2 的后续元素留作计算。下面补出结果：

$$\widetilde{H}_2 = \frac{1}{\sqrt{61}} \begin{bmatrix} 3\sqrt{5} & 4 \\ 4 & -3\sqrt{5} \end{bmatrix}.$$

$$R = H_2 H_1 A = \begin{bmatrix} \sqrt{5} & 2/\sqrt{5} & \sqrt{5} \\ 0 & \sqrt{61/5} & 10\sqrt{5}/\sqrt{61} \\ 0 & 0 & -7/\sqrt{61} \end{bmatrix}.$$

$$Q = H_1 H_2 = \begin{bmatrix} 1/\sqrt{5} & 8/\sqrt{305} & -6/\sqrt{61} \\ 0 & 3\sqrt{5}/\sqrt{61} & 4/\sqrt{61} \\ 2/\sqrt{5} & -4/\sqrt{305} & 3/\sqrt{61} \end{bmatrix}.$$

【补全】上面给出的是合法的 $A = QR$。若还要求 R 对角线全部为正，应同时将 Q 的第 3 列和 R 的第 3 行乘以 -1。

7 基于 QR 分解的最小二乘法

（原稿第 15 – 16 页）

设 $A \in \mathbb{R}^{m \times n}$，$m \geq n$，且 A 列满秩。采用完整 QR 分解

$$A = Q_f R_f = [Q_1, Q_2] \begin{bmatrix} R_1 \\ 0 \end{bmatrix},$$

其中 $Q_f \in \mathbb{R}^{m \times m}$ 正交，$R_1 \in \mathbb{R}^{n \times n}$ 非奇异上三角，$Q_1 \in \mathbb{R}^{m \times n}$，$Q_2 \in \mathbb{R}^{m \times (m-n)}$。

正交变换保持长度，所以

$$\|Ax - b\|_2^2 = \|Q_f R_f x - b\|_2^2 = \|R_f x - Q_f^T b\|_2^2.$$

也可通过展开内积验证：

$$\begin{aligned} \|Q_f R_f x - b\|_2^2 &= x^T R_f^T Q_f^T Q_f R_f x - 2 x^T R_f^T Q_f^T b + b^T b \\ &= x^T R_f^T R_f x - 2 x^T R_f^T Q_f^T b + (Q_f^T b)^T (Q_f^T b). \end{aligned}$$

令

$$Q_f^T b = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix}, \qquad c_1 = Q_1^T b \in \mathbb{R}^n, \qquad c_2 = Q_2^T b \in \mathbb{R}^{m-n}.$$

则

$$\|Ax - b\|_2^2 = \|R_1 x - c_1\|_2^2 + \|c_2\|_2^2.$$

后项与 x 无关；前项的最小值为零。因此唯一的最小二乘解由

$$\boxed{R_1 x = Q_1^T b}$$

得到，最小残差平方为 $\|Q_2^T b\|_2^2$。

逐分量展开，前 n 项为

$$\sum_{k=i}^{n} r_{ik} x_k - q_i^T b, \qquad i = 1, \dots, n,$$

后 $m-n$ 项为 $-q_i^T b$。使前 n 项全部为零即得到上三角方程组

$$\begin{cases} r_{11}x_1 + r_{12}x_2 + \cdots + r_{1n}x_n = q_1^T b, \\ r_{22}x_2 + \cdots + r_{2n}x_n = q_2^T b, \\ \vdots \\ r_{nn}x_n = q_n^T b. \end{cases}$$

利用回代即可求解。

7.1 快速计算变换后的右端项

（原稿第 17 – 18 页）

无须显式形成 Q_f。若 $Q_f = H_1 H_2 \cdots H_s$，则

$$Q_f^T b = H_s H_{s-1} \cdots H_1 b.$$

令 $b^{(0)} = b$，依次计算

$$b^{(k)} = H_k b^{(k-1)}, \qquad k = 1, \dots, s.$$

由于 $H_k = \operatorname{diag}(I_{k-1}, \widetilde{H}_k)$，它不改变右端项的前 $k-1$ 个分量。把

$$b^{(k-1)} = \begin{bmatrix} d_1 \\ d_2 \end{bmatrix}, \qquad \widetilde{H}_k = I - \beta_k v_k v_k^T$$

按前 $k-1$ 个分量与剩余分量分块，则

$$b^{(k)} = \begin{bmatrix} d_1 \\ d_2 - \beta_k (v_k^T d_2) v_k \end{bmatrix}.$$

因此在计算 QR 的同时，以同一反射更新 b，最后取前 n 个分量作为上三角方程的右端项。

原稿还讨论了补全正交基时可能继续施加的 H_p：若 $p \geq n+1$，它只作用于后 $m-p+1$ 个分量，不改变前 n 项，因而不会改变最小二乘解的右端项。

【校正】完整 QR 的正交矩阵已经可由前述所需的 s 个反射相乘得到，并不必须再做到 $m-1$ 步。原稿第 17 页的额外乘积应理解为讨论正交补空间中的后续变换。

7.2 法方程与 QR 的条件数比较

（原稿第 18 页）

法方程解 $A^TAx = A^Tb$；QR 方法解 $R_1x = Q_1^Tb$。对于列满秩矩阵，在 2-范数意义下，

$$\kappa_2(A^TA) = \kappa_2(A)^2, \qquad \kappa_2(R_1) = \kappa_2(A).$$

【补全】原稿用“约等于”提示条件数的量级关系；在上述明确的 2-范数和列满秩条件下，这两式是严格相等。因此形成法方程会把条件数平方，病态问题通常更适合用正交变换方法处理。

8 秩亏矩阵的最小二乘问题

（原稿第 19 – 20 页）

设 $A \in \mathbb{R}^{m\times n}$、$\operatorname{rank}(A) = k < n$。此时 $\det(A^TA) = 0$，不能直接用 $(A^TA)^{-1}A^Tb$ 表示解。

将 b 正交分解为

$$b = b_1 + b_2, \qquad b_1 \in \operatorname{range}(A), \quad b_2 \in \operatorname{range}(A)^{\perp}.$$

$\operatorname{range}(A)$ 是各列的所有线性组合构成的空间：

$$\operatorname{range}(A) = \left\{ \sum_{j=1}^{n} \gamma_j a_j : \gamma_j \in \mathbb{R} \right\}.$$

8.1 利用列空间的正交基降维

先考虑 $m \ge n$。选取 $Q_k \in \mathbb{R}^{m\times k}$，使其列向量是 $\operatorname{range}(A)$ 的一组标准正交基。于是存在 $S \in \mathbb{R}^{k\times n}$，使

$$A = Q_k S, \qquad Q_k^TQ_k = I_k.$$

求最小二乘解等价于求 $Ax = b_1$，即

$$Q_kSx = b_1 \quad \Longleftrightarrow \quad Sx = Q_k^Tb_1 = Q_k^Tb.$$

这是 k 个独立方程、n 个未知量，解不唯一。一般的 S 未必具有前 k 列为上三角的结构，因此引入列置换。

8.2 带列置换的 QR 分解

存在置换矩阵 $P \in \mathbb{R}^{n\times n}$ 和正交矩阵 $Q \in \mathbb{R}^{m\times m}$，使

$$AP = Q \begin{bmatrix} R_{11} & R_{12} \\ 0 & 0 \end{bmatrix},$$

其中 $R_{11} \in \mathbb{R}^{k\times k}$ 是非奇异上三角矩阵，$R_{12} \in \mathbb{R}^{k\times(n-k)}$。原稿的证明思路是对列重排，把 k 个线性无关列放在前面，然后进行 QR 分解。

写 $Q = [Q_k, Q_{\perp}]$，则

$$A = Q \begin{bmatrix} R_{11} & R_{12} \\ 0 & 0 \end{bmatrix} P^T,$$

$$
\begin{aligned}
S = Q_k^T A &= [I_k, 0] \begin{bmatrix} R_{11} & R_{12} \\ 0 & 0 \end{bmatrix} P^T \\
&= [R_{11}, R_{12}] P^T .
\end{aligned}
$$

令 $y = P^T x$，并分块为 $y = (y_1^T, y_2^T)^T$，其中 $y_1 \in \mathbb{R}^k$、$y_2 \in \mathbb{R}^{n-k}$。则

$$
R_{11} y_1 + R_{12} y_2 = Q_k^T b,
$$

所以全部最小二乘解为

$$
\boxed{x = P \begin{bmatrix} R_{11}^{-1}(Q_k^T b - R_{12} y_2) \\ y_2 \end{bmatrix}, \qquad y_2 \in \mathbb{R}^{n-k} \text{ 任意.}}
$$

【校正】由 $y = P^T x$ 必须得到 $x = Py$，原稿末行中 P 与 P^T 有一次混写，这里已统一。实际计算应回代求 y_1，不必显式形成 R_{11}^{-1}。

【补全】取 $y_2 = 0$ 可得到一个基本解，但一般不是最小范数解；若还要求最小化 $\|x\|_2$，需要进一步处理自由变量。

8.3 欠定情形

原稿最后分别画出 $m < n$ 时的 $k = m$ 与 $k < m$ 两种块结构。相同的列置换与分块方法仍适用。

- 若 $k = m$，矩阵行满秩，A 的列空间为 $\mathbb{R}^m$，任意 b 都有精确解；自由变量数为 $n - m$。
- 若 $k < m$，列空间是真子空间，先投影 b，再解有 $n - k$ 个自由变量的方程组。

【补全】当 $k = 0$ 即 $A = 0$ 时，任意 x 都是最小二乘解，最小残差为 $\|b\|_2$。

9 线性方程组方法的联系

（原稿第 20 页）

原稿用总览图把本章与前面的线性方程组方法联系起来，可整理如下。

问题或结构	主要方法	对应的计算形式
非奇异方阵方程组	Gauss 消元、LU 分解	三角化后前代与回代
对称正定方阵方程组	Cholesky 分解	$A=LL^T$
三对角方程组	追赶法	利用带状结构消元
定常迭代	Jacobi、Gauss – Seidel	$x^{(k+1)}=Bx^{(k)}+g$
对称正定系统的梯度方法	最速下降、共轭梯度	最小化二次函数
不相容或非方阵系统	最小二乘法	最小化 $\|Ax-b\|_2^2$
列满秩最小二乘	法方程或 QR	$A^TAx=A^Tb$，或 $R_1x=Q_1^Tb$
秩亏最小二乘	带列置换 QR 等	投影与自由变量参数化

对于对称正定 A，求 $Ax=b$ 等价于最小化

$$\phi(x)=\frac{1}{2}x^TAx-b^Tx.$$

若 $A=LL^T$，则

$$\frac{1}{2}x^TAx=\frac{1}{2}\|L^Tx\|_2^2.$$

【补全】配方后为

$$\phi(x)=\frac{1}{2}\|L^Tx-L^{-1}b\|_2^2-\frac{1}{2}\|L^{-1}b\|_2^2,$$

这也说明二次优化与最小二乘形式的联系。

【校正与补全】原稿旁注的复杂度按通常实现明确为：稠密直接分解通常为 $O(n^3)$；三对角追赶法为 $O(n)$；稠密矩阵下进行 K 次定常迭代通常为 $O(Kn^2)$。这些量级应与矩阵结构及每次迭代的实际运算量一起理解。

非线性方程与方程组

本章对应《CM+Opt_非线性.pdf》全部 15 页。沿用原稿的教学顺序，将标量方程推广到向量方程组；原稿中的省略推导、适用条件与明显笔误在相应位置标记为【补全】或【校正】。

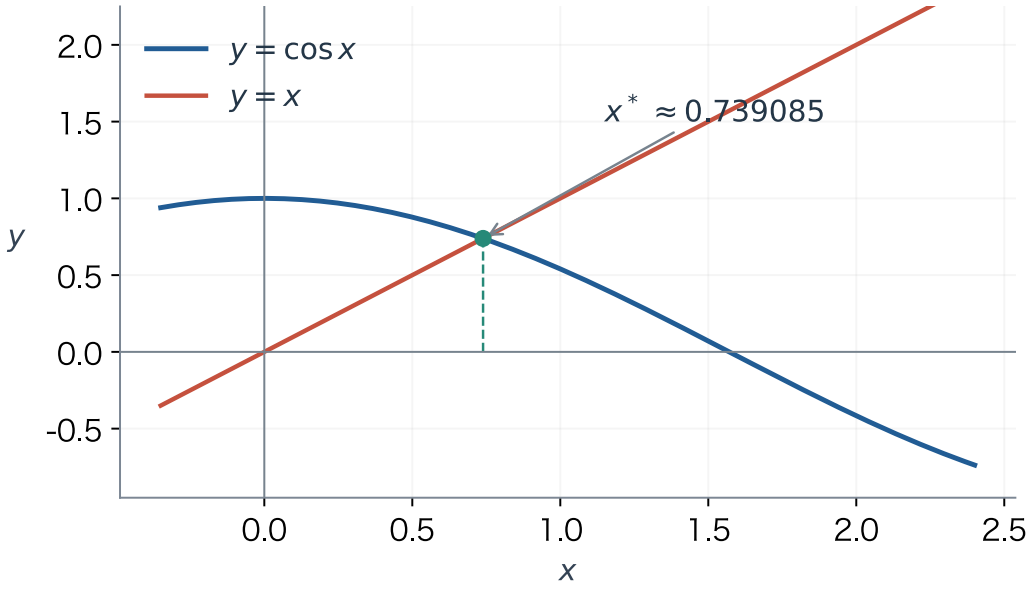
1 非线性方程与二分法

（原稿第 1 – 2 页）

非线性方程的一般形式为

$$f(x)=0.$$

例如 $x=\cos x$ 可以写为 $f(x)=x-\cos x=0$。解 x^{*} 既是 f 的零点，也是曲线 $y=\cos x$ 与直线 $y=x$ 交点的横坐标。



非线性方程 x=cos x 的图解

1.1 二分法的依据与步骤

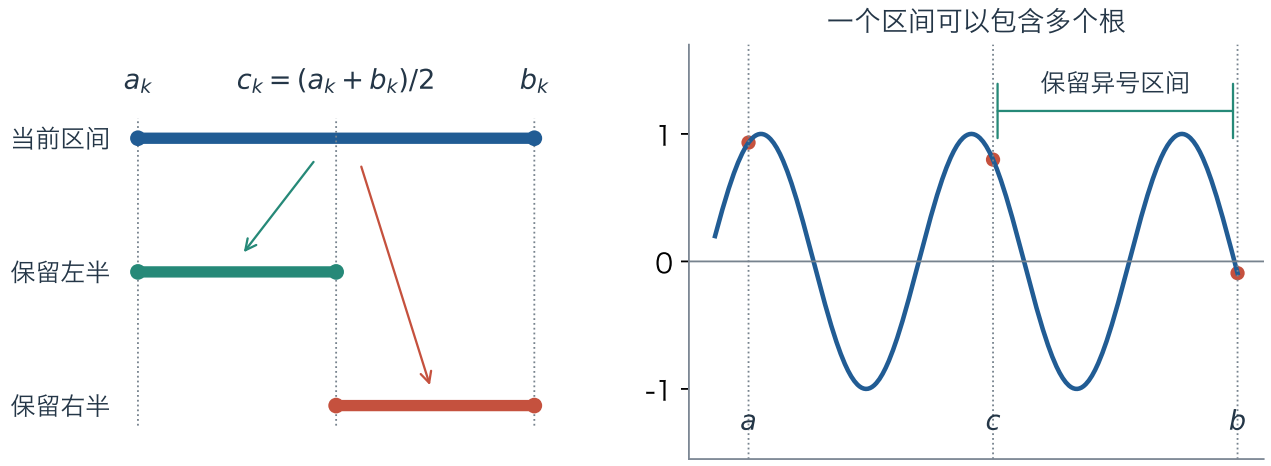
介值定理。若 $f\in C[a,b]$，且 $f(a)f(b)<0$，则至少存在一点 $x^{*}\in(a,b)$ 使 $f(x^{*})=0$。该条件保证存在性，不保证区间内根唯一。

设当前区间为 $[a_k,b_k]$，取中点

$$c_k=\frac{a_k+b_k}{2}.$$

1. 若 $f(c_k)=0$，则已求得根，停止。
2. 若 $f(a_k)f(c_k)<0$，令 $a_{k+1}=a_k$，$b_{k+1}=c_k$。
3. 否则令 $a_{k+1}=c_k$，$b_{k+1}=b_k$。

【补全】原稿仅写出两种缩区间情形，这里单列中点恰好为根的停止情形。赋值式右侧的 a_k, b_k 均指更新前的左右端点。



二分法保留异号半区间与多根区间示意

例：求 $x^3-x^2-1=0$ 在 $[0,2]$ 中的根。

次数	a	b	中点 c	$f(a)$ 符号	$f(b)$ 符号	$f(c)$ 符号
1	0	2	1	负	正	负
2	1	2	1.5	负	正	正
3	1	1.5	1.25	负	正	负

依次缩小区间即可得到更精确的近似解。

1.2 二分法误差估计

若初始区间长度为 $L=b_0-a_0$，完成 i 次二分后区间长度为 $L/2^i$。取该区间中点作为近似根，绝对误差满足

$$|c_i-x^*|\le\frac{L}{2^{i+1}}.$$

【补全】若要求误差不超过 ε，可取满足 $L/2^{i+1}\le\varepsilon$ 的非负整数 i；这也可作为停止准则。

2 不动点迭代法

（原稿第 2 页）

2.1 不动点与基本迭代策略

将 $f(x)=0$ 等价改写为

$$x = g(x),$$

其中 g 连续。满足 $x^{*}=g(x^{*})$ 的点称为 g 的不动点。给定 x_0，构造

$$x_{k+1}=g(x_k),\qquad k=0,1,2,\dots.$$

若 $x_k\to x^{*}$，由连续性可得 $x^{*}=g(x^{*})$。在线性方程组中，$A\boldsymbol{x}=\boldsymbol{b}$ 改写为 $\boldsymbol{x}=B\boldsymbol{x}+\boldsymbol{q}$，也是不动点迭代的特例。

不动点存在唯一性定理。 设 $g\in C[a,b]$，且

$$a\le g(x)\le b,\qquad \forall x\in[a,b].$$

则 g 在 $[a,b]$ 上至少有一个不动点。若进一步存在 $L\in[0,1)$，使

$$|g(x)-g(y)|\le L|x-y|,\qquad \forall x,y\in[a,b],$$

则该不动点唯一。这一不等式称为 Lipschitz 条件；当 $L<1$ 时，g 是压缩映射。

证明。 令 $\psi(x)=g(x)-x$。由 $\psi(a)\ge 0$、$\psi(b)\le 0$ 及连续性，存在 x^{*} 使 $\psi(x^{*})=0$。若有两个不动点 $x_1^{*}\neq x_2^{*}$，则

$$|x_1^{*}-x_2^{*}|=|g(x_1^{*})-g(x_2^{*})|\le L|x_1^{*}-x_2^{*}|<|x_1^{*}-x_2^{*}|,$$

矛盾，故唯一。

导数判据。 若 $g\in C^{1}[a,b]$，$g([a,b])\subseteq[a,b]$，且 $|g'(x)|\le L<1$，则不动点存在且唯一。由中值定理，

$$|g(x)-g(y)|=|g'(\eta)|\,|x-y|\le L|x-y|.$$

实际问题中，导数上界通常比直接验证 Lipschitz 条件方便。标量线性迭代 $g(x)=Bx+q$ 的对应条件为 $|B|<1$；向量情形则应使用相容矩阵范数。

例：方程 $x^{2}+x-10=0$ 可产生不同的迭代格式，取 $x_0=1$：

$$\begin{aligned}
&g_1(x)=10-x^{2}, && x_{k+1}=10-x_k^{2},\\
&g_2(x)=x^{2}+2x-10, && x_{k+1}=x_k^{2}+2x_k-10,\\
&g_3(x)=\sqrt{10-x}, && x_{k+1}=\sqrt{10-x_k}.
\end{aligned}$$

【补全】第三种写法只寻找非负根。正根为 $(-1+\sqrt{41})/2$；前两种格式在该根处的导数绝对值大于 1，第三种小于 1。等价方程的不同改写可能产生完全不同的收敛行为。

2.2 全局收敛与局部收敛

（原稿第 3 页）

全局收敛定理。 若 $g \in C[a,b]$，$g([a,b]) \subseteq [a,b]$，且 g 满足常数为 $L<1$ 的压缩条件，则对任意 $x_0 \in [a,b]$，迭代序列均收敛到唯一不动点 x^*。

证明。

$$\begin{aligned} |x_k - x^*| &= |g(x_{k-1}) - g(x^*)| \\ &\le L|x_{k-1}-x^*| \le \cdots \le L^k |x_0 - x^*| \to 0. \end{aligned}$$

这里的“全局”是相对于所讨论的区间 $[a,b]$ 而言。

局部收敛的定义。 若 $g(x^*)=x^*$，且存在邻域 $U(x^*,\delta)\subset I$，使每个 $x_0 \in U(x^*,\delta)$ 产生的序列均留在该邻域内，并收敛于 x^*，则称迭代在 x^* 处局部收敛。

局部收敛判据。 设 g' 在 x^* 的某邻域内存在且连续，且 $|g'(x^*)|<1$，则 $x_{k+1}=g(x_k)$ 在 x^* 处局部收敛。

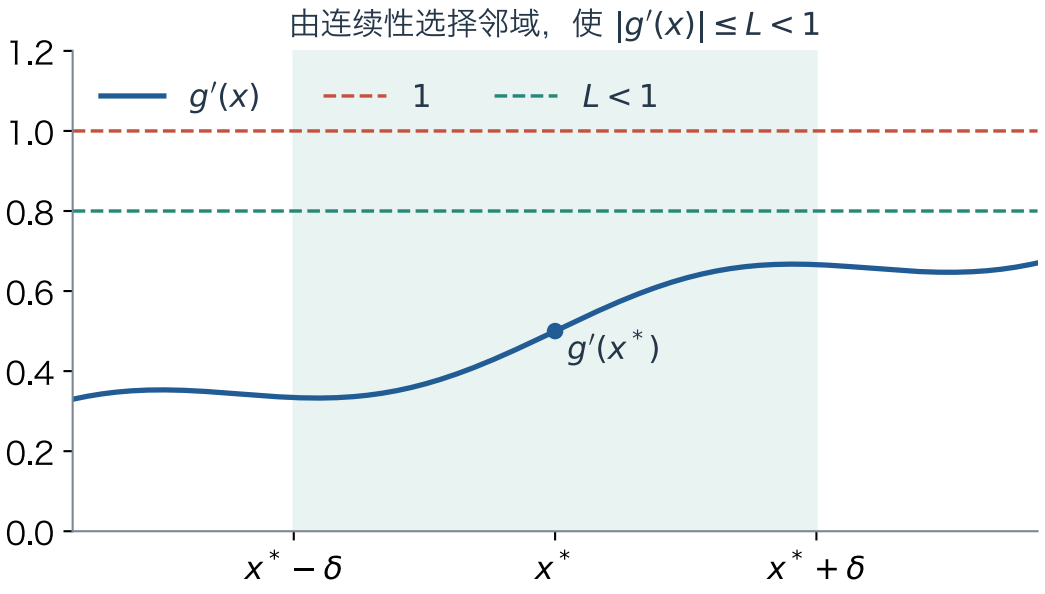
证明。 取

$$\varepsilon = \frac{1-|g'(x^*)|}{2}, \qquad L = |g'(x^*)| + \varepsilon < 1.$$

由 g' 连续，可选充分小的闭邻域，使其中 $|g'(x)| \le L$。于是

$$|g(x)-x^*| = |g(x)-g(x^*)| \le L|x-x^*| \le L\delta < \delta.$$

该邻域在 g 下保持不变，且 g 在其中为压缩映射，故可应用全局收敛定理。



导数连续性给出的局部压缩邻域

原稿列出的要点为：不动点存在；迭代函数的导数在附近存在且连续；$|g'(x^*)|<1$。

【校正】原稿将 $|g'(x^*)|>1$ 写成“任意附近初值均发散”。准确说法是：该不动点局部排斥，在充分小邻域内，非零误差会被放大，因此一般附近初值不能收敛到它；$x_0=x^*$ 等恰好到达不动点的特殊初值须排除。

2.3 收敛阶与收敛速度

（原稿第 4 页）

设 $x_k \to x^*$，记误差 $e_k = x_k - x^*$。若存在实数 $p \geq 1$ 和常数 $C > 0$，使

$$\lim_{k \to \infty} \frac{|e_{k+1}|}{|e_k|^p} = C,$$

则称序列为 p 阶收敛，C 称为渐近误差常数。当 $p = 1$ 时，还要求 $0 < C < 1$。

- $p = 1$：线性收敛。
- $p = 2$：平方收敛或二阶收敛。
- $p > 1$：超线性收敛。

【补全】更一般地，若 $|e_{k+1}|/|e_k| \to 0$，即称超线性收敛，并不一定存在某个固定的 $p > 1$。

例如二阶收敛时，若 $|e_k| \approx 10^{-2}$，则

$$|e_{k+1}| \approx C \cdot 10^{-4}, \quad |e_{k+2}| \approx C^3 \cdot 10^{-8}, \quad |e_{k+3}| \approx C^7 \cdot 10^{-16}.$$

进入渐近收敛阶段后，更高的收敛阶通常意味着更快的误差下降。

导数与收敛阶定理。 设整数 $p > 1$，$g^{(p)}$ 在 x^* 的邻域内连续，$g(x^*) = x^*$，且

$$g'(x^*) = g''(x^*) = \cdots = g^{(p-1)}(x^*) = 0, \qquad g^{(p)}(x^*) \neq 0.$$

则迭代局部 p 阶收敛，并且

$$\lim_{k \to \infty} \frac{e_{k+1}}{e_k^p} = \frac{g^{(p)}(x^*)}{p!}, \qquad C = \frac{|g^{(p)}(x^*)|}{p!}.$$

证明。 $g'(x^*) = 0$ 保证局部收敛。Taylor 展开给出

$$g(x_k) = g(x^*) + \sum_{j=1}^{p-1} \frac{g^{(j)}(x^*)}{j!}(x_k - x^*)^j + \frac{g^{(p)}(\xi_k)}{p!}(x_k - x^*)^p.$$

前 $p - 1$ 阶项均为零，因此

$$e_{k+1} = \frac{g^{(p)}(\xi_k)}{p!} e_k^p.$$

由 $\xi_k \to x^*$ 与连续性即可得结论。给定迭代函数后，可以计算其在不动点处的各阶导数，寻找第一个非零导数以判断收敛阶。

3 迭代加速

3.1 Aitken 加速方法

（原稿第 5 页）

对线性收敛序列，若充分大时有 $e_{k+1}\approx \lambda e_k$、$e_{k+2}\approx \lambda e_{k+1}$，消去 λ 得

$$\frac{x_{k+2}-x^*}{x_{k+1}-x^*}\approx\frac{x_{k+1}-x^*}{x_k-x^*}.$$

于是

$$x^*\approx\frac{x_kx_{k+2}-x_{k+1}^2}{x_{k+2}-2x_{k+1}+x_k}.$$

定义 Aitken Δ^2 加速序列

$$\bar{x}_k=x_k-\frac{(x_{k+1}-x_k)^2}{x_{k+2}-2x_{k+1}+x_k}=\frac{x_kx_{k+2}-x_{k+1}^2}{x_{k+2}-2x_{k+1}+x_k}.$$

该变换利用原序列的连续三项，得到更好的近似值；它可以作为对既有序列的后处理。

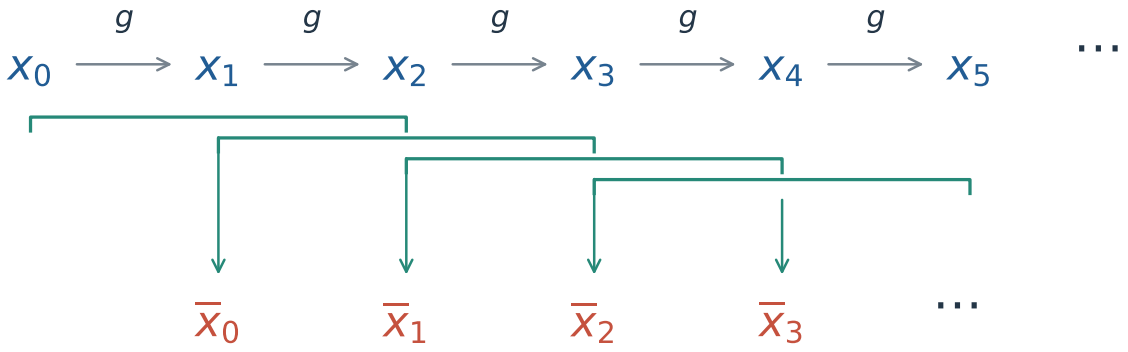
定理。 设 $e_k\neq 0$，且存在 $0<|\lambda|<1$，满足

$$e_{k+1}=(\lambda+\delta_k)e_k,\qquad \delta_k\to 0.$$

则充分大时 $\bar{x}_k$ 有定义，且

$$\lim_{k\to\infty}\frac{\bar{x}_k-x^*}{x_k-x^*}=0.$$

【校正】此处需使用带符号的渐近比值 λ，它可以为负；由绝对误差比值趋于 C 不能直接推出 $e_{k+1}\approx Ce_k$。定理中应排除的是 $e_k=0$，而非单纯要求 $x_k\neq 0$。



Aitken 由原序列连续三项生成加速序列

3.2 Steffensen 迭代法

（原稿第 6 – 7 页）

将 Aitken 加速与不动点迭代结合，每轮执行

$$\begin{aligned} y_k &= g(x_k), \\ z_k &= g(y_k), \\ x_{k+1} &= x_k - \frac{(y_k - x_k)^2}{z_k - 2y_k + x_k} = \varphi(x_k). \end{aligned}$$

其中

$$\varphi(x) = x - \frac{[g(x) - x]^2}{g(g(x)) - 2g(x) + x} = \frac{x g(g(x)) - [g(x)]^2}{g(g(x)) - 2g(x) + x}.$$

与 Aitken 的后处理不同，Steffensen 将加速后的值直接作为下一轮初值。

不动点关系。 原稿意图说明 φ 与 g 有相同不动点。应注意：若 $g(x^*) = x^*$，上式的分子、分母均为零，须作连续延拓。

若 g' 连续且 $g'(x^*) \neq 1$，则

$$\lim_{x \to x^*} \frac{[g(x) - x]^2}{g(g(x)) - 2g(x) + x} = 0.$$

例如用 L'Hôpital 法则，分子导数为 $2[g(x) - x][g'(x) - 1]$，分母导数在 x^* 处为

$$g'(g(x^*))g'(x^*) - 2g'(x^*) + 1 = [g'(x^*) - 1]^2 \neq 0.$$

故定义延拓值 $\varphi(x^*) = x^*$。反过来，在上述公式有意义或可作相应连续延拓的情形，固定点方程化简为 $[g(x) - x]^2 = 0$。

【校正】原稿直接在 x^* 处代入 $0/0$ 并使用 L'Hôpital 法则；这里改为计算极限和连续延拓。在实际算法中，若 $y_k = x_k$ 应直接停止；若分母为零而尚未收敛，应更换步骤，不能直接相除。

收敛速度。 在所需高阶导数存在且连续、非退化的情况下：

- 原迭代线性收敛且 $g'(x^*) \neq 1$ 时，Steffensen 至少二阶收敛；通常为二阶。
- 原迭代为整数 $p > 1$ 阶收敛时，通常提升为 $2p - 1$ 阶。

【补全】原稿未注明非退化条件；当主误差项恰好消失时，实际阶数可能更高，甚至有限步达到精确解。

4 牛顿法

4.1 公式与几何意义

（原稿第 7 页）

对根 x^*，在近似值 x_k 处作 Taylor 展开：

$$0 = f(x^*) = f(x_k) + f'(x_k)(x^* - x_k) + \frac{1}{2} f''(\xi_k)(x^* - x_k)^2.$$

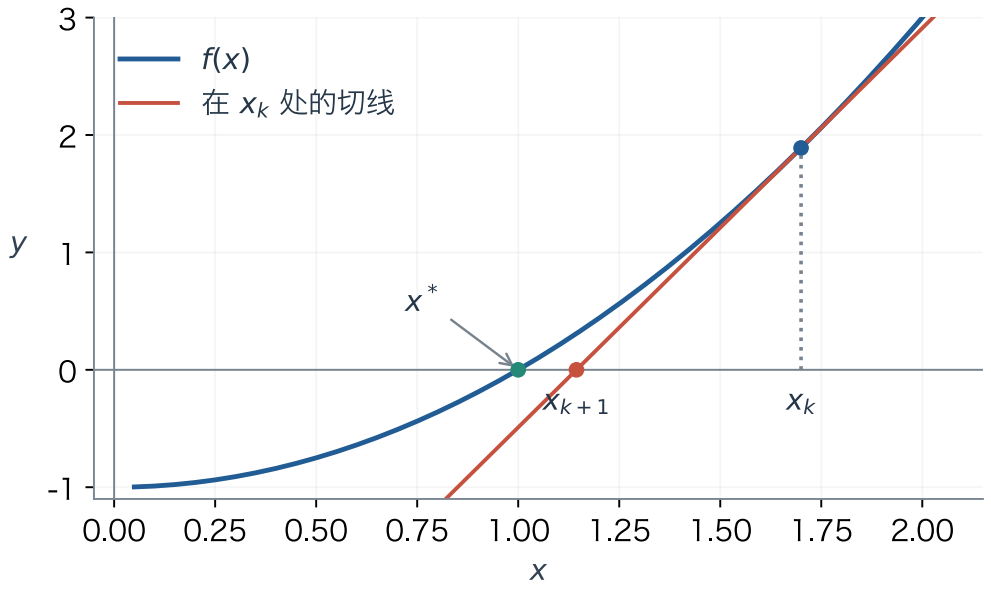
当 x_k 足够接近 x^* 时，忽略二阶项，得到牛顿迭代

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} = g(x_k), \qquad g(x) = x - \frac{f(x)}{f'(x)}.$$

几何上，用曲线在 $(x_k, f(x_k))$ 处的切线

$$y = f(x_k) + f'(x_k)(x - x_k)$$

代替曲线，以切线与 x 轴的交点作为下一次近似值。



牛顿法以切线零点更新近似解

4.2 局部收敛性质与证明

（原稿第 7 – 8 页）

若 $f \in C^2$，$f(x^*) = 0$ 且 $f'(x^*) \neq 0$，则充分接近 x^* 的初值产生的牛顿序列收敛于 x^*，并有

$$\lim_{k \to \infty} \frac{|x_{k+1} - x^*|}{|x_k - x^*|^2} = \frac{|f''(x^*)|}{2|f'(x^*)|} = C^*.$$

若 $f''(x^*) \neq 0$，收敛阶恰为 2；若 $f''(x^*) = 0$，可能更快。

证明。 由上述 Taylor 展开，

$$x^* = x_k - \frac{f(x_k)}{f'(x_k)} - \frac{f''(\xi_k)}{2f'(x_k)}(x^* - x_k)^2,$$

从而

$$e_{k+1} = \frac{f''(\xi_k)}{2f'(x_k)} e_k^2.$$

任取 $C > C^{*}$，由连续性可在足够小邻域内保证 $|f''(\xi)/(2f'(x))| \le C$。若 x_N 位于该邻域且 $|e_N| < 1/C$，则

$$|e_{N+1}| \le C|e_N|^2 < |e_N|.$$

后续迭代保持在邻域内。令 $q = C|e_N| < 1$，则 $|e_{k+1}| \le q|e_k|$，故 $e_k \to 0$。再对误差关系取极限，得到渐近误差常数。

4.3 简单根与重根的例子

（原稿第 8 – 9 页）

例 1 计算 $\sqrt{2}$。取 $f(x) = x^2 - 2$，则

$$x_{k+1} = x_k - \frac{x_k^2 - 2}{2x_k} = \frac{x_k}{2} + \frac{1}{x_k}.$$

从 $x_0 = 2$ 出发，

k	x_k	$\lvert x_k - \sqrt{2}\rvert$
0	2	约 0.585786
1	1.5	约 0.085786
2	1.416666667	约 0.002453

序列收敛到 $\sqrt{2}$；若从 $x_0 = -2$ 出发，则依次得到 $-1.5, -1.416666667, \dots$，收敛到 $-\sqrt{2}$。表中将原稿的粗略小数补为较精确值。

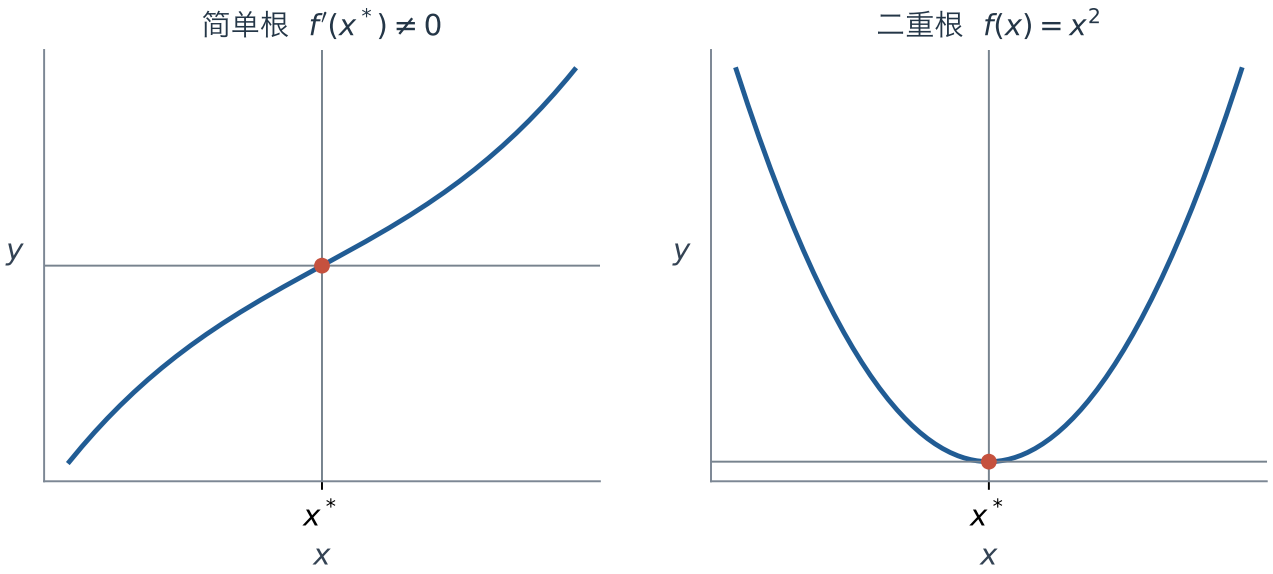
例 2 求 $x^2 = 0$ 的根。此时 $x^{*} = 0$ 是二重根，牛顿迭代仍可在 $x_k \neq 0$ 时使用：

$$x_{k+1} = x_k - \frac{x_k^2}{2x_k} = \frac{x_k}{2}.$$

取 $x_0 = 2$，则 $x_1 = 1$、$x_2 = 1/2$、$x_3 = 1/4$，且

$$x_k = e_k = 2^{1-k}, \qquad \frac{e_{k+1}}{e_k} = \frac{1}{2}.$$

因此仅线性收敛。其原因是 $f'(x^{*}) = 0$，不满足简单根情形的平方收敛条件。



简单根与重根的曲线形态

例 3 求 $x^N=0$ 的根。 对整数 $N>2$，

$$x_{k+1}=x_k-\frac{x_k^N}{Nx_k^{N-1}}=\left(1-\frac{1}{N}\right)x_k.$$

重数越大，线性收敛因子 $1-1/N$ 越接近 1。

【补全】若 $f(x)=(x-x^*)^m h(x)$，$h(x^*)\neq 0$，则普通牛顿法在 $m>1$ 重根附近通常只有线性收敛，因子为 $(m-1)/m$。原稿页边关于因式分解的备注按此写明。

5 标量拟牛顿方法与构造例题

5.1 常数斜率法与割线法

（原稿第 9 页）

牛顿法需显式计算 $f'(x_k)$。若以易计算的近似量 $a_k\approx f'(x_k)$ 替代，则得到拟牛顿思想：

$$x_{k+1}=x_k-\frac{f(x_k)}{a_k}.$$

常数斜率法。 取非零常数 a，

$$x_{k+1}=x_k-\frac{f(x_k)}{a}.$$

原稿称其为“常数梯度法”。

割线法。 用差商近似导数，

$$a_k=\frac{f(x_k)-f(x_{k-1})}{x_k-x_{k-1}},$$

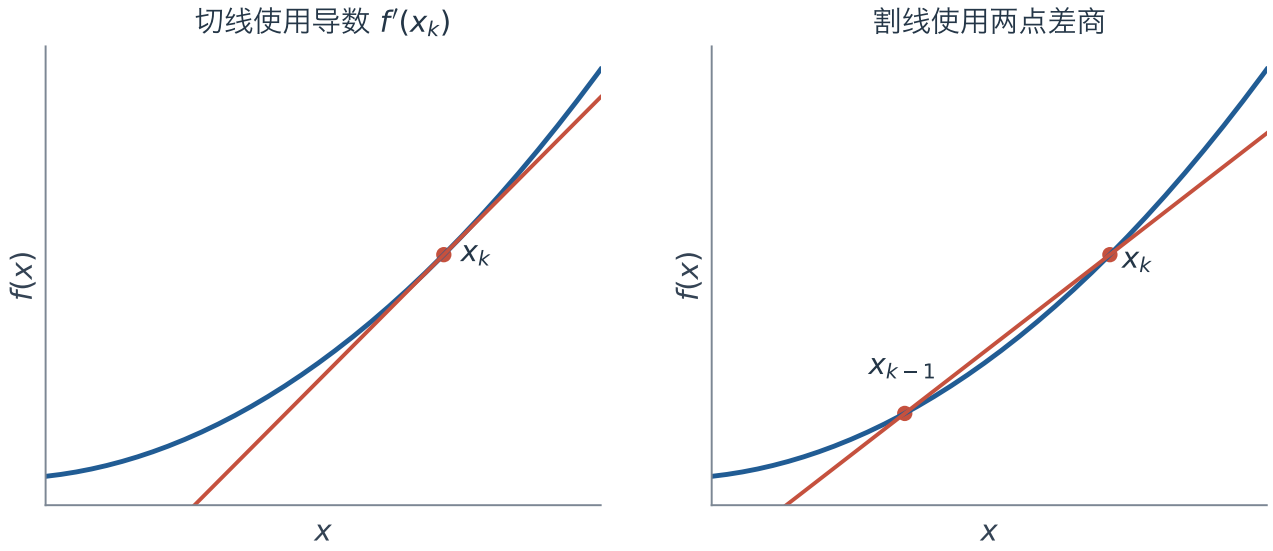
得到

$$x_{k+1} = x_k - \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})} f(x_k).$$

割线法需要两个初值 x_0, x_1。在简单根附近并满足通常的光滑性与非退化条件时，

$$\lim_{k\to\infty} \frac{e_{k+1}}{e_k e_{k-1}} = \frac{f''(x^*)}{2f'(x^*)}, \qquad p = \frac{1+\sqrt{5}}{2}.$$

【补全】如果 $f''(x^*) = 0$，上面的常数可能为零，精确收敛阶需另作分析。



切线斜率与割线差商的比较

5.2 构造三阶局部收敛迭代

（原稿第 9 – 10 页）

设 x^* 为 f 的简单零点，考虑

$$x_{k+1} = \varphi(x_k), \qquad \varphi(x) = x - \gamma_1(x) f(x) - \gamma_2(x) f(x)^2.$$

希望选择 γ_1, γ_2，使 $\varphi'(x^*) = \varphi''(x^*) = 0$。牛顿法对应 $\gamma_1 = 1/f'$、$\gamma_2 = 0$；常数斜率法对应 $\gamma_1 = 1/a$、$\gamma_2 = 0$。

首先

$$\varphi' = 1 - \gamma_1' f - \gamma_1 f' - \gamma_2' f^2 - 2\gamma_2 f f'.$$

因 $f(x^*) = 0$、$f'(x^*) \neq 0$，令 $\varphi'(x^*) = 0$ 得 $\gamma_1(x^*) = 1/f'(x^*)$，可选

$$\gamma_1(x) = \frac{1}{f'(x)}.$$

于是

$$\varphi'(x) = \frac{f''}{(f')^2} f - \gamma_2' f^2 - 2\gamma_2 f f'.$$

在 x^* 处再求导，含 f 的项均消失，得到

$$\varphi''(x^*) = \frac{f''(x^*)}{f'(x^*)} - 2\gamma_2(x^*)[f'(x^*)]^2.$$

令其等于零，可选

$$\gamma_2(x) = \frac{f''(x)}{2[f'(x)]^3}.$$

最终构造为

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} - \frac{f''(x_k)f(x_k)^2}{2[f'(x_k)]^3}.$$

【校正】$(1/f')' = -f''/(f')^2$，原稿页边漏写负号。上述构造在相应光滑性条件下至少三阶收敛；要称“恰为三阶”，还需 $\varphi'''(x^*) \neq 0$。

5.3 同一个根的两种牛顿构造

（原稿第 10 页）

计算 $\sqrt[n]{a}$，其中 $a>0$、整数 $n \geq 2$。可选择

$$f_1(x) = x^n - a, \qquad f_2(x) = 1 - \frac{a}{x^n}.$$

对应的牛顿迭代分别为

$$x_{k+1} = x_k - \frac{x_k^n - a}{n x_k^{n-1}} = \frac{n-1}{n}x_k + \frac{a}{n x_k^{n-1}},$$
$$x_{k+1} = x_k - \frac{1 - a/x_k^n}{n a / x_k^{n+1}} = \frac{n+1}{n}x_k - \frac{x_k^{n+1}}{n a}.$$

在正根 $x^* = a^{1/n}$ 处，渐近误差常数为

$$C_1 = \frac{|f_1''(x^*)|}{2|f_1'(x^*)|} = \frac{n-1}{2a^{1/n}}, \qquad C_2 = \frac{|f_2''(x^*)|}{2|f_2'(x^*)|} = \frac{n+1}{2a^{1/n}}.$$

两者在该根附近均平方收敛，但误差常数不同。

6 非线性方程组与向量函数

（原稿第 11 页）

由 n 个未知量和 n 个非线性方程组成的系统写为

$$F(\boldsymbol{x}) = \mathbf{0}, \qquad \boldsymbol{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \qquad F(\boldsymbol{x}) = \begin{bmatrix} f_1(x_1,\dots,x_n) \\ f_2(x_1,\dots,x_n) \\ \vdots \\ f_n(x_1,\dots,x_n) \end{bmatrix}.$$

6.1 连续性与 Fréchet 导数

更一般地，设 $F:D\subset\mathbb{R}^n\to\mathbb{R}^m$。当各分量 f_i 在 $\boldsymbol{x}$ 处连续时，F 在该点连续；各分量在 D 上连续则 F 在 D 上连续。

若 $\boldsymbol{x}$ 是 D 的内点，存在矩阵 $A\in\mathbb{R}^{m\times n}$ 使

$$\lim_{\boldsymbol{h}\to\boldsymbol{0}}\frac{\|F(\boldsymbol{x}+\boldsymbol{h})-F(\boldsymbol{x})-A\boldsymbol{h}\|}{\|\boldsymbol{h}\|}=0,$$

则称 F 在 $\boldsymbol{x}$ 处 Fréchet 可微，A 为其导数，记作 $F'(\boldsymbol{x})$。

取 $\boldsymbol{h}=\varepsilon\boldsymbol{e}_j$，可得 $A_{ij}=\partial f_i/\partial x_j$。因此

$$F'(\boldsymbol{x})=J_F(\boldsymbol{x})=\begin{bmatrix}\dfrac{\partial f_1}{\partial x_1}&\cdots&\dfrac{\partial f_1}{\partial x_n}\\ \vdots&\ddots&\vdots\\ \dfrac{\partial f_m}{\partial x_1}&\cdots&\dfrac{\partial f_m}{\partial x_n}\end{bmatrix},$$

称为 Jacobian 矩阵，即雅可比矩阵。$m=1$ 时，导数是行向量 $\nabla f(\boldsymbol{x})^{\mathsf T}$。标量函数的二阶导数用 Hessian 矩阵表示：

$$\nabla^2 f(\boldsymbol{x})=\left[\frac{\partial^2 f}{\partial x_i\partial x_j}\right]_{i,j=1}^{n}.$$

6.2 压缩映射与不动点迭代

（原稿第 11 – 12 页）

将 $F(\boldsymbol{x})=\boldsymbol{0}$ 改写为 $\boldsymbol{x}=\Phi(\boldsymbol{x})$。若 $\boldsymbol{x}^*=\Phi(\boldsymbol{x}^*)$，则称 $\boldsymbol{x}^*$ 为不动点。迭代为

$$\boldsymbol{x}^{k+1}=\Phi(\boldsymbol{x}^k).$$

若存在 $L\in[0,1)$，使

$$\|\Phi(\boldsymbol{x})-\Phi(\boldsymbol{y})\|\le L\|\boldsymbol{x}-\boldsymbol{y}\|,\qquad\forall\boldsymbol{x},\boldsymbol{y}\in D,$$

则称 Φ 在这一范数下是压缩映射。

全局收敛。 若非空闭集 $D_0\subseteq D$ 满足 $\Phi(D_0)\subseteq D_0$，且 Φ 在 D_0 上为压缩映射，则 D_0 中存在唯一不动点，对任意 $\boldsymbol{x}^0\in D_0$，迭代都收敛到它。

【补全】原稿此处未明确写出 D_0 闭且非空；在有限维空间中该条件保证完备性，是应用压缩映射定理所需的条件。

局部收敛。 若存在 $\boldsymbol{x}^*$ 的邻域 S，使从 S 内任意初值开始，迭代点始终在 S 中且趋于 $\boldsymbol{x}^*$，则称局部收敛。

定理 1。 设 $\boldsymbol{x}^*=\Phi(\boldsymbol{x}^*)$，且对某闭球

$$S=\{\boldsymbol{x}:\|\boldsymbol{x}-\boldsymbol{x}^*\|\le\delta\}\subset D$$

有压缩条件，常数 $L<1$。由

$$\|\Phi(\boldsymbol{x})-\boldsymbol{x}^*\|\le L\|\boldsymbol{x}-\boldsymbol{x}^*\|\le L\delta<\delta$$

知 $\Phi(S)\subset S$，从而所有 $\boldsymbol{x}^0\in S$ 产生的序列均收敛。

定理 2。 若 Φ 在不动点 $\boldsymbol{x}^*$ 处 Fréchet 可微，且

$$\rho\big(\Phi'(\boldsymbol{x}^*)\big)<1,$$

则存在足够小邻域，邻域内任意初值的迭代均收敛到 $\boldsymbol{x}^*$。

【校正】原稿页边写道“对于某一种范数压缩，则另一种范数也压缩”。有限维范数等价保证同一个序列的收敛性不依赖范数，但压缩常数小于 1 的性质不一定在任意给定范数下保持。谱半径小于 1 可保证存在某个相容范数使导数范数小于 1，结合可微余项可建立局部误差收缩。

7 非线性方程组的牛顿法

7.1 迭代公式与实际计算

（原稿第 12 页）

将 $F(\boldsymbol{x}^*)=\boldsymbol{0}$ 在 $\boldsymbol{x}^k$ 附近线性化：

$$\boldsymbol{0}\approx F(\boldsymbol{x}^k)+F'(\boldsymbol{x}^k)(\boldsymbol{x}^*-\boldsymbol{x}^k).$$

若雅可比矩阵可逆，则

$$\boldsymbol{x}^{k+1}=\boldsymbol{x}^k-[F'(\boldsymbol{x}^k)]^{-1}F(\boldsymbol{x}^k).$$

这里上标 k 表示迭代次数，下标 i 表示向量分量。实际计算通常不显式求逆，而是：

1. 解线性方程组 $F'(\boldsymbol{x}^k)\boldsymbol{\Delta}^k=F(\boldsymbol{x}^k)$。
2. 更新 $\boldsymbol{x}^{k+1}=\boldsymbol{x}^k-\boldsymbol{\Delta}^k$。

例。 求解

$$\begin{cases} -x_1^3+x_2=0,\\ x_1^2+x_2^2-1=0, \end{cases}\qquad \boldsymbol{x}^0=\begin{bmatrix}1\\1\end{bmatrix}.$$

对应雅可比矩阵为

$$F'(\boldsymbol{x})=\begin{bmatrix}-3x_1^2 & 1\\ 2x_1 & 2x_2\end{bmatrix}.$$

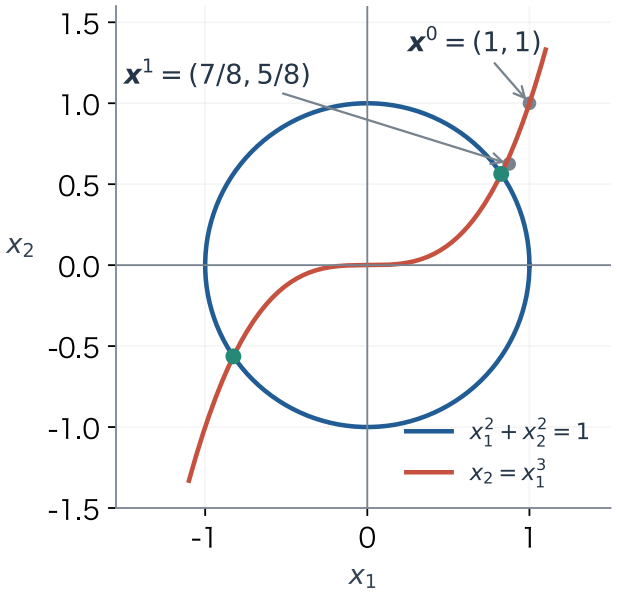
第一步解

$$\begin{bmatrix}-3 & 1\\ 2 & 2\end{bmatrix}\begin{bmatrix}\Delta_1\\ \Delta_2\end{bmatrix}=\begin{bmatrix}0\\ 1\end{bmatrix},$$

得 $\boldsymbol{\Delta}^0=(1/8,3/8)^{\mathsf T}$，从而

$$\boldsymbol{x}^1=\begin{bmatrix}7/8\\ 5/8\end{bmatrix}.$$

【补全与校正】原稿止于第一步线性系统，末尾写成加号。按前文 $F'\Delta=F$ 的约定，更新应为减号；上式补出求解结果。



三次曲线与单位圆的两个交点

7.2 牛顿法的局部超线性收敛

（原稿第 13 – 14 页）

定理。 设 $F: D \subset \mathbb{R}^n \to \mathbb{R}^n$，$F(\boldsymbol{x}^*) = \boldsymbol{0}$；$F$ 在 $\boldsymbol{x}^*$ 的开邻域内可微，F' 在 $\boldsymbol{x}^*$ 处连续，且 $J_* = F'(\boldsymbol{x}^*)$ 可逆。则存在充分小邻域，使：

1. 邻域内所有点的雅可比矩阵均可逆。
2. 从该邻域内初值出发的牛顿序列收敛于 $\boldsymbol{x}^*$，且超线性收敛。

证明。 记 $\alpha = \|J_*^{-1}\|$。选邻域使 $\|F'(\boldsymbol{x}) - J_*\| \le \varepsilon$，且 $\alpha\varepsilon < 1$。由矩阵扰动估计，

$$
\begin{aligned}
\|F'(\boldsymbol{x})^{-1}\| &\le \frac{\|J_*^{-1}\|}{1 - \|J_*^{-1}\|\,\|F'(\boldsymbol{x}) - J_*\|} \\
&\le \frac{\alpha}{1 - \alpha\varepsilon} = M.
\end{aligned}
$$

例如可先取 $\varepsilon < 1/(2\alpha)$。记 $\boldsymbol{e}_k = \boldsymbol{x}^k - \boldsymbol{x}^*$、$J_k = F'(\boldsymbol{x}^k)$，则

$$
\begin{aligned}
\boldsymbol{e}_{k+1} &= \boldsymbol{e}_k - J_k^{-1} F(\boldsymbol{x}^k) \\
&= -J_k^{-1}\left[F(\boldsymbol{x}^k) - J_k \boldsymbol{e}_k\right] \\
&= -J_k^{-1}\left[F(\boldsymbol{x}^k) - J_*\boldsymbol{e}_k - (J_k - J_*)\boldsymbol{e}_k\right].
\end{aligned}
$$

由可微性，

$$
F(\boldsymbol{x}^k) = F(\boldsymbol{x}^*) + J_*\boldsymbol{e}_k + o(\|\boldsymbol{e}_k\|).
$$

因此

$$
\|\boldsymbol{e}_{k+1}\| \le M\left[o(\|\boldsymbol{e}_k\|) + \|J_k - J_*\|\,\|\boldsymbol{e}_k\|\right].
$$

缩小邻域可使误差比小于某个 $q<1$，先得到迭代留在邻域内且收敛；再用 $J_k\to J_*$，得

$$\lim_{k\to\infty}\frac{\|\boldsymbol{e}_{k+1}\|}{\|\boldsymbol{e}_k\|}=0.$$

【校正】原稿在只假设一阶导数连续的条件下写出 $O(\|\boldsymbol{e}_k\|^2)$，此时应使用 $o(\|\boldsymbol{e}_k\|)$。若进一步假设雅可比矩阵局部 Lipschitz 连续，则可得到二次误差界和局部平方收敛。

8 非线性方程组的拟牛顿法

（原稿第 14 – 15 页）

8.1 割线条件与秩一修正

用矩阵 A_k 近似 $F'(\boldsymbol{x}^k)$，迭代为

$$\boldsymbol{x}^{k+1}=\boldsymbol{x}^k-A_k^{-1}F(\boldsymbol{x}^k).$$

标量割线法满足 $a_k(x_k-x_{k-1})=f(x_k)-f(x_{k-1})$。推广到向量，要求

$$A_k\boldsymbol{p}=\boldsymbol{q},\qquad \boldsymbol{p}=\boldsymbol{x}^k-\boldsymbol{x}^{k-1},\quad \boldsymbol{q}=F(\boldsymbol{x}^k)-F(\boldsymbol{x}^{k-1}).$$

这个条件不能唯一确定 $n\times n$ 矩阵，因此考虑简单修正 $A_k=A_{k-1}+\Delta A_{k-1}$。

线性模型下的秩一更新。 若 $F(\boldsymbol{u})=D\boldsymbol{u}+\boldsymbol{b}$，则 $\boldsymbol{q}=D\boldsymbol{p}$。对任意 A 与非零 $\boldsymbol{p}$，定义

$$A^{+}=A+\frac{(\boldsymbol{q}-A\boldsymbol{p})\boldsymbol{p}^{\mathsf T}}{\|\boldsymbol{p}\|_2^2}.$$

则 $A^{+}\boldsymbol{p}=D\boldsymbol{p}=\boldsymbol{q}$，且

$$\|A^{+}-D\|_2\le\|A-D\|_2.$$

【补全】因为

$$A^{+}-D=(A-D)\left(I-\frac{\boldsymbol{p}\boldsymbol{p}^{\mathsf T}}{\|\boldsymbol{p}\|_2^2}\right),$$

右侧括号是正交投影，谱范数不超过 1，所以成立。

8.2 Broyden 秩一方法

给定初始近似雅可比矩阵，逐步执行

$$\begin{aligned}
\boldsymbol{p}&=\boldsymbol{x}^k-\boldsymbol{x}^{k-1},\\
\boldsymbol{q}&=F(\boldsymbol{x}^k)-F(\boldsymbol{x}^{k-1}),\\
A_k&=A_{k-1}+\frac{(\boldsymbol{q}-A_{k-1}\boldsymbol{p})\boldsymbol{p}^{\mathsf T}}{\boldsymbol{p}^{\mathsf T}\boldsymbol{p}},\\
\boldsymbol{x}^{k+1}&=\boldsymbol{x}^k-A_k^{-1}F(\boldsymbol{x}^k).
\end{aligned}$$

若每一步重新求逆或从头解一般稠密线性系统，计算量可达 $O(n^3)$；可以通过逆矩阵秩一更新降低每步代价。

8.3 Sherman—Morrison 公式

设 A 可逆。当且仅当 $1+\boldsymbol{v}^{\mathsf{T}}A^{-1}\boldsymbol{u}\neq 0$ 时，$A+\boldsymbol{u}\boldsymbol{v}^{\mathsf{T}}$ 可逆，且

$$(A+\boldsymbol{u}\boldsymbol{v}^{\mathsf{T}})^{-1}=A^{-1}-\frac{A^{-1}\boldsymbol{u}\boldsymbol{v}^{\mathsf{T}}A^{-1}}{1+\boldsymbol{v}^{\mathsf{T}}A^{-1}\boldsymbol{u}}.$$

在 Broyden 更新中，取

$$\boldsymbol{u}=\frac{\boldsymbol{q}-A\boldsymbol{p}}{\|\boldsymbol{p}\|_2},\qquad \boldsymbol{v}=\frac{\boldsymbol{p}}{\|\boldsymbol{p}\|_2}.$$

记 $B=A^{-1}$，代入并化简：

$$\begin{aligned}(A^{+})^{-1}&=B-\frac{(B\boldsymbol{q}-\boldsymbol{p})\boldsymbol{p}^{\mathsf{T}}B}{\|\boldsymbol{p}\|_2^2+\boldsymbol{p}^{\mathsf{T}}B(\boldsymbol{q}-A\boldsymbol{p})}\\&=B+\frac{(\boldsymbol{p}-B\boldsymbol{q})\boldsymbol{p}^{\mathsf{T}}B}{\boldsymbol{p}^{\mathsf{T}}B\boldsymbol{q}}.\end{aligned}$$

8.4 逆矩阵形式的 Broyden 方法

以 $B_k\approx F'(\boldsymbol{x}^k)^{-1}$ 为迭代变量，可写为

$$\begin{aligned}\boldsymbol{p}^k&=-B_kF(\boldsymbol{x}^k),\\\boldsymbol{x}^{k+1}&=\boldsymbol{x}^k+\boldsymbol{p}^k,\\\boldsymbol{q}^k&=F(\boldsymbol{x}^{k+1})-F(\boldsymbol{x}^k),\\B_{k+1}&=B_k+\frac{(\boldsymbol{p}^k-B_k\boldsymbol{q}^k)(\boldsymbol{p}^k)^{\mathsf{T}}B_k}{(\boldsymbol{p}^k)^{\mathsf{T}}B_k\boldsymbol{q}^k}.\end{aligned}$$

可取 $B_0=F'(\boldsymbol{x}^0)^{-1}$，该初始逆矩阵仍需计算。更新要求分母非零，并满足逆割线条件 $B_{k+1}\boldsymbol{q}^k=\boldsymbol{p}^k$。

【校正】原稿最后一行更新式的分子写为 $(\boldsymbol{p}-B\boldsymbol{q})\boldsymbol{q}^{\mathsf{T}}B$，与前面的 Sherman – Morrison 推导不一致；正确项应为 $(\boldsymbol{p}-B\boldsymbol{q})\boldsymbol{p}^{\mathsf{T}}B$。这里给出的是前述 Broyden 雅可比更新的逆矩阵实现。